### 第5章 多元线性回归

#### 5.1 二元线性回归

一元回归很可能遗漏了其他因素。

比如,在关于教育投资回报率的研究中,将工资对数对教育年限回归。

工资还依赖于个人能力,而个人能力未包括在回归方程中,故被纳入扰动项。

1

能力强的人通常上学更久(二者正相关),故一元回归所估计的教育回报率事实上也包括了对能力的回报,导致估计出现偏差。

其他遗漏变量还包括年龄、工龄、性别、种族、相貌等,其中年龄与工龄可视为"在职培训"(on the job training)的代理变量,而在职培训是增加人力资本(human capital)的另一重要方式。

本章考虑多元回归。

首先考察二元回归。

$$y_i = \alpha + \beta x_{i1} + \gamma x_{i2} + \varepsilon_i \quad (i = 1, \dots, n)$$
 (5.1)

 $x_{i1}$ 与 $x_{i2}$ 为解释变量。 $\alpha$ 为截距项。

 $\beta$ 为在给定 $x_2$ 条件下, $x_1$ 对y的边际效应(忽略扰动项 $\varepsilon_i$ )。

 $\gamma$ 为在给定 $x_1$ 条件下, $x_2$ 对y的边际效应。

OLS 估计量的最优化问题仍为残差平方和最小化:

$$\min_{\hat{\alpha},\hat{\beta},\hat{\gamma}} \sum_{i=1}^{n} e_i^2 = \sum_{i=1}^{n} (y_i - \hat{\alpha} - \hat{\beta} x_{i1} - \hat{\gamma} x_{i2})^2$$
 (5.2)

寻找一个回归平面 $\hat{y}_i \equiv \hat{\alpha} + \hat{\beta} x_{1i} + \hat{\gamma} x_{2i}$ ,即估计参数 $\hat{\alpha}$ ,  $\hat{\beta}$ ,  $\hat{\gamma}$ ,使得所有样本点 $\{(x_{1i}, x_{2i}, y_i)\}_{i=1}^n$ 离此回归平面最近,参见图 5.1。

将表达式(5.2)分别对 $\hat{\alpha}$ ,  $\hat{\beta}$ ,  $\hat{\gamma}$ 求偏导数,可得此最小化问题的一阶条件,求解可获得 $\hat{\alpha}$ ,  $\hat{\beta}$ ,  $\hat{\gamma}$  的 OLS 估计量。

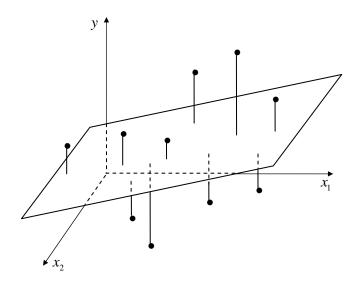


图 5.1 二元线性回归的示意图

例 (Cobb-Douglas 生产函数)

Cobb and Douglas (1928)使用美国 1899-1922 年制造业产出(y)、资本(k)与劳动力(l)的数据,估计如下生产函数:

$$y_{t} = \alpha k_{t}^{\beta} l_{t}^{\gamma} e^{\varepsilon_{t}}$$
 (5.3)

 $e^{\epsilon_t}$ 为乘积形式的扰动项,下标 t 表示时间(年)。

两边取对数,可转换为线性模型:

$$\ln y_t = \ln \alpha + \beta \ln k_t + \gamma \ln l_t + \varepsilon_t \tag{5.4}$$

数据集 cobb\_douglas.dta 提供了 Cobb and Douglas (1928)的原始数据。

首先看数据集中的观测值。

- . use cobb\_douglas.dta, clear
- . list

|     | year | k   | 1   | У   | lnk      | lnl      | lny      |
|-----|------|-----|-----|-----|----------|----------|----------|
| 1.  | 1899 | 100 | 100 | 100 | 4.60517  | 4.60517  | 4.60517  |
| 2.  | 1900 | 107 | 105 | 101 | 4.672829 | 4.65396  | 4.61512  |
| 3.  | 1901 | 114 | 110 | 112 | 4.736198 | 4.70048  | 4.718499 |
| 4.  | 1902 | 122 | 118 | 122 | 4.804021 | 4.770685 | 4.804021 |
| 5.  | 1903 | 131 | 123 | 124 | 4.875197 | 4.812184 | 4.820282 |
| 6.  | 1904 | 138 | 116 | 122 | 4.927254 | 4.75359  | 4.804021 |
| 7.  | 1905 | 149 | 125 | 143 | 5.003946 | 4.828314 | 4.962845 |
| 8.  | 1906 | 163 | 133 | 152 | 5.09375  | 4.890349 | 5.02388  |
| 9.  | 1907 | 176 | 138 | 151 | 5.170484 | 4.927254 | 5.01728  |
| 10. | 1908 | 185 | 121 | 126 | 5.220356 | 4.795791 | 4.836282 |
| 11. | 1909 | 198 | 140 | 155 | 5.288267 | 4.941642 | 5.043425 |
| 12. | 1910 | 208 | 144 | 159 | 5.337538 | 4.969813 | 5.068904 |
| 13. | 1911 | 216 | 145 | 153 | 5.375278 | 4.976734 | 5.030438 |
| 14. | 1912 | 226 | 152 | 177 | 5.420535 | 5.02388  | 5.17615  |
| 15. | 1913 | 236 | 154 | 184 | 5.463832 | 5.036952 | 5.214936 |
| 16. | 1914 | 244 | 149 | 169 | 5.497168 | 5.003946 | 5.129899 |
| 17. | 1915 | 266 | 154 | 189 | 5.583496 | 5.036952 | 5.241747 |
| 18. | 1916 | 298 | 182 | 225 | 5.697093 | 5.204007 | 5.416101 |
| 19. | 1917 | 335 | 196 | 227 | 5.81413  | 5.278115 | 5.42495  |
| 20. | 1918 | 366 | 200 | 223 | 5.902633 | 5.298317 | 5.407172 |
| 21. | 1919 | 387 | 193 | 218 | 5.958425 | 5.26269  | 5.384495 |
| 22. | 1920 | 407 | 193 | 231 | 6.008813 | 5.26269  | 5.442418 |
| 23. | 1921 | 417 | 147 | 179 | 6.033086 | 4.990433 | 5.187386 |
| 24. | 1922 | 431 | 161 | 240 | 6.066108 | 5.081404 | 5.480639 |

变量k, l与y均将 1899年的取值标准化为 100(以 1899年为指数的基期),而 $\ln k$ ,  $\ln l$ 与 $\ln y$ 分别为其对数值。

在 Stata 中进行二元回归的命令为

. regress y x1 x2

其中,"y"为被解释变量,而"x1 x2"为解释变量。

对方程(5.4)进行二元回归估计,可输入命令:

.reg lny lnk lnl

| Source            | SS                       | df     | MS                       |       | Number of obs F(2, 21)    |                      |
|-------------------|--------------------------|--------|--------------------------|-------|---------------------------|----------------------|
| Model<br>Residual | 1.59622155<br>.070981736 |        | .798110773<br>.003380083 |       | Prob > F<br>R-squared     | = 0.0000<br>= 0.9574 |
| Total             | 1.66720328               | 23     | .072487099               |       | Adj R-squared<br>Root MSE | = 0.9534             |
| lny               | Coef.                    | Std. E | rr. t                    | P> t  | [95% Conf.                | Interval]            |
| lnk               | .2330537                 | .06352 | 98 3.67                  | 0.001 | .1009363                  | .3651711             |
| lnl               | .807278                  | .14507 | 62 5.56                  | 0.000 | .5055755                  | 1.108981             |
| _cons             | 1773099                  | .43429 | 33 -0.41                 | 0.687 | -1.080472                 | .7258525             |

lnk (资本对数)与 lnl (劳动力对数)的系数分别为 0.233 与 0.807,且拟合优度  $R^2$  高达 0.957。

根据回归结果,可得样本回归平面:

$$\widehat{\ln y_t} = -0.177 + 0.233 \ln k_t + 0.807 \ln l_t \qquad (5.5)$$

ln y, 为ln y, 的拟合值或预测值。

在 Stata 中,做完 OLS 回归后,可用命令 predict 来计算拟合值与残差。

. predict lny1
(option xb assumed; fitted values)

此命令将 lny 的拟合值记为"lny1"。

如要计算残差,并记为 e,可输入命令

. predict e, <u>r</u>esidual

选择项 "residual"表示计算残差(默认计算拟合值)。

将 lny 及其拟合值、残差同时列表。

. list lny lny1 e

|     | lny      | lny1     | e        |
|-----|----------|----------|----------|
| 1.  | 4.60517  | 4.613595 | 0084246  |
| 2.  | 4.61512  | 4.66875  | 0536295  |
| 3.  | 4.718499 | 4.721073 | 0025745  |
| 4.  | 4.804021 | 4.793554 | .010467  |
| 5.  | 4.820282 | 4.843644 | 0233621  |
| 6.  | 4.804021 | 4.808474 | 0044528  |
| 7.  | 4.962845 | 4.88667  | .0761749 |
| 8.  | 5.02388  | 4.957679 | .0662019 |
| 9.  | 5.01728  | 5.005354 | .0119254 |
| 10. | 4.836282 | 4.91085  | 074568   |
| 11. | 5.043425 | 5.04442  | 0009945  |
| 12. | 5.068904 | 5.078644 | 0097398  |
| 13. | 5.030438 | 5.093026 | 0625884  |
| 14. | 5.17615  | 5.141634 | .0345157 |
| 15. | 5.214936 | 5.162277 | .0526584 |
| 16. | 5.129899 | 5.143401 | 0135028  |
| 17. | 5.241747 | 5.190166 | .0515813 |
| 18. | 5.416101 | 5.351499 | .0646015 |
| 19. | 5.42495  | 5.438601 | 0136506  |
| 20. | 5.407172 | 5.475536 | 0683641  |
| 21. | 5.384495 | 5.459777 | 0752818  |
| 22. | 5.442418 | 5.47152  | 0291027  |
| 23. | 5.187386 | 5.25739  | 0700038  |
| 24. | 5.480639 | 5.338525 | .142114  |

更直观地,将产出对数及其拟合值画在一起(参见图 5.2):

. line lny lny1 year, lpattern(solid dash)

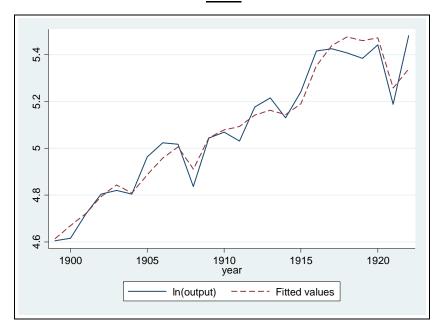


图 5.2 产出对数的实际值与预测值

产出对数的预测值与实际值相当吻合。

## 5.2 多元线性回归模型

一般的多元回归模型可写为

$$y_i = \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_K x_{iK} + \varepsilon_i \quad (i = 1, \dots, n)$$
 (5.6)

 $x_{i1}$ 为个体 i 的第 1 个解释变量, $x_{i2}$ 为个体 i 的第 2 个解释变量,以此类推。

一般地, $x_{ik}$ 的第一个下标表示个体i(共有n位个体,即样本容量为n),而第二个下标表示第k个解释变量 (共有K个解释变量)。

绝大多数情况下,都有常数项,故通常令 $x_{i1} \equiv 1$  (恒等于 1),则方程(5.6)简化为

$$y_i = \beta_1 + \beta_2 x_{i2} + \dots + \beta_K x_{iK} + \varepsilon_i \qquad (5.7)$$

多元线性回归模型可更方便地以矩阵表示。

此方程右边的主体部分为乘积之和,即 $\sum_{k=1}^K \beta_k x_{ik}$ ,其中 $x_{i1} \equiv 1$ 。

乘积之和可写为两个向量的内积。

定义列向量 $\mathbf{x}_i \equiv (1 \ x_{i2} \ \cdots \ x_{iK})'$ (包含个体i的全部解释变量)。

参数向量 $\boldsymbol{\beta} \equiv (\beta_1 \ \beta_2 \ \cdots \ \beta_K)'$ (包含全部回归系数),则  $\sum_{k=1}^K \beta_k x_{ik} = \boldsymbol{x}_i' \boldsymbol{\beta} \ \text{o} \ \text{可将原模型}(5.7)$ 写为

$$y_{i} = \begin{pmatrix} 1 & x_{i2} & \cdots & x_{iK} \end{pmatrix} \begin{pmatrix} \beta_{1} \\ \beta_{2} \\ \vdots \\ \beta_{K} \end{pmatrix} + \varepsilon_{i} = \mathbf{x}_{i}' \boldsymbol{\beta} + \varepsilon_{i} \qquad (5.8)$$

上式对所有个体i都成立( $i=1,\dots,n$ ),故有n个形如(5.8)的方程。

将所有这n个方程都叠放:

$$\begin{pmatrix}
y_1 = \mathbf{x}_1' \boldsymbol{\beta} + \varepsilon_1 \\
y_2 = \mathbf{x}_2' \boldsymbol{\beta} + \varepsilon_2 \\
\vdots \\
y_n = \mathbf{x}_n' \boldsymbol{\beta} + \varepsilon_n
\end{pmatrix} (5.9)$$

将共同的参数向量 $\beta$ 向右边提出:

$$\mathbf{y} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix} = \begin{pmatrix} \mathbf{x}'_1 \\ \mathbf{x}'_2 \\ \vdots \\ \mathbf{x}'_n \end{pmatrix} \boldsymbol{\beta} + \begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{pmatrix} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon} \quad (5.10)$$

$$\mathbf{y} \equiv (y_1 \ y_2 \ \cdots \ y_n)'$$
为被解释变量构成的列向量。

$$\boldsymbol{\varepsilon} \equiv (\varepsilon_1 \ \varepsilon_2 \ \cdots \ \varepsilon_n)'$$
为所有扰动项构成的列向量。

X为 $n \times K$ 数据矩阵(data matrix),其第 i 行包含个体 i 的全部解释变量,而第 k 列包含第 k 个解释变量的全部观测值,即

$$X = \begin{pmatrix} 1 & x_{12} & \cdots & x_{1K} \\ 1 & x_{22} & \cdots & x_{2K} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n2} & \cdots & x_{nK} \end{pmatrix}_{n \times K}$$
 (5.11)

#### 5.3 OLS 估计量的推导

对于多元回归模型, OLS 估计量的最小化问题为

$$\min_{\hat{\beta}_1, \dots, \hat{\beta}_K} \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_i - \hat{\beta}_1 - \hat{\beta}_2 x_{i2} - \hat{\beta}_3 x_{i3} - \dots - \hat{\beta}_K x_{iK})^2$$
 (5.12)

最小二乘法寻找使残差平方和(SSR) $\sum_{i=1}^n e_i^2$ 最小的( $\hat{eta}_1, \hat{eta}_2, \dots, \hat{eta}_K$ )。

在几何上,一元回归寻找最佳拟合的回归直线,使得观测值 y<sub>i</sub>到该回归直线的距离之平方和最小。

二元回归寻找最佳拟合的回归平面;而多元回归则寻找最佳拟合的回归超平面(superplane)。

#### 一阶条件为

$$\begin{cases} \frac{\partial}{\partial \hat{\beta}_{1}} \sum_{i=1}^{n} e_{i}^{2} = -2 \sum_{i=1}^{n} (y_{i} - \hat{\beta}_{1} - \hat{\beta}_{2} x_{i2} - \dots - \hat{\beta}_{K} x_{iK}) = 0 \\ \frac{\partial}{\partial \hat{\beta}_{2}} \sum_{i=1}^{n} e_{i}^{2} = -2 \sum_{i=1}^{n} (y_{i} - \hat{\beta}_{1} - \hat{\beta}_{2} x_{i2} - \dots - \hat{\beta}_{K} x_{iK}) x_{i2} = 0 \\ \vdots \\ \frac{\partial}{\partial \hat{\beta}_{K}} \sum_{i=1}^{n} e_{i}^{2} = -2 \sum_{i=1}^{n} (y_{i} - \hat{\beta}_{1} - \hat{\beta}_{2} x_{i2} - \dots - \hat{\beta}_{K} x_{iK}) x_{iK} = 0 \end{cases}$$

$$(5.13)$$

消去方程左边的"-2"可得

$$\begin{cases}
\sum_{i=1}^{n} (y_{i} - \hat{\beta}_{1} - \hat{\beta}_{2} x_{i2} - \dots - \hat{\beta}_{K} x_{iK}) = 0 \\
\sum_{i=1}^{n} x_{i2} (y_{i} - \hat{\beta}_{1} - \hat{\beta}_{2} x_{i2} - \dots - \hat{\beta}_{K} x_{iK}) = 0 \\
\vdots \\
\sum_{i=1}^{n} x_{iK} (y_{i} - \hat{\beta}_{1} - \hat{\beta}_{2} x_{i2} - \dots - \hat{\beta}_{K} x_{iK}) = 0
\end{cases} (5.14)$$

这是包含K个未知数 $(\hat{\beta}_1,\hat{\beta}_2,\dots,\hat{\beta}_K)$ 与K个方程的联立方程组,称为"正规方程组"(normal equations)。

满足此正规方程组的 $\hat{\boldsymbol{\beta}} \equiv (\hat{\beta}_1 \ \hat{\beta}_2 \cdots \hat{\beta}_K)'$ 称为 OLS 估计量(OLS estimator)。

正规方程组可方便地用矩阵来表达。

由于残差 $e_i \equiv y_i - \hat{\beta}_1 - \hat{\beta}_2 x_{i2} - \dots - \hat{\beta}_K x_{iK}$ , 故正规方程组可写为

$$\begin{cases} \sum_{i=1}^{n} e_{i} = 0 \\ \sum_{i=1}^{n} x_{i2} e_{i} = 0 \\ \vdots \\ \sum_{i=1}^{n} x_{iK} e_{i} = 0 \end{cases}$$
(5.15)

上式每一方程都是乘积求和的形式,可用向量内积表示。

第1个方程可写为

$$\sum_{i=1}^{n} e_i = \begin{pmatrix} 1 & 1 & \cdots & 1 \end{pmatrix} \begin{pmatrix} e_1 \\ e_2 \\ \vdots \\ e_n \end{pmatrix} = 0 \qquad (5.16)$$

第2个方程可写为

$$\sum_{i=1}^{n} x_{i2} e_i = \begin{pmatrix} x_{12} & x_{22} & \cdots & x_{n2} \end{pmatrix} \begin{pmatrix} e_1 \\ e_2 \\ \vdots \\ e_n \end{pmatrix} = 0 \qquad (5.17)$$

以此类推,第K个方程可写为

$$\sum_{i=1}^{n} x_{iK} e_{i} = \begin{pmatrix} x_{1K} & x_{2K} & \cdots & x_{nK} \end{pmatrix} \begin{pmatrix} e_{1} \\ e_{2} \\ \vdots \\ e_{n} \end{pmatrix} = 0 \qquad (5.18)$$

残差向量 $\mathbf{e} \equiv (e_1 \ e_2 \ \cdots \ e_n)'$ 与每个解释变量都正交,这是 OLS 估计量的一大特征。将以上内积以矩阵形式表示:

$$\begin{pmatrix}
1 & 1 & \cdots & 1 \\
x_{12} & x_{22} & \cdots & x_{n2} \\
\vdots & \vdots & \vdots \\
x_{1K} & x_{2K} & \cdots & x_{nK}
\end{pmatrix}
\begin{pmatrix}
e_1 \\
e_2 \\
\vdots \\
e_n
\end{pmatrix} = \begin{pmatrix}
0 \\
0 \\
\vdots \\
0
\end{pmatrix}$$
(5.19)

X'为数据矩阵X的转置。正规方程组可简洁地写为

$$X'e = 0 (5.20)$$

由于X'的第k行包含第k个解释变量的全部观测值,根据X'e=0也可看出,残差向量e与每个解释变量都正交。

从 $e_i \equiv y_i - (\hat{\beta}_1 + \hat{\beta}_2 x_{i2} + \dots + \hat{\beta}_K x_{iK})$ 出发,可将残差向量写为(参见习题)

$$e = y - X\hat{\beta} \tag{5.21}$$

代入正规方程组(5.20)可得

$$X'(y - X\hat{\beta}) = 0 \tag{5.22}$$

乘开并移项可知,最小二乘估计量 $\hat{\beta}$ 满足:

$$(X'X)_{K\times K}\hat{\beta}_{K\times 1} = X'_{K\times n}y_{n\times 1}$$
 (5.23)

假设 $(XX)^{-1}$ 存在,求解 OLS 估计量:

$$\hat{\boldsymbol{\beta}} \equiv (\boldsymbol{X}'\boldsymbol{X})^{-1}\boldsymbol{X}'\boldsymbol{y} \tag{5.24}$$

这就是多元回归的 OLS 估计量。

### **5.4 OLS** 的几何解释

定义被解释变量  $y_i$  的拟合值(fitted value)或预测值(predicted value)为

$$\hat{y}_i \equiv \hat{\beta}_1 + \hat{\beta}_2 x_{i2} + \dots + \hat{\beta}_K x_{iK} \quad (i = 1, \dots, n)$$
 (5.25)

将所有个体的拟合值写为列向量 $\hat{y}$ ,并参照方程(5.10)同样的推导可得

$$\hat{\boldsymbol{y}} \equiv (\hat{y}_1 \quad \hat{y}_2 \quad \cdots \quad \hat{y}_n)' = \boldsymbol{X}\hat{\boldsymbol{\beta}} \qquad (5.26)$$

拟合值向量与残差向量正交, 因为

$$\hat{\mathbf{y}}'\mathbf{e} = (\mathbf{X}\hat{\boldsymbol{\beta}})'\mathbf{e} = \hat{\boldsymbol{\beta}}'\mathbf{X}'\mathbf{e} = \hat{\boldsymbol{\beta}}' \cdot \mathbf{0} = 0 \quad (5.27)$$

由于
$$e = y - X\hat{\beta} = y - \hat{y}$$
,故 $y = \hat{y} + e$ 

被解释变量y可分解为相互正交的拟合值 $\hat{y}$ 与残差e之和,参见图 5.3。

拟合值 $\hat{y}$ 可视为被解释变量y向解释变量超平面X的投影 (projection)。由于拟合值为解释变量的线性组合,即 $\hat{y} = X\hat{\beta}$ ,故 拟合值向量 $\hat{y}$ 正好在超平面X上。根据 OLS 的正交性,残差向量e与 $\hat{y}$ 正交。

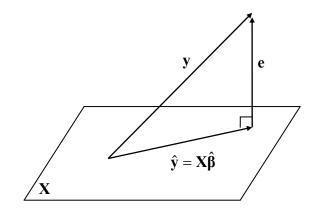


图 5.3 最小二乘法的正交性

#### 5.5 拟合优度

对于多元回归,在回归方程有常数项的情况下,由于 OLS 的正交性,平方和分解公式依然成立 (证明方法与一元回归相同),故仍可将被解释变量的离差平方和 $\sum_{i=1}^{n}(y_i-\bar{y})^2$ 分解如下:

$$\sum_{i=1}^{n} (y_i - \overline{y})^2 = \sum_{i=1}^{n} (\hat{y}_i - \overline{y})^2 + \sum_{i=1}^{n} e_i^2$$
 (5.28)

ESS 为模型可解释的部分,而 RSS 为模型不可解释的部分。

根据平方和分解公式(5.28),可定义拟合优度。

## 定义 拟合优度 $R^2$ 为

$$0 \le R^2 = \frac{\sum_{i=1}^{n} (\hat{y}_i - \overline{y})^2}{\sum_{i=1}^{n} (y_i - \overline{y})^2} = 1 - \frac{\sum_{i=1}^{n} e_i^2}{\sum_{i=1}^{n} (y_i - \overline{y})^2} \le 1$$
 (5.29)

拟合优度 $R^2$ 的缺点是,如果增加解释变量的数目,则 $R^2$ 只增不减,因为至少可让新增解释变量的系数为0而保持 $R^2$ 不变。

另一方面,通过最优地选择新增解释变量的系数(以及已有解释变量的系数),通常可以提高 $\mathbb{R}^2$ 。

引入校正拟合优度,对解释变量过多(模型不够简洁)进行惩罚。

# 定义 校正拟合优度(adjusted $R^2$ ) $\bar{R}^2$ 为

$$\overline{R}^{2} = 1 - \frac{\sum_{i=1}^{n} e_{i}^{2} / (n - K)}{\sum_{i=1}^{n} (y_{i} - \overline{y})^{2} / (n - 1)}$$
 (5.30)

 $\sum_{i=1}^{n} e_i^2$  的自由度(degree of freedom)为(n-K)。

虽然 $\sum_{i=1}^{n} e_i^2$ 由n个随机变量 $\{e_1, \dots, e_n\}$ 所构成,但 $\{e_1, \dots, e_n\}$ 受由 K个方程组成的正规方程组(5.19)的约束,故只有其中(n-K)个残差是(自由)独立的。

给定 $\{e_1, \dots, e_{n-K}\}$ , 即可根据正规方程组求解其余 $\{e_{n-K+1}, \dots, e_n\}$ 。

类似地, $\sum_{i=1}^{n} (y_i - \bar{y})^2$ 的自由度为(n-1)。

虽然  $\sum_{i=1}^{n} (y_i - \overline{y})^2$  由 n 个 离差  $\{(y_1 - \overline{y}), \dots, (y_n - \overline{y})\}$  所构成,但这些 离差之和必然为 0,即  $\sum_{i=1}^{n} (y_i - \overline{y}) = 0$ ,故只有其中(n-1) 个离差是(自由)独立的。

 $\bar{R}^2$ 的缺点是,它可能为负值。

无论 $R^2$ 还是 $\overline{R}^2$ ,只反映拟合程度的好坏,除此并无太多意义。

评估回归方程是否显著,应使用 F 检验( $R^2$ 与 F 统计量也有联系)。

如果回归模型无常数项,则仍须使用"非中心 $R^2$ " (uncentered  $R^2$ ):

$$R_{uc}^{2} \equiv \frac{\sum_{i=1}^{n} \hat{y}_{i}^{2}}{\sum_{i=1}^{n} y_{i}^{2}}$$
 (5.31)

## 5.6 古典线性回归模型的假定

为得到 OLS 估计量的良好性质,"古典线性回归模型"(Classical Linear Regression Model) 作了如下假定。

假定 5.1 线性假定(linearity)。总体模型为

$$y_i = \beta_1 + \beta_2 x_{i2} + \dots + \beta_K x_{iK} + \varepsilon_i \quad (i = 1, \dots, n)$$
 (5.32)

线性假设的含义是每个解释变量对 $y_i$ 的边际效应为常数,比如  $\frac{\partial y_i}{\partial x_{i2}} = \beta_2 ($ 忽略扰动项 $\varepsilon_i$ )。

如果边际效应可变,可加入平方项(比如 $x_{i2}^2$ ),或交叉项(比如 $x_{i2}^2x_{i3}$ )。

交叉项也称为互动项(interaction term)。

例(平方项): 考虑如下回归方程

$$\ln w_{i} = \beta_{1} + \beta_{2}s_{i} + \beta_{3}s_{i}^{2} + \varepsilon_{i} \qquad (5.33)$$

 $\ln w_i$ 为工资对数, $s_i$ 为教育年限。教育年限对工资对数的边际效应为(忽略扰动项)

$$\frac{\partial \ln w_i}{\partial s_i} = \beta_2 + 2\beta_3 s_i \tag{5.34}$$

如果 $\beta_3$ <0,则存在教育投资回报率递减。

反之,如果 $\beta_3 > 0$ ,则存在教育投资回报率递增。

如果变量的边际效应不是常数,可考虑在回归方程中加入平方项。

只要将s<sup>2</sup>也视为解释变量,则仍符合线性模型的假定。

例(互动项): 考虑如下生产函数方程

$$y_i = \beta_1 + \beta_2 k_i + \beta_3 l_i + \beta_4 k_i \times l_i + \varepsilon_i \qquad (5.35)$$

y为产出,k为资本,l为劳动力,而 $k \times l$ 为资本与劳动力的互动项。劳动力的边际产出为 $\frac{\partial y_i}{\partial l_i} = \beta_3 + \beta_4 k_i$ (忽略扰动项)。

如果 $\beta_4 > 0$ ,则说明资本与劳动力是互补的,即随着资本上升, 劳动力的边际产出也增加。

只要将 $k \times l$ 也视为解释变量,则依然符合线性模型的假定。

例(函数形式): 经济学中常用的生产函数为 Cobb-Douglas 生产函数:

$$y_i = e^{\beta_1} k_i^{\beta_2} l_i^{\beta_3} e^{\varepsilon_i} \tag{5.36}$$

 $e^{\beta_i}$ 与 $e^{\varepsilon_i}$ 分别为乘积形式的常数项与扰动项。两边取对数:

$$\ln y_i = \beta_1 + \beta_2 \ln k_i + \beta_3 \ln l_i + \varepsilon_i \quad (5.37)$$

 $\beta_2$ 为产出的资本弹性,即资本每增加 1%,产出平均增加百分之几。

 $\beta_3$ 为产出的劳动力弹性,即劳动力每增加 1%,产出平均增加百分之几。

将 $\ln y_i$ 视为被解释变量,而将 $\ln k_i$ 与 $\ln l_i$ 视为解释变量,则仍符合线性模型的假定。

只要将回归方程中变量的高次项(比如 $x^2$ )或函数(比如 $\ln x$ )都作为变量来看待,则依然满足线性假定。

线性假定的本质要求是,回归函数是参数( $\beta_1 \cdots \beta_K$ )的线性函数 (linear in parameters)。

## 假定 5.2 严格外生性(strict exogeneity)要求

$$E(\varepsilon_i \mid X) = E(\varepsilon_i \mid x_1, \dots, x_n) = 0 \quad (i = 1, \dots, n)$$

严格外生性意味着,在给定数据矩阵X的情况下,扰动项 $\varepsilon_i$ 的条件期望为0。

因此, $\varepsilon_i$ 均值独立于(mean-independent)所有解释变量的观测数据,而不仅仅是同一观测数据 $\mathbf{x}_i$ 中的解释变量。

这意味着, $\varepsilon_i$ 与所有个体的解释变量都不相关,即 $Cov(\varepsilon_i, x_{ik}) = 0, \forall j, k$ 。

此假定很强,在第6章大样本OLS可放松。

均值独立仅要求 $E(\varepsilon_i | X) = c$ ,其中 c 为常数,不一定为 0。

当回归方程有常数项时,要求 $E(\varepsilon_i | X) = 0$ 并不会带来过多限制,因为如果 $E(\varepsilon_i | X) = c \neq 0$ ,总可以把 c 归入常数项。

 $\mathcal{L}(\varepsilon_i|X) = 0$  出发,可证明扰动项的无条件期望也为 0,因为

$$E(\varepsilon_i) = E_X \underbrace{E(\varepsilon_i \mid X)}_{=0} = E_X(0) = 0 \qquad (5.38)$$

上式使用了迭代期望定律。

从 $Cov(\varepsilon_i, x_{jk}) = 0$ 出发,可证明扰动项与解释变量"正交"。

在线性代数中,如果两个向量的内积为0,则这两个向量正交。 在概率统计中,两个随机变量的正交定义有所不同。

定义 如果随机变量 x, y 满足 E(xy) = 0,则称 x, y 正交 (orthogonal)。

根据此定义,可证明解释变量与扰动项正交,因为

$$0 = \operatorname{Cov}(x_{jk}, \varepsilon_i) = \operatorname{E}(x_{jk}\varepsilon_i) - \operatorname{E}(x_{jk}) \underbrace{\operatorname{E}(\varepsilon_i)}_{=0} = \operatorname{E}(x_{jk}\varepsilon_i)$$
 (5.39)

假定 5.3 不存在"严格多重共线性"(strict multicollinearity),

即数据矩阵X满列秩(full column rank)。

数据矩阵的各列向量为线性无关,即不存在某个解释变量为另一解释变量的倍数,或可由其他解释变量线性表出的情形。

换言之, X中不存在多余的变量。

考虑以下一元回归模型:

$$\ln w_i = \beta_1 + \beta_2 s_i + \varepsilon_i \quad (i = 1, \dots, n) \quad (5.40)$$

其数据矩阵X为

$$\boldsymbol{X} = \begin{pmatrix} 1 & s_1 \\ 1 & s_2 \\ \vdots & \vdots \\ 1 & s_n \end{pmatrix} \tag{5.41}$$

数据矩阵X满列秩要求,解释变量 $s_i$ 不是常数项的固定倍数,即 $s_i$ 应有变动,不能是常数。如果所有个体的教育年限 $s_i$ 都相同,则无法定义 OLS 估计量

$$\hat{\beta} = \frac{\sum_{i=1}^{n} (s_i - \overline{s})(\ln w_i - \overline{\ln w})}{\sum_{i=1}^{n} (s_i - \overline{s})^2}$$
 (5.42)

 $\overline{s}$ 与 $\overline{\ln w}$ 分别为 s与  $\ln w$  的样本均值。

更一般地,对于多元回归,如果X满列秩,则XX为正定矩阵 (positive definite), 故  $(XX)^{-1}$  存在, 可 计 算 OLS 估 计 量  $\hat{\beta} = (XX)^{-1}X'y$ 。

反之,如果X不满列秩,则(XX) $^{-1}$ 不存在,无法定义 OLS 估计量。

此时,称 $\beta$  "不可识别" (unidentified)。

数据矩阵X满列秩只是对数据的最低要求。

现实数据不容易出现严格多重共线性。

即使出现,Stata 也会自动识别,并去掉多余的变量。

#### 5.7 OLS 的小样本性质

OLS 估计量 $\hat{\beta} = (X'X)^{-1}X'y$ 为样本数据的函数,也是随机变量,其分布称为"抽样分布"(sampling distribution)。

在古典线性回归模型的假定 5.1-5.3 之下, OLS 估计量具有以下良好性质。

(1) 线性性: OLS 估计量 $\hat{\beta}$ 为线性估计量(linear estimator)。

从 OLS 估计量的表达式 $\hat{\boldsymbol{\beta}} = (XX)^{-1}Xy$ 可知, $\hat{\boldsymbol{\beta}}$ 可视为y的线性组合(将[(X'X) $^{-1}X'$ ]视为系数矩阵),故为线性估计量。

(2) 无偏性:  $E(\hat{\boldsymbol{\beta}}|X) = \boldsymbol{\beta}$ , 即 $\hat{\boldsymbol{\beta}}$ 不会系统地高估或低估 $\boldsymbol{\beta}$ ,参见图 5.4。

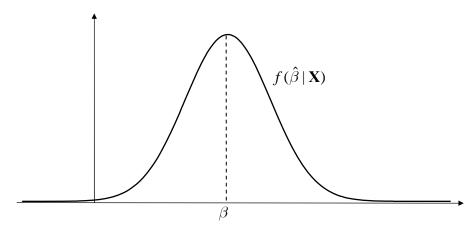


图 5.4 OLS 估计量 $\hat{\beta}$ 的无偏性

证明: 抽样误差(sampling error)为

$$\hat{\boldsymbol{\beta}} - \boldsymbol{\beta} = (X'X)^{-1}X'y - \boldsymbol{\beta} = (X'X)^{-1}X'(X\boldsymbol{\beta} + \boldsymbol{\varepsilon}) - \boldsymbol{\beta} = \underbrace{(X'X)^{-1}X'}_{A}\boldsymbol{\varepsilon} \equiv A\boldsymbol{\varepsilon}$$
(5.43)

记 $A \equiv (XX)^{-1}X'$ 。给定解释变量X,对上式两边求条件期望,根据严格外生性可得

$$E(\hat{\beta} - \beta \mid X) = E(A\varepsilon \mid X) = A\underbrace{E(\varepsilon \mid X)}_{=0} = 0$$
 (5.44)

移项可得, $E(\hat{\beta}|X) = \beta$ 。

在此证明中, 严格外生性不可或缺。

使用迭代期望定律,可进一步证明,无条件期望 $E(\hat{\beta}) = \beta$ ,因为

$$E(\hat{\beta}) = E_X E(\hat{\beta} \mid X) = E_X(\beta) = \beta \qquad (5.45)$$

# (3) 估计量 $\hat{\beta}$ 的协方差矩阵

由于 $\beta$ 为常数,故 $Var(\hat{\beta} | X) = Var(\hat{\beta} - \beta | X)$ ,因此

$$\operatorname{Var}(\hat{\boldsymbol{\beta}} \mid \boldsymbol{X}) = \operatorname{Var}(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta} \mid \boldsymbol{X}) = \operatorname{Var}(\boldsymbol{A\boldsymbol{\varepsilon}} \mid \boldsymbol{X})$$

$$= \boldsymbol{A} \operatorname{Var}(\boldsymbol{\varepsilon} \mid \boldsymbol{X}) \boldsymbol{A}' = (\boldsymbol{X}'\boldsymbol{X})^{-1} \boldsymbol{X}' \operatorname{Var}(\boldsymbol{\varepsilon} \mid \boldsymbol{X}) \boldsymbol{X} (\boldsymbol{X}'\boldsymbol{X})^{-1}$$
(5.46)

在上式中,使用了协方差矩阵的夹心估计量表达式,而且  $A = (X'X)^{-1}X'$ ,  $A' = X(X'X)^{-1}$ (其中, $(X'X)^{-1}$ 为对称矩阵)。

此式似乎很复杂,尤其在计量发展初期,电脑还未普及。

古典模型假定 $Var(\boldsymbol{\varepsilon}|\boldsymbol{X}) = \sigma^2 \boldsymbol{I}_n$ , 称为"球形扰动项"。

在球形扰动项的假定下,表达式(5.46)可大大简化:

$$\operatorname{Var}(\hat{\boldsymbol{\beta}} \mid \boldsymbol{X}) = (\boldsymbol{X}'\boldsymbol{X})^{-1} \boldsymbol{X}' (\sigma^{2} \boldsymbol{I}_{n}) \boldsymbol{X} (\boldsymbol{X}'\boldsymbol{X})^{-1}$$

$$= \sigma^{2} (\boldsymbol{X}'\boldsymbol{X})^{-1} (\boldsymbol{X}'\boldsymbol{X}) (\boldsymbol{X}'\boldsymbol{X})^{-1} = \sigma^{2} (\boldsymbol{X}'\boldsymbol{X})^{-1}$$
(5.47)

假定 5.4 球型扰动项(spherical disturbance),即扰动项满足"同方差"、"无自相关"的性质,故扰动项 $\varepsilon$ 的协方差矩阵可写为

$$\operatorname{Var}(\boldsymbol{\varepsilon} \mid \boldsymbol{X}) = \sigma^{2} \boldsymbol{I}_{n} = \begin{pmatrix} \sigma^{2} & 0 & \cdots & 0 \\ 0 & \sigma^{2} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \sigma^{2} \end{pmatrix}$$
(5.48)

协方差矩阵 $Var(\varepsilon | X)$ 的主对角线元素都等于 $\sigma^2$ ,即满足"条件同方差" (conditional homoskedasticity),简称"同方差"。

如果不完全相等,则存在"条件异方差"(conditional heteroskedasticity),简称"异方差"。

协方差矩阵 $Var(\boldsymbol{\varepsilon}|\boldsymbol{X})$ 的非主对角线元素都为0,故不同个体的扰动项之间无"自相关"(autocorrelation)或"序列相关"(serial correlation);反之,则存在自相关。

球型扰动项假定是证明协方差表达式 $\sigma^2(XX)^{-1}$ 的关键(无偏性不依赖于球形扰动项)。

此表达式虽然简单,但只在同方差与无自相关的情况下才成立。

如果存在条件异方差,则方差表达式有所不同,应使用"稳健标准误差"(robust standard error),参见第7章。

引入球形扰动项假定的另一好处是,可以证明 OLS 估计量在某种范围内是最有效率的估计量,即方差最小。

## (4) 高斯-马尔可夫定理(Gauss-Markov Theorem):

在假定 5.1-5.4 之下,最小二乘法是最佳线性无偏估计(Best Linear Unbiased Estimator,简记 BLUE),即在所有线性的无偏估计中,最小二乘法的方差最小,参见图 5.5。

严格来说,记 OLS 估计量为 $\hat{\boldsymbol{\beta}}_{OLS}$ ,而任一线性无偏估计量为 $\tilde{\boldsymbol{\beta}}$ ,则[Var( $\tilde{\boldsymbol{\beta}}|X$ )-Var( $\hat{\boldsymbol{\beta}}_{OLS}|X$ )]为半正定矩阵。

高斯-马尔可夫定理的核心假设是球形扰动项。

如果不满足球形扰动项(比如,存在异方差或自相关),则高斯-马尔可夫定理不成立。

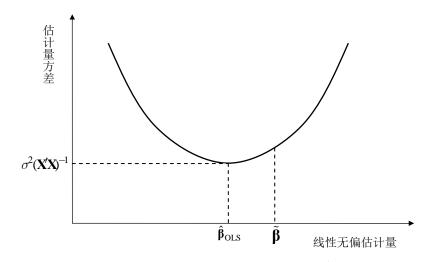


图 5.5 OLS 估计量为 BLUE

#### (5) 对扰动项方差的无偏估计

对于扰动项方差 $\sigma^2 = \text{Var}(\varepsilon_i)$ ,由于 $\{\varepsilon_1, \dots, \varepsilon_n\}$ 不可观测,将 $\{e_1, \dots, e_n\}$ 视为其实现值,得到对 $\sigma^2$ 的估计:

$$s^2 = \frac{1}{n - K} \sum_{i=1}^{n} e_i^2 \tag{5.49}$$

(n-K)为自由度。

为什么除以(n-K)而不除以n?

虽然有n个残差 $\{e_1, e_2, \dots, e_n\}$ ,但随机变量 $\{e_1, e_2, \dots, e_n\}$ 须满足K个正规方程X'e=0,故只有其中(n-K)个残差是(自由)独立的。

经过校正后,才是"无偏估计"(unbiased estimator),即 $E(s^2) = \sigma^2$ 。

如果样本容量n很大,当 $n \to \infty$ 时,则 $\frac{n-K}{n} \to 1$ ,是否进行"小样本校正" (small sample adjustment)并无多大差别。

称  $s = \sqrt{s^2}$  为 "回归方程的标准误差" (standard error of the regression),简称"回归方程的标准误",它衡量回归方程扰动项的波动幅度。

故 OLS 估计量 $\hat{\beta}$ 的协方差矩阵 $\sigma^2(XX)^{-1}$ 可用 $s^2(XX)^{-1}$ 来估计。

特别地, $\hat{\boldsymbol{\beta}}$ 的第k个分量 $\hat{\boldsymbol{\beta}}_k$ 的估计方差为 $s^2(\boldsymbol{X}\boldsymbol{X})^{-1}_{kk}$ ,其中 $(\boldsymbol{X}\boldsymbol{X})^{-1}_{kk}$ 表示矩阵 $(\boldsymbol{X}\boldsymbol{X})^{-1}$ 的(k,k)元素,即主对角线上的第k个元素。

称 $\sqrt{s^2(XX)_{kk}^{-1}}$ 为 OLS 估计量 $\hat{\beta}_k$ 的"标准误差"(standard error),简称"标准误",记为SE( $\hat{\beta}_k$ ),即

$$SE(\hat{\beta}_k) \equiv \sqrt{s^2 (X'X)_{kk}^{-1}}$$
 (5.50)

更一般地,称对某统计量的标准差之估计值(estimated standard deviation)为该统计量的"标准误"(standard error),作为对统计量估计误差的度量。

得到参数的点估计(point estimate)后,还须给出相应的标准误,才能知道此点估计的准确程度(或不确定性)。

#### 5.8 对单个系数的 t 检验

计量经济学中的统计推断(statistical inference)方法,可分为两大类,即"小样本理论"(small sample theory)与"大样本理论"(large sample theory)。

无论样本容量是多少,小样本理论都成立,不需要让样本容量  $n \to \infty$ ,也称"有限样本理论"(finite sample theory)。

大样本理论要求 $n \to \infty$ ,适用于较大的样本容量,在第6章介绍。

本章介绍小样本理论。

小样本理论虽适用于各种样本容量,但不易推导统计量的分布, 需对随机变量的概率分布作很强假定。

假定 5.5 在给定X的情况下, $\boldsymbol{\varepsilon}|X$ 的条件分布为正态,即  $\boldsymbol{\varepsilon}|X\sim N(\mathbf{0},\sigma^2\boldsymbol{I}_n)$ 。

考虑最简单的假设检验(hypothesis testing),即对单个回归系数  $\beta_k$ 进行检验。

需要检验的"原假设"(null hypothesis,也称"零假设")为

$$H_0: \beta_k = c \tag{5.51}$$

c为给定常数,也称为"假想值"(hypothesized value)。

通常c=0,即检验变量 $x_{ik}$ 的系数是否显著地不等于 0。

假设检验是一种概率意义上的反证法。

首先假设原假设成立,然后看在原假设成立的前提下,是否导致不太可能发生的"小概率事件"在一次抽样的样本中出现。

如果小概率事件竟然在一次抽样实验中被观测到,则说明原假设不可信,应拒绝原假设,接受"替代假设"(alternative hypothesis,也称"备择假设"):

$$H_1: \beta_k \neq c \tag{5.52}$$

替代假设" $H_1: \beta_k \neq c$ "也称"双边替代假设"(two-sided alternative hypothesis),因为它既包括 $\beta_k > c$ ,也包括 $\beta_k < c$ 的情形。

这类检验称为"双边检验"(two-sided test)。

如果未知参数 $\beta_k$ 的估计值 $\hat{\beta}_k$ 离c较远,则应倾向于拒绝原假设。

使用此原理的这类统计检验称为"沃尔德检验"(Wald test)。

在衡量距离时,由于绝对距离依赖于变量单位,故需以标准差为基准来考虑相对距离。

由于扰动项 $\boldsymbol{\varepsilon}|\boldsymbol{X} \sim N(\boldsymbol{0}, \sigma^2 \boldsymbol{I}_n)$ ,而 $\hat{\boldsymbol{\beta}} - \boldsymbol{\beta} = \boldsymbol{A}\boldsymbol{\varepsilon}$ 为 $\boldsymbol{\varepsilon}$ 的线性函数(其中 $\boldsymbol{A} \equiv (\boldsymbol{X}'\boldsymbol{X})^{-1}\boldsymbol{X}'$ ),故( $\hat{\boldsymbol{\beta}} - \boldsymbol{\beta}$ )| $\boldsymbol{X}$ 也服从正态分布。

由于E(
$$\hat{\boldsymbol{\beta}} - \boldsymbol{\beta} \mid \boldsymbol{X}$$
) =  $\boldsymbol{0}$ , Var( $\hat{\boldsymbol{\beta}} \mid \boldsymbol{X}$ ) =  $\sigma^2 (\boldsymbol{X}'\boldsymbol{X})^{-1}$ , 故  
( $\hat{\boldsymbol{\beta}} - \boldsymbol{\beta}$ ) |  $\boldsymbol{X} \sim N(\boldsymbol{0}, \sigma^2 (\boldsymbol{X}'\boldsymbol{X})^{-1})$  (5.53)

单独考虑上式的第 k个分量:

$$(\hat{\beta}_k - \beta_k) | X \sim N(0, \sigma^2 (X'X)_{kk}^{-1})$$
 (5.54)

 $(XX)_{kk}^{-1}$ 为矩阵 $(XX)^{-1}$ 的(k,k)元素(即主对角线上第k个元素),而 $\sigma^2(XX)_{kk}^{-1}$ 为 $\hat{\beta}_k$ 的方差。

在原假设" $H_0:\beta_k=c$ "成立的情况下:

$$(\hat{\beta}_k - c) | X \sim N(0, \sigma^2 (X'X)_{kk}^{-1})$$
 (5.55)

如果 $\sigma^2$ 已知,则标准化的统计量服从标准正态分布:

$$z_{k} = \frac{\hat{\beta}_{k} - c}{\sqrt{\sigma^{2} (X'X)_{kk}^{-1}}} \sim N(0, 1)$$
 (5.56)

但通常 $\sigma^2$ 未知,称为"厌恶参数" (nuisance parameter)。

虽然对 $\sigma^2$ 不感兴趣, $\sigma^2$ 却出现在表达式(5.56)中,故名。

合格的"检验统计量"(test statistic)须满足两个条件。

首先,它应能根据样本数据算出来。其次,它的概率分布已知。

对于 $z_k$ 统计量,虽已知其分布为标准正态,但不知道 $\sigma^2$ ,无法根据数据计算 $z_k$ 统计量的样本观测值。

以 $\sigma^2$ 的估计量 $s^2$ 替代 $\sigma^2$ ,可得以下t统计量(t-statistic)。

定理(t 统计量的分布) 在假定 5.1-5.5 均满足,且原假设" $H_0: \beta_k = c$ "也成立的情况下,t 统计量服从自由度为(n-K)的t 分布:

$$t_k \equiv \frac{\hat{\beta}_k - c}{\text{SE}(\hat{\beta}_k)} \sim t(n - K)$$
 (5.57)

更一般地, t统计量的通用公式为

$$t = \frac{\text{估计量} - \text{假想值}}{\text{估计量的标准误}}$$
 (5.58)

t 统计量度量估计量 $(\hat{\beta}_k)$ 离假想值(c)的距离,并以估计量的标准误 $SE(\hat{\beta}_k)$ 作为距离的度量单位,即此距离为标准误的多少倍。

#### t 检验的步骤

第一步: 计算t统计量,记其具体取值为 $t_k$ 。

如果 $H_0$ 为真,则 $|t_k|$ 很大的概率将很小(为小概率事件),不应在抽样中观测到。因此,如果 $|t_k|$ 很大,则 $H_0$ 较不可信。

第二步: 计算"显著性水平"(significance level)为 $\alpha$ 的"临界值"(critical value) $t_{\alpha/2}(n-K)$ ,其中 $t_{\alpha/2}(n-K)$ 的定义为

$$P\{T > t_{\alpha/2}(n-K)\} = P\{T < -t_{\alpha/2}(n-K)\} = \alpha/2$$
 (5.59)

其中,随机变量 $T \sim t(n-K)$ 。

随机变量T大于 $t_{\alpha/2}(n-K)$ ,或小于 $-t_{\alpha/2}(n-K)$ 的概率都是 $\alpha/2$ ,参见图 5.6。

通常取 $\alpha = 5\%$ ,则 $\alpha/2 = 2.5\%$ 。有时也使用 $\alpha = 1\%$ 或 $\alpha = 10\%$ 。

第三步:如果 $|t_k| \ge t_{\alpha/2}(n-K)$ ,则 $t_k$ 落入"拒绝域"(rejection region),故拒绝 $H_0$ 。反之,如果 $|t_k| < t_{\alpha/2}(n-K)$ ,则 $t_k$ 落入"接受域"(acceptance region),故接受 $H_0$ 。

因为拒绝域分布在t分布两边,故称"双边检验"(two-sided test)。

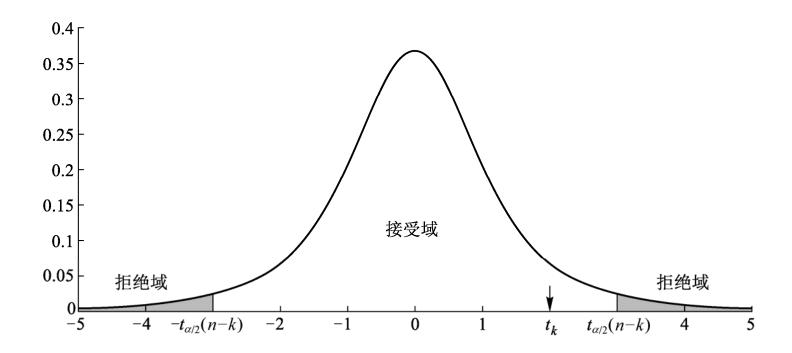


图 5.6 双边 t 检验的临界值与拒绝域

# 计算 p 值

假设检验的基本逻辑就是概率意义上的反证法。

观测到样本数据的发生概率究竟小到何种程度,可通过下面的p值来度量。

在双边t检验中,给定t统计量的样本观测值 $t_k$ ,此假设检验问题的 p值(probability value,即 p-value)为

$$p \stackrel{\text{de}}{=} P(|T| > |t_k|) \tag{5.60}$$

其中,随机变量 $T \sim t(n-K)$ 。

给定t统计量 $t_k$ ,则p值衡量比 $|t_k|$ 更大的t分布两端的尾部概率,参见图 5.7。

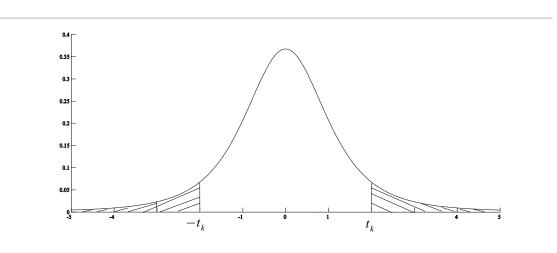


图 5.7 双边t检验的 p 值

如果*p*值为0.05,则正好可以在5%的显著性水平上拒绝原假设,但无法在4.9%的显著性水平上拒绝原假设。

定义 称原假设可被拒绝的最小显著性水平为此假设检验问题的 p 值(probability value,即 p-value)。

p值越小,则越倾向于拒绝原假设。

如选定显著性水平为5%,只要p值比0.05小,即可拒绝原假设。

比如,p值 = 0.03,则可在 5%的显著性水平上拒绝原假设。

进一步,"p值=0.03"还可"在3%的显著性水平上拒绝原假设"。

使用p值进行假设检验一般比临界值更有信息量。

使用p值进行检验的另一好处是,只要将p值与 0.05 相比,即可得到检验结果,操作简便。

#### 计算置信区间

有时点估计还不够,希望进行区间估计,即参数最可能的取值范围。

假设"置信度"(confidence level)为 $(1-\alpha)$ (比如 $\alpha = 5\%$ ,则 $1-\alpha = 95\%$ ),即要找到"置信区间"(confidence interval),使得该区间覆盖真实参数 $\beta_k$ 的概率为 $(1-\alpha)$ 。

由于 $t_k = \frac{\hat{\beta}_k - \beta_k}{\text{SE}(\hat{\beta}_k)} \sim t(n - K)$ ,故t 统计量落入接受域的概率为  $(1 - \alpha)$ :

$$P\left\{-t_{\alpha/2} < \frac{\hat{\beta}_k - \beta_k}{SE(\hat{\beta}_k)} < t_{\alpha/2}\right\} = 1 - \alpha \qquad (5.61)$$

其中, $t_{\alpha/2}$ 为显著性水平为 $\alpha$ 的临界值。将不等式变形可得

$$P\{\hat{\beta}_k - t_{\alpha/2} \operatorname{SE}(\hat{\beta}_k) < \beta_k < \hat{\beta}_k + t_{\alpha/2} \operatorname{SE}(\hat{\beta}_k)\} = 1 - \alpha \qquad (5.62)$$

由此可知, $\beta_k$ 的置信区间为

$$\left[\hat{\beta}_k - t_{\alpha/2} \operatorname{SE}(\hat{\beta}_k), \ \hat{\beta}_k + t_{\alpha/2} \operatorname{SE}(\hat{\beta}_k)\right]$$
 (5.63)

此置信区间以点估计 $\hat{eta}_k$ 为中心,区间半径为 $t_{\alpha/2}$ SE( $\hat{eta}_k$ )。

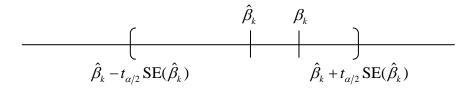


图 5.8 置信区间的示意图

标准误 $SE(\hat{\beta}_k)$ 越大,对 $\beta_k$ 的估计越不准确,置信区间也越宽。

置信区间是随机区间,随着样本不同而不同。

如果置信度为 95%,抽样 100 次,得到 100 个置信区间,大约 95 个置信区间能覆盖到真实参数  $\beta_k$ 。

## 单边检验

有时也进行单边检验(one-sided test)。

考虑原假设为 $H_0: \beta_k = 0$ ,而替代假设为 $H_1: \beta_k > 0$ 。

比如,从理论上认为解释变量x<sub>k</sub>对y的作用不可能为负。

仍可计算t统计量:

$$t_k \equiv \frac{\hat{\beta}_k}{\text{SE}(\hat{\beta}_k)} \sim t(n - K)$$
 (5.64)

如果此t统计量很大,则倾向于拒绝原假设;而如果此t统计量很小(比如为负数),则倾向于接受原假设。

拒绝域只在概率分布的最右边一侧。

给定显著性水平 $\alpha$ 后,计算的临界值为 $t_{\alpha}(n-K)$ ,使得取值大于此临界值的概率为 $\alpha$ :

$$P\{T > t_{\alpha}(n-K)\} = \alpha \tag{5.65}$$

其中,随机变量 $T \sim t(n-K)$ 。

如要计算此单边检验的p值,则为比统计量 $t_k$ 更大的右侧尾部概率(参见图 5.9):

$$p \stackrel{\text{de}}{=} P(T > t_k) \tag{5.66}$$

拒绝域只在分布的右侧尾部,故称"单边右侧检验"(one-sided right-tail test)。

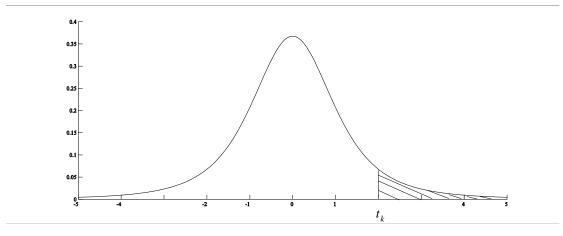


图 5.9 单边右侧t检验的 p值

如果原假设为 $H_0: \beta_k = 0$ ,而替代假设为 $H_1: \beta_k < 0$ ,则为"单边左侧检验" (one-sided left-tail test)。

此时, *t* 统计量越小(比如为负数), 则越倾向于拒绝原假设; 故拒绝域只在分布的左侧尾部。

对于单边左侧检验, 计算p值的公式为(参见图 5.10):

$$p \stackrel{\text{de}}{=} P(T < t_k) \tag{5.67}$$

其中,随机变量 $T \sim t(n-K)$ 。

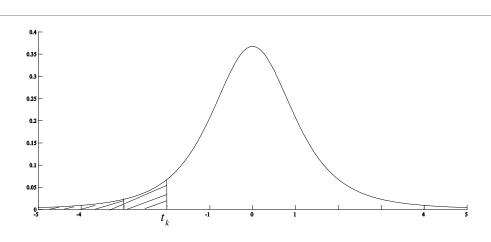


图 5.10 单边左侧t检验的p值

### 第 | 类错误与第 || 类错误

进行假设检验时,可能犯以下两类错误。

定义 第 L 类错误(Type I error)指的是,虽然原假设为真,但却根据观测数据做出了拒绝原假设的错误判断,即"弃真"。

第Ⅰ类错误的发生概率为

 $P(拒绝H_0|H_0) = P(检验统计量落入拒绝域|H_0) = \alpha$  (5.68)

其中, α正是检验的显著性水平。

定义 第 II 类错误(Type II error)指的是,虽然原假设为假(替代假设为真),但却根据观测数据做出了接受原假设的错误判断,即"存伪"。

第II类错误的发生概率为

$$P(接受 H_0|H_1) = P(检验统计量落入接受域|H_1)$$
 (5.69)

在 $\beta_k$ 可能取值的参数空间中,通常 $H_0$ 仅包含一个点(比如 $\beta_k=0$ ),故容易计算第 I 类错误的发生概率,即 $P(拒绝H_0|H_0)=\alpha$ 。

反之,替代假设 $H_1$ 则一般包括许多点(比如 $\beta_k \neq 0$ ),故不易计算第 II 类错误的发生概率。

第 I 类错误与第 II 类错误存在此消彼长的关系。如果减少第 I 类错误的发生概率,则第 II 类错误的发生概率必然增加;反之亦然。

如果同时减少第 I 类错误与第 II 类错误的发生概率,则必须增加样本容量。

在进行假设检验时,一般先指定可接受的发生第 I 类错误的最大概率,即显著性水平 $\alpha$ (比如 5%),而不指定第 II 类错误的发生概率(通常更难计算)。

**定义** 称 "1 减去第Ⅱ类错误的发生概率"为统计检验的"功效"或"势"(power),即

功效 = 
$$1 - P(接受H_0|H_1) = P(拒绝H_0|H_1)$$
 (5.70)

功效为在原假设为错误的情况下,拒绝原假设的概率。

在进行检验时,通常知道第 I 类错误的发生概率,而不知道第 II 类错误的发生概率。

如果拒绝原假设,则比较理直气壮,因为知道犯错概率(显著性水平)。

如果接受原假设,则比较没有把握,因为通常不知犯错概率。

## 5.9 对线性假设的 F 检验

想知道整个回归方程是否显著,即除常数项以外,所有解释变量的回归系数是否都为零。

检验以下原假设:

$$H_0: \beta_2 = \dots = \beta_K = 0$$
 (5.71)

其中, $\beta_1$ 为常数项。此原假设等价于对(K-1)个约束条件进行联合检验(joint test):

$$H_0: \beta_2 = 0, \beta_3 = 0, \dots, \beta_K = 0$$
 (5.72)

**例** 对于模型  $y = \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \beta_4 x_4 + \varepsilon$ , 检验以下两个约束:

$$H_0: \beta_2 = \beta_3, \ \beta_4 = 0$$
 (5.73)

写成向量形式:

$$H_0: \begin{pmatrix} \beta_2 - \beta_3 \\ \beta_4 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \tag{5.74}$$

上式可写为

$$H_0: \begin{pmatrix} \beta_2 - \beta_3 \\ \beta_4 \end{pmatrix} = \underbrace{\begin{pmatrix} 0 & 1 & -1 & 0 \\ 0 & 0 & 0 & 1 \end{pmatrix}}_{R} \underbrace{\begin{pmatrix} \beta_1 \\ \beta_2 \\ \beta_3 \\ \beta_4 \end{pmatrix}}_{\beta} = \underbrace{\begin{pmatrix} 0 \\ 0 \end{pmatrix}}_{r}$$
 (5.75)

更一般地,考虑检验m个线性假设是否同时成立:

$$H_0: \underset{m \times K}{\mathcal{R}} \underset{K \times 1}{\mathcal{F}} = \underset{m \times 1}{\mathcal{F}}$$

其中,r为m维列向量(m < K),R为 $m \times K$ 维矩阵,而且rank(R) = m,即R满行秩,没有多余或自相矛盾的行或方程。在上例中,

$$\mathbf{R} = \begin{pmatrix} 0 & 1 & -1 & 0 \\ 0 & 0 & 0 & 1 \end{pmatrix}, \quad \overrightarrow{\mathbf{m}} \, \mathbf{r} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \circ$$

根据沃尔德检验原理,由于 $\hat{\boldsymbol{\beta}}$ 是 $\boldsymbol{\beta}$ 的估计量,故如果 $H_0$ 成立,则( $R\hat{\boldsymbol{\beta}}-\boldsymbol{r}$ )应比较接近 $\mathbf{0}$ (零向量)。

这种接近程度可用其二次型来衡量,比如

$$(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{r})' [\operatorname{Var}(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{r})]^{-1} (\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{r}) \quad (5.76)$$

其中, $(R\hat{\beta}-r)$ 的协方差矩阵可写为

$$Var(\mathbf{R}\hat{\boldsymbol{\beta}} - \boldsymbol{r}) = Var(\mathbf{R}\hat{\boldsymbol{\beta}}) \qquad (去掉常数,方差不变)$$

$$= \mathbf{R} Var(\hat{\boldsymbol{\beta}}) \mathbf{R}' \qquad (夹心估计量的公式) \qquad (5.77)$$

$$= \sigma^2 \mathbf{R} (\mathbf{X}'\mathbf{X})^{-1} \mathbf{R}' \quad (因为 Var(\hat{\boldsymbol{\beta}}) = \sigma^2 (\mathbf{X}'\mathbf{X})^{-1})$$

其中, $\sigma^2$ 可由 $s^2$ 来估计,故有如下定理。

定理(F 统计量的分布) 在假定 5.1-5.5 均满足,且原假设" $H_0$ :  $R\beta = r$ "也成立的情况下,则 F 统计量服从自由度为 (m, n-K)的F分布:

$$F = \frac{(R\hat{\beta} - r)'[R(X'X)^{-1}R']^{-1}(R\hat{\beta} - r)/m}{s^2} \sim F(m, n - K)$$
 (5.78)

### F检验的步骤

第一步: 计算F统计量。如果 $H_0$ 为真,则"F统计量很大"的概率将很小(为小概率事件),不应在一次抽样中观测到。

如果F统计量很大,则 $H_0$ 较不可信。

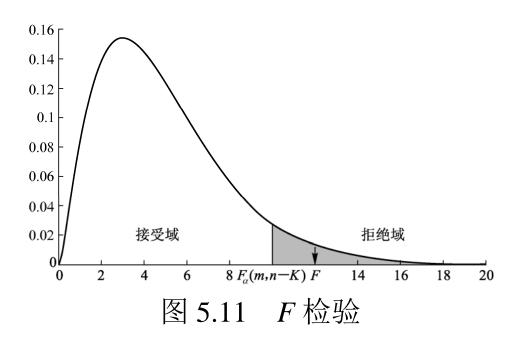
第二步: 计算显著性水平为 $\alpha$ 的临界值 $F_{\alpha}(m, n-K)$ ,其中 $F_{\alpha}(m, n-K)$ 的定义为

$$P\{\widetilde{F} > F_{\alpha}(m, n - K)\} = \alpha \qquad (5.79)$$

其中,随机变量 $\widetilde{F} \sim F(m, n-K)$ 。

 $\tilde{F}$ 大于临界值 $F_{\alpha}(m, n-K)$ 的概率恰好为 $\alpha$ 。

第三步: 如果F统计量大于临界值 $F_{\alpha}(m, n-K)$ ,即落入右边拒绝域,则拒绝 $H_0$ ; 反之,如果F统计量小于临界值,即落入接受域,则接受 $H_0$ ,参见图 5.11。



对于F检验,也可使用p值来进行。

给定F统计量的样本观测值,此假设检验问题的p值为比F统计量更大的F分布的右侧尾部概率,即

$$p$$
恒 =  $P(\tilde{F} > F)$  (5.80)

其中,随机变量 $\widetilde{F} \sim F(m, n-K)$ ,而F为F统计量的取值。

### **5.10** F 统计量的似然比原理表达式

在做假设检验时,如果接受原假设,则可将此原假设作为约束条件,代入最小二乘法的最优化问题。

使用约束条件下的最小二乘法,即"约束最小二乘法"(Restricted OLS 或 Constrained OLS),可得到F统计量的另一方便表达式。

考虑约束极值问题:

$$\min_{\hat{\beta}} SSR(\hat{\beta})$$

$$s.t. R\hat{\beta} = r$$
(5.81)

其中, $SSR(\hat{\beta})$ 为残差平方和,是 $\hat{\beta}$ 的函数;而 $\hat{\beta}$ 还须满足约束条件  $R\hat{\beta} = r(s.t.$ 表示受约束,即 subject to)。

 $\hat{\boldsymbol{\beta}}$ 并不能任意取值,而只能在所有满足 $R\hat{\boldsymbol{\beta}} = r$ 的子集中,选择使残差平方和 $SSR(\hat{\boldsymbol{\beta}})$ 最小化的 $\hat{\boldsymbol{\beta}}$ 。

如果 $H_0: \mathbf{R}\boldsymbol{\beta} = \mathbf{r}$ 正确,则加上此约束不应使残差平方和增大很多。

记无约束的残差平方和SSR,而有约束的残差平方和为SSR\*。

在 $H_0$ 正确的情况下,(SSR\*-SSR)不应很大。

构造如下F统计量。通过求解此约束极值问题,可以证明:

$$F = \frac{(SSR^* - SSR)/m}{SSR/(n-K)}$$
 (5.82)

其中,m为约束条件个数(即矩阵R的行数),n为样本容量,而K为参数个数(即 $\beta$ 的维度)。

此F统计量表达式有时更容易计算。

这种通过比较"条件极值"与"无条件极值"而进行的检验, 统称为"似然比检验"(Likelihood Ratio test, LR)。

F 统计量的似然比表达式(5.82),也可通过拟合优度来表示。

记 $R^2$ 为无约束回归的拟合优度, $R^2$ 为约束回归的拟合优度,则

$$F = \frac{(R^2 - R_*^2)/m}{(1 - R^2)/(n - K)}$$
 (5.83)

如果去掉约束条件后拟合优度上升越多,即 $(R^2 - R_*^2)$ 越大,则越应该拒绝约束条件成立的原假设。

证明: 在方程(5.82)右边的分子分母同时除以TSS  $\equiv \sum_{i=1}^{n} (y_i - \overline{y})^2$ 

$$F = \frac{\frac{(SSR^* - SSR)}{TSS} / m}{\frac{SSR}{TSS} / (n - K)}$$
 (5.84)

由于
$$\frac{SSR}{TSS} = 1 - R^2$$
, 面 $\frac{SSR}{TSS} = 1 - R_*^2$ , 故

$$F = \frac{\left[ (1 - R_*^2) - (1 - R^2) \right] / m}{(1 - R^2) / (n - K)} = \frac{(R^2 - R_*^2) / m}{(1 - R^2) / (n - K)}$$
(5.85)

考虑一个特殊情形,即检验整个回归方程的显著性。

命题 对于线性回归方程 " $y_i = \beta_1 + \beta_2 x_{i2} + \dots + \beta_K x_{iK} + \varepsilon_i$ ",检验原假设 " $H_0: \beta_2 = \dots = \beta_K = 0$ "的F统计量等于  $\frac{R^2/(K-1)}{(1-R^2)/(n-K)}$ 。

证明:对于 $H_0: \beta_2 = \cdots = \beta_K = 0$ ,共有(K-1)个约束,故在表达式(5.83)中,m = (K-1)。

当原假设成立时, $y_i = \beta_1 + \varepsilon_i$ ,故约束回归只是对常数项回归,因此 $R_*^2 = 0$ (参见第 4 章习题)。

将m = (K-1)与 $R_*^2 = 0$ 代入表达式(5.85)即得证。

 $R^2$ 并非决定F统计量的唯一因素;还取决于样本容量n与解释变量个数K。

### 5.11 预测

有时也用计量模型进行预测(prediction 或 forecasting),即给定解释向量 $x_0$ 的(未来)取值,预测被解释变量 $y_0$ 的取值。

假设计量模型对所有观测值都成立(包括外推到未来),

$$y_0 = \mathbf{x}_0' \mathbf{\beta} + \varepsilon_0 \tag{5.86}$$

记 $\hat{\boldsymbol{\beta}}$ 为 $\boldsymbol{\beta}$ 的 OLS 估计量,对 $y_0$ 作点预测为

$$\hat{y}_0 \equiv \mathbf{x}_0' \hat{\boldsymbol{\beta}} \tag{5.87}$$

"预测误差" (prediction error)( $\hat{y}_0 - y_0$ )可写为

$$\hat{y}_0 - y_0 = \mathbf{x}_0' \hat{\boldsymbol{\beta}} - (\mathbf{x}_0' \boldsymbol{\beta} + \varepsilon_0) = \mathbf{x}_0' (\hat{\boldsymbol{\beta}} - \boldsymbol{\beta}) - \varepsilon_0 \qquad (5.88)$$

 $\hat{y}_0$ 为 "无偏预测" (unbiased predictor),即用  $\hat{y}_0$ 作为  $y_0$ 的预测值不会系统地高估或低估  $y_0$ ,因为

$$E(\hat{y}_0 - y_0) = \mathbf{x}_0' E(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta}) - E(\varepsilon_0) = 0 \qquad (5.89)$$

其中,由于 $\hat{\boldsymbol{\beta}}$ 是 $\boldsymbol{\beta}$ 的无偏估计,故 $\mathbf{E}(\hat{\boldsymbol{\beta}}-\boldsymbol{\beta})=0$ 。

有时希望知道此预测的置信区间。

计算预测误差 $(\hat{y}_0 - y_0)$ 的方差:

$$Var(\hat{y}_{0} - y_{0}) = Var[\mathbf{x}'_{0}(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta}) - \varepsilon_{0}]$$

$$= Var(\varepsilon_{0}) + Var[\mathbf{x}'_{0}(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta})]$$

$$= \sigma^{2} + Var[\mathbf{x}'_{0}(\hat{\boldsymbol{\beta}})] \qquad (去掉常数,方差不变)$$

$$= \sigma^{2} + \mathbf{x}'_{0} Var(\hat{\boldsymbol{\beta}})\mathbf{x}_{0} \qquad (夹心估计量的公式)$$

$$= \sigma^{2} + \sigma^{2}\mathbf{x}'_{0}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{x}_{0} \qquad (因为Var(\hat{\boldsymbol{\beta}}) = \sigma^{2}(\mathbf{X}'\mathbf{X})^{-1})$$

其中,假设 $\varepsilon_0$ 与 $\hat{\boldsymbol{\beta}}$ 不相关(估计 $\hat{\boldsymbol{\beta}}$ 没用到 $\varepsilon_0$ 的信息)。

预测误差的方差有两个来源,即抽样误差 $\sigma^2 x_0'(X'X)^{-1} x_0$ (不能精确知道参数 $\beta$ ),以及 $y_0$ 本身的不确定性( $\varepsilon_0$ 的方差 $\sigma^2$ )。

如果样本很大,则抽样误差将很小;但扰动项方差 $\sigma^2$ 始终存在。

将方程(5.90)中的 $\sigma^2$ 用 $s^2$ 替代,可得预测误差( $\hat{y}_0 - y_0$ )的标准误:

$$SE(\hat{y}_0 - y_0) = s\sqrt{1 + x_0'(X'X)^{-1}x_0}$$
 (5.91)

由此可得 t 统计量:

$$\frac{\hat{y}_0 - y_0}{\text{SE}(\hat{y}_0 - y_0)} \sim t(n - K)$$
 (5.92)

 $y_0$ 的置信度为 $(1-\alpha)$ 的置信区间为

$$(\hat{y}_0 - t_{\alpha/2}SE(\hat{y}_0 - y_0), \hat{y}_0 + t_{\alpha/2}SE(\hat{y}_0 - y_0))$$
 (5.93)

其中, $t_{\alpha/2}$ 为显著性水平为 $\alpha$ 的t(n-K)分布的双边检验临界值。

## 5.12 多元回归的 Stata 实例

在 Stata 中进行多元回归的命令为

. regress y x1 x2 x3

其中,"y"为被解释变量,而"x1 x2 x3"为解释变量。

以数据集 grilic.dta 为例,该数据集包括 758 名美国年轻男子的数据。对以下方程进行多元回归估计:

 $\ln w = \beta_1 + \beta_2 s + \beta_3 expr + \beta_4 tenure + \beta_5 smsa + \beta_6 rns + \varepsilon$  (5.94)

被解释变量为 lnw (工资对数),主要解释变量包括 s (教育年限)、

expr (工龄)、tenure (在现单位工作年限)、smsa (是否住在大城市) 以及 rns (是否住在美国南方)。

# 为估计方程(5.94),可输入如下命令

## . reg lnw s expr tenure smsa rns

| Source                                 | SS                              | df     | MS  |                | Number of obs                    |                                 |
|--|---------------------------------|--------|---|----------------|----------------------------------|---------------------------------|
| Model                                  | 49.0478814                      | 5      | 9.80957628                                    |                | Prob > F                         | = 0.0000                        |
| Residual                               | 90.2382684                      | 752    | .119997697                                    |                | R-squared                        | = 0.3521                        |
| Total                                  | 139.28615                       | 757    | .183997556                                    |                | Adj R-squared<br>Root MSE        | = 0.3478<br>= .34641            |
|  | I                               |        |   |                |                                  |                                 |
| lnw                                    | Coef.                           | Std. I | Err. t  | P> t           | [95% Conf.                       | Interval]                       |
| lnw<br>s                               | Coef.<br>.102643                | .00584 |   | P> t <br>0.000 | [95% Conf.<br><br>.0911611       | Interval]<br>.114125            |
| ······································ |                                 |        | 488 17.55                                     | · ·            | <u>-</u>                         |                                 |
| s                                      | .102643                         | .00584 | 488 17.55<br>268 6.02                         | 0.000          | .0911611                         | .114125                         |
| s<br>expr                              | .102643                         | .00584 | 488 17.55<br>268 6.02<br>424 4.60             | 0.000          | .0911611                         | .114125                         |
| s<br>expr<br>tenure                    | .102643<br>.0381189<br>.0356146 | .00584 | 488 17.55<br>268 6.02<br>424 4.60<br>821 4.97 | 0.000          | .0911611<br>.0256986<br>.0204153 | .114125<br>.0505392<br>.0508138 |

"\_cons"表示常数项,"R-squared"显示  $R^2 = 0.3521$ ,"Adj R-squared"显示  $\bar{R}^2 = 0.3478$ 。

表上方显示,残差平方和 $\sum_{i=1}^{n} e_i^2 = 90.24$ ,方程的标准误差(Root MSE)为s = 0.34641。

检验整个方程显著性的F统计量为81.75,其对应的p值(Prob > F)为0.0000,表明这个回归方程整体高度显著。

所有解释变量(包括常数项)的回归系数的p值(P>|t|)都小于0.01,故均在1%水平上显著,而且符号与理论预期一致。

教育年限(s)的系数估计值为0.103,即教育投资回报率为10.3%。

工龄(expr)与在现单位工作年限(tenure)的回报率分别为 3.8%与 3.6%(可视为在职培训的回报率),小于正规教育的回报率。

住在大城市的回报率高达 14.0%, 甚至高于一年教育的回报率, 说明了环境的重要性。

变量 rns 的系数为-0.084,表明在给定其他变量的情况下,南方居民的工资比北方居民低 8.4%。

常数项的估计值为 4.104,这意味着未受任何教育(s = 0)、也无工作经验(expr = tenure = 0)、不住在大城市(smsa = 0),且身在南方(rns = 0)的年轻男子预期工资对数为 4.104。

## 如果要显示回归系数的协方差矩阵,可输入命令

#### . vce

## 其中, "vce" 表示 "variance covariance matrix estimated"。

| Covariance mat | trix of coeff | icients of r | egress model |           |           |          |
|----------------|---------------|--------------|--------------|-----------|-----------|----------|
| e(V)           | s             | expr         | tenure       | smsa      | rns       | _cons    |
| s              | .00003421     |              |              |           |           |          |
| expr           | 8.660e-06     | .00004003    |              |           |           |          |
| tenure         | -3.997e-08    | 00001107     | .00005994    |           |           |          |
| smsa           | 0000144       | 3.261e-06    | -7.819e-06   | .00078861 |           |          |
| rns            | 8.524e-06     | 7.334e-07    | 7.259e-06    | .00012486 | .00082928 |          |
| _cons          | 00046567      | 00016778     | 00008646     | 00038746  | 00043997  | .0072415 |

主对角线元素为各回归系数的方差,而非主对角线元素则为相应的协方差。

## 为演示目的,加上选择项"noconstant",进行无常数项回归:

## . reg lnw s expr tenure smsa rns, noc

|                       | Number of obs F( 5, 753)  |       | MS     | df        | SS         | Source   |
|-----------------------|---------------------------|-------|--------|-----------|------------|----------|
| = 9902.73<br>= 0.0000 | Prob > F                  |       | .59061 | 5 4856    | 24282.9531 | Model    |
| = 0.9850              | R-squared                 |       | 429688 | 753 .490  | 369.293555 | Residual |
| = 0.9849<br>= .70031  | Adj R-squared<br>Root MSE |       | 227528 | 758 32.5  | 24652.2466 | Total    |
| Interval]             | [95% Conf.                | P> t  | t      | Std. Err. | Coef.      | lnw      |
|                       | 2502200                   | 0.000 | 87.81  | .0041742  | .3665333   | s        |
| .3747277              | .3583389                  | 0.000 | 07.01  | .0041/42  | .3003333   | 5        |
| .3747277<br>.1570578  | .1093403                  | 0.000 | 10.96  | .0121535  | .1331991   | expr     |
|                       |                           |       |        |           |            |          |
| .1570578              | .1093403                  | 0.000 | 10.96  | .0121535  | .1331991   | expr     |

根据无常数项回归,教育投资回报率高达每年36.7%,显然不合理。

由于常数项很显著,故忽略常数项将导致估计偏差,得不到一致估计。

即使真实模型不包括常数项,在回归中加入常数项,也不会导致不一致的估计,故危害较小。

反之,如果真实模型包括常数项,但在回归时被忽略了,则可能导致严重的估计偏差。

因此,一般建议在回归中包括常数项。

# 如果只对南方居民的子样本进行回归,可使用虚拟变量 rms:

## . reg lnw s expr tenure smsa if rns

| Source    | SS                | df               | MS                             |                | Number of obs F( 4, 199) |      | 204<br>36.07         |
|-----------|-------------------|------------------|--------------------------------|----------------|--------------------------|------|----------------------|
| Model     | 17.603542         | 4                | 4.40088551                     |                | Prob > F                 |      | 0.0000               |
| Residual  | 24.2783596        | 199              | .122001807                     |                | R-squared                | = (  | 0.4203               |
|           |                   |                  | <del></del>                    |                | Adj R-squared            |      | 0.4087               |
| Total     | 41.8819016        | 203              | .206314786                     |                | Root MSE                 | = .  | .34929               |
|           |                   |                  |                                |                |                          |      |                      |
| -         |                   |                  |                                |                |                          |      |                      |
| lnw       | Coef.             | Std. E           | rr. t                          | P>   t         | [95% Conf.               | Inte | erval]               |
| Inw       | Coef.<br>.1198242 | Std. E<br>.01131 |                                | P> t <br>0.000 | [95% Conf.<br>           |      | erval]<br><br>421381 |
|           |                   |                  | 56 10.59                       | · · ·          |                          | .14  |                      |
| s         | .1198242          | .01131           | 56 10.59<br>72 3.69            | 0.000          | .0975103                 | .14  | 421381               |
| s<br>expr | .1198242          | .01131           | 56 10.59<br>72 3.69<br>79 0.59 | 0.000          | .0975103                 | .14  | 421381<br>069361     |

如果只对北方居民的子样本进行回归,可使用命令:

. reg lnw s expr tenure smsa if ~rns 其中, "~"表示逻辑的"否"(not)运算。

|                       | Number of obs F( 4, 549) |                | MS          | df        | SS                | Source    |
|-----------------------|--------------------------|----------------|-------------|-----------|-------------------|-----------|
| = 0.0000              | Prob > F                 |                | 161426      | 4 7.37    | 29.486457         | Model     |
| = 0.3127              | R-squared                |                | 036364      | 549 .118  | 64.8019636        | Residual  |
| = 0.3077              | Adj R-squared            |                | <del></del> |           |                   |           |
| = .34356              | Root MSE                 |                | 503473      | 553 .170  | 94.2884207        | Total     |
|                       |                          |                |             |           |                   |           |
| Interval]             | [95% Conf.               | P> t           | t           | Std. Err. | Coef.             | lnw       |
| Interval]<br>.1079076 | [95% Conf.<br>.0810498   | P> t <br>0.000 | t<br>13.82  | .0068365  | Coef.<br>.0944787 | lnw<br>s  |
|                       |                          |                |             |           |                   |           |
| .1079076              | .0810498                 | 0.000          | 13.82       | .0068365  | .0944787          | S         |
| .1079076              | .0810498                 | 0.000          | 13.82       | .0068365  | .0944787          | s<br>expr |

南方居民的教育投资回报率为 12.0%, 反而高于北方居民 9.4%的教育投资回报率。

# 如果只对中学以上(s>=12)的子样本进行回归,可输入命令:

. reg lnw s expr tenure smsa rns if s>=12

| Source         | SS                   | df     | MS                           |        | Number of obs F( 5, 673) |          |
|----------------|----------------------|--------|------------------------------|--------|--------------------------|----------|
| Model          | 41.8750434           | 5      | 8.37500867                   |        | Prob > F                 | = 0.0000 |
| Residual       | 80.7410668           | 673    | .119971867                   |        | R-squared                | = 0.3415 |
|                |                      |        | <del> </del>                 |        | Adj R-squared            | = 0.3366 |
| Total          | 122.61611            | 678    | .18084972                    |        | Root MSE                 | = .34635 |
|                |                      |        |                              |        |                          |          |
| lnw            | Coef.                | Std. E | Err. t                       | P>   t | [95% Conf.               | Interval |
|                |                      |        |                              |        |                          |          |
| S              | .1077261             | .00667 | 92 16.13                     | 0.000  | .0946115                 | .1208408 |
| s<br>expr      | .1077261<br>.0344524 | .00667 |                              | 0.000  | .0946115<br>.0204745     | .1208408 |
|                |                      |        | .89 4.84                     |        |                          |          |
| expr           | .0344524             | .00711 | 4.84<br>94 4.40              | 0.000  | .0204745                 | .0484304 |
| expr<br>tenure | .0344524             | .00711 | 4.84<br>4.40<br>4.48<br>5.31 | 0.000  | .0204745                 | .0484304 |

如果只对中学以上(s>=12)且在南方居住的子样本进行回归,可输入命令:

### . reg lnw s expr tenure smsa if s>=12 & rns

| Source                                | SS                | df                   | MS                   |                | Number of obs F( 4, 169) |    | 174<br>32.17           |
|---------------------------------------|-------------------|----------------------|----------------------|----------------|--------------------------|----|------------------------|
| Model                                 | 15.404067         | 4 3.                 | 85101675             |                | Prob > F                 | =  | 0.0000                 |
| Residual                              | 20.2300414        | 169 .1               | 19704387             |                | R-squared                | =  | 0.4323                 |
|                                       |                   |                      |                      |                | Adj R-squared            | =  | 0.4188                 |
| Total                                 | 35.6341084        | 173 .2               | 05977505             |                | Root MSE                 | =  | .34598                 |
| · · · · · · · · · · · · · · · · · · · |                   |                      |                      |                |                          |    |                        |
| lnw                                   | Coef.             | Std. Err             | . t                  | P>   t         | [95% Conf.               | In | terval]                |
| lnw                                   | Coef.<br>.1269124 | Std. Err<br>.0131847 | . t<br>9.63          | P> t <br>0.000 | [95% Conf.               |    | terval]<br><br>1529404 |
|                                       |                   |                      | 9.63                 |                |                          |    |                        |
| s                                     | .1269124          | .0131847             | 9.63<br>1.45         | 0.000          | .1008845                 | •  | 1529404                |
| s<br>expr                             | .1269124          | .0131847             | 9.63<br>1.45<br>0.81 | 0.000          | .1008845                 | •  | 1529404<br>0534613     |

回到最初估计的全样本:

. quietly reg lnw s expr tenure smsa rns

其中,前缀"quietly"表示不汇报回归结果。

如要计算被解释变量的拟合值 $(\widehat{\ln w})$ ,并记为  $\lim 1$ ,可使用命令:

. predict lnw1

如果要计算残差,并将其记为 e,可输入命令:

. predict e,<u>r</u>esidual 其中,选择项 "residual"表示计算残差,默认计算拟合值。 对于方程 $\ln w = \beta_1 + \beta_2 s + \beta_3 expr + \beta_4 tenure + \beta_5 smsa + \beta_6 rns + \varepsilon$ ,考虑检验教育投资回报率是否为 10%,即检验原假设" $H_0: \beta_2 = 0.1$ ",可使用命令:

. test s=0.1

此命令检验的原假设为,变量 s 的系数等于 0.1。

```
(1) s = .1
F(1, 752) = 0.20
Prob > F = 0.6515
```

由于t分布的平方为F分布,故 Stata 统一汇报F统计量及其p值。 上表显示,p值 = 0.6515,故无法拒绝原假设。 对于单个系数的检验, 手工计算t统计量也十分方便。

根据公式(5.58)可得

$$t = \frac{\text{估计量-假想值}}{\text{估计量的标准误}} = \frac{0.102643 - 0.1}{0.0058488} = 0.45188757 \sim t(n - K) = t(752)$$
(5.95)

由于默认为双边检验,故可计算此t统计量对应的p值如下:

- . dis ttail(752,0.45188757)\*2
- .65148029

其中,"ttail(752,0.45188757)"表示自由度为 752 的 t 分 布比 0.45188757 更大的右侧尾部概率,正好是反向累积分布函数。

手工计算的t统计量的p值,与 Stata 汇报的F统计量的p值完全相同。

如要进行单边检验,比如原假设仍为 $H_0: \beta_2 = 0.1$ ,而替代假设为 $H_1: \beta_2 > 0.1$ ,则拒绝域在t分布的右侧尾部。

相应的t统计量仍为 0.45188757,但在计算p值时,只须计算大于此t统计量的右侧尾部概率即可:

- . dis ttail(752, 0.45188757)
- .32574014

由于p值高达 0.3257,故依然可接受原假设。

如果已知双边检验的p值,在做单边检验时(假设t统计量的符号与替代假设的方向相同),一般只需将双边检验的p值除以 2,即可得到单边检验的p值,然后得到单边检验的结果。

考虑检验 expr 与 tenure 的系数是否相等,即检验 $H_0$ :  $\beta_3 = \beta_4$ ,可输入命令:

. test expr=tenure

```
(1) expr - tenure = 0
F(1, 752) = 0.05
Prob > F = 0.8208
```

由于p值 = 0.8208,可轻松接受原假设。

考虑检验工龄回报率与现单位年限回报率之和是否等于教育回报率,即" $H_0: \beta_3 + \beta_4 = \beta_2$ ",可使用命令:

. test expr+tenure=s

```
(1) - s + expr + tenure = 0

F(1, 752) = 8.82
Prob > F = 0.0031
```

由于p值 = 0.0031,故可在 1%的显著性水平上拒绝原假设,即认为 $\beta_3 + \beta_4 \neq \beta_2$ 。