第6章 大样本OLS

6.1 为何需要大样本理论

"大样本理论"(large sample theory), 也称"渐近理论"(asymptotic theory), 研究当样本容量n趋向无穷大时统计量的性质。

大样本理论已成为当代计量经济学的主流方法,原因如下。

(1) 小样本理论的假设过强。

首先,小样本理论的严格外生性假设要求解释变量与所有的扰动项均正交(不相关)。

1

在时间序列模型中,这意味着解释变量与扰动项的过去、现在与未来值全部正交!

例 考虑以下一阶自回归模型(first order autoregression, 简记 AR(1)):

$$y_{t} = \rho y_{t-1} + \varepsilon_{t} \quad (t = 2, \dots, T)$$
 (6.1)

解释变量 y_{t-1} 为被解释变量 y_t 的一阶滞后;且Cov $(y_{t-1}, \varepsilon_t) = 0$ 。

严格外生性要求,解释变量 y_{t-1} 与所有 $\{\varepsilon_2, \dots, \varepsilon_T\}$ 均不相关。

这意味着, y_t 也不与 ε_t 相关。但 ε_t 是 y_t 的一部分,故二者一定相关,因为

$$Cov(y_t, \varepsilon_t) = Cov[(\rho y_{t-1} + \varepsilon_t), \varepsilon_t] = \rho \underbrace{Cov(y_{t-1}, \varepsilon_t)}_{=0} + Var(\varepsilon_t) = Var(\varepsilon_t) > 0$$
(6.2)

以被解释变量滞后值为解释变量的自回归模型,必然违背严格外生性的假定。

大样本理论只要求解释变量与同期(同方程)的扰动项不相关。

其次,小样本理论假定扰动项为正态分布,而大样本理论无此限制。

在很多情况下,并无把握经济变量是否服从正态分布。

比如,正态分布为对称分布,但许多经济变量的分布并不对称, 例如工资收入。

即使考虑比较对称的工资对数,由于正态变量的取值范围为 $(-\infty, +\infty)$,而工资对数一般为正数(假设工资大于 1),也不相符。

将数据集 grilic.dta 的工资与工资对数的核密度图画在一起,参见图 6.1。

- . use grilic.dta, clear
- . gen wage=exp(lnw)

. twoway kdensity wage,xaxis(1) yaxis(1)
xvarlab(wage) | | kdensity lnw,xaxis(2) yaxis(2)
xvarlab(ln(wage)) lpattern(dash)

选择项 "xaxis(1) yaxis(1)"与 "xaxis(2) yaxis(2)" 指定对于变量 wage 与 lnw 分别使用不同的x轴与y轴,因为这两个变量的取值范围与概率密度很不相同。

选择项 "xvarlab(wage)"与 "xvarlab(ln(wage))"将 变量 wage 与 lnw 核密度图的横轴标签分别指定为 "wage"与 "ln(wage)"。

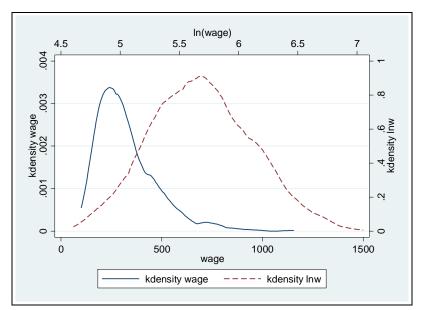


图 6.1 工资与工资对数的分布

工资的分布与正态分布相去甚远。

即使工资对数,在取值范围为(-∞,+∞)上,也与正态分布不符。

被解释变量的分布可能为各种形状;有时即使取对数也不能使其接近正态分布。

将教育年限(s)与其对数(lns)的核密度图画在一起,参见图 6.2。

- . gen lns=log(s)
- . twoway kdensity s,xaxis(1) yaxis(1) xvarlab(s)
 || kdensity lns,xaxis(2) yaxis(2) xvarlab(lns)
 lpattern(dash)

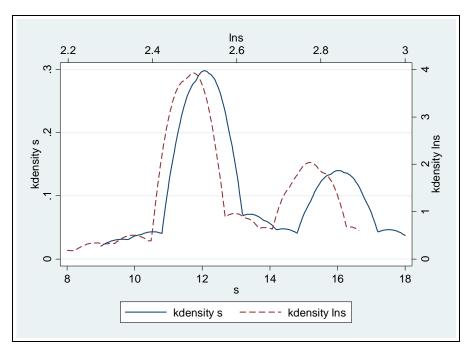


图 6.2 教育年限 s 与其对数 lns 的分布

教育年限的分布呈现"双峰"状,即多数人为中学或大学毕业。这种双峰形状,即使取对数后,也难以改变。

无论教育年限还是其对数,都与"单峰"的正态分布相去甚远。 通过取对数使得变量的分布接近于正态并非万能。

对于小样本理论来说,为了进行统计推断(比如,推导t与F统计量的分布),须假设扰动项服从正态分布(故被解释变量也为正态)。

由于现实中的被解释变量可能服从各种分布(比如,变量婚否mrt 为离散的两点分布),故基于正态假设的小样本理论的适用范围受到很大限制。

(2) 在小样本理论的框架下,须研究统计量的精确分布(exact distribution),但常难以推导(即使在正态分布的假设之下)。

根据大样本理论,只要研究统计量的大样本分布,即当 $n\to\infty$ 时的渐近分布,相对容易推导(可使用大数定律与中心极限定理)。

(3) 使用大样本理论的代价是要求样本容量较大,以便大数定律与中心极限定理可以起作用。

大样本理论对于样本容量的要求,一般认为至少 $n \ge 30$,最好在 100 以上。现代的数据集越来越大,经常成百上千。

在当代计量实践中,研究人员一般用大样本理论;小样本 OLS 已很少使用。

6.2 随机收敛

1. 确定性序列的收敛

定义 确定性序列 $\{a_n\}_{n=1}^{\infty} = \{a_1, a_2, a_3, \cdots\}$ 收敛(converge)于常数 a_n 记为 $\lim_{n\to\infty} a_n = a$ 或 $a_n\to a$,如果对于任意小的正数 $\varepsilon>0$,都存在 N>0,只要 n>N,就有 $|a_n-a|<\varepsilon$,即在 a_N 以后的序列 $\{a_{N+1}, a_{N+2}, \cdots\}$ 均落入区间 $(a-\varepsilon, a+\varepsilon)$ 内,参见图 6.3。

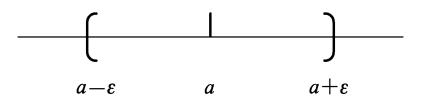


图 6.3 确定性序列的收敛

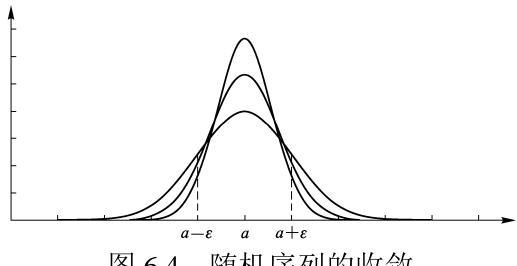
例 假设
$$a_n = 5 + \frac{1}{n}$$
,则 $\lim_{n \to \infty} a_n = \lim_{n \to \infty} (5 + \frac{1}{n}) = 5 + \lim_{n \to \infty} \frac{1}{n} = 5 + 0 = 5$ 。

2. 随机序列的收敛

考虑随机序列 $\{x_n\}_{n=1}^{\infty} = \{x_1, x_2, x_3, \cdots\}$,即由随机变量构成的序列,其中每个元素 x_n 都是随机变量,下标n通常表示样本容量。

定义 随机序列 $\{x_n\}_{n=1}^{\infty}$ 依概率收敛(converge in probability)于常数 a,记为p $\lim_{n\to\infty} x_n = a$,或 $x_n \xrightarrow{p} a$,如果对于任意 $\varepsilon > 0$,当 $n\to\infty$ 时,都有 $\lim_{n\to\infty} P(|x_n-a|>\varepsilon)=0$ 。

任意给定很小的正数 $\varepsilon > 0$,当n越来越大时,随机变量 x_n 落在区间($a-\varepsilon$, $a+\varepsilon$)之外的概率收敛于 0,参见图 6.4。



随机序列的收敛 图 6.4

当n变大时, x_n 远离常数 a 的可能性越来越小,变得几乎不可能。

由于已将随机事件 $(|x_n-a|>\varepsilon)$ 取概率,故 $P(|x_n-a|>\varepsilon)$ 其实是确 定性序列(为概率的具体取值,已无不确定性),而 $\lim_{n\to\infty} P(|x_n-a|>\varepsilon)$ 只是普通的微积分极限。

例 假设 x_n 服从如下两点分布:

$$x_n = \begin{cases} 0 & \text{取值概率 } 1-(1/n) \\ n & \text{取值概率 } 1/n \end{cases}$$
 (6.3)

随着 $n\to\infty$, x_n 的分布越来越集中于 0,取值为n的可能性越来越小。故根据定义, $p\lim x_n=0$ 。

利用随机变量依概率收敛于常数的概念,可定义随机变量之间的随机收敛,只要随机变量之差别依概率收敛于0。

定义 随机序列 $\{x_n\}_{n=1}^{\infty}$ 依概率收敛于随机变量x,记为 $x_n \xrightarrow{p} x$,如果随机序列 $\{x_n - x\}_{n=1}^{\infty}$ 依概率收敛于 0。

概率收敛(plim)的运算规则类似于微积分中极限($\lim_{n\to\infty}$)的运算。

比如,假设 $g(\cdot)$ 为连续函数,则

$$\operatorname{plim}_{n \to \infty} g(x_n) = g\left(\operatorname{plim}_{n \to \infty} x_n\right) \tag{6.4}$$

概率极限plim与连续函数 $g(\cdot)$ 可交换运算次序。

当 x_n 的分布越来越集中于 $x^* \equiv \underset{n \to \infty}{\text{plim}} x_n$ 附近时, $g(x_n)$ 的分布自然也就越来越集中于 $g(x^*)$ 附近。

期望算子 $E(\cdot)$ 无此性质,因为 $E(x^2) \neq [E(x)]^2$ 。这正是大样本理论的方便之处。

例 如果 $\lim_{n\to\infty} s^2 = \sigma^2$ (样本方差依概率收敛于总体方差),则样本标准差s也依概率收敛于总体标准差 σ ,因为

$$\underset{n\to\infty}{\text{plim } s = \text{plim } \sqrt{s^2}} = \sqrt{\underset{n\to\infty}{\text{plim } s^2}} = \sqrt{\sigma^2} = \sigma$$
(6.5)

其中,"开根号"($\sqrt{\cdot}$)是连续函数,故可与求概率极限的运算交换次序。

对于随机向量序列(即序列中每个元素都是随机向量),也可类似地定义依概率收敛,只要定义其每个分量都依概率收敛即可。

比如,随机向量序列 $\{x_n\}_{n=1}^{\infty} = \{x_1, x_2, x_3 \cdots \}$ 依概率收敛于随机向量x,意味着 x_n 的每个分量都依概率收敛至x的相应分量,记为 $\lim x_n = x$ 。

3. 依均方收敛

定义 如果随机序列 $\{x_n\}_{n=1}^{\infty}$ 的期望收敛于 a,即 $\lim_{n\to\infty} E(x_n) = a$;而 方差收敛于 0,即 $\lim_{n\to\infty} Var(x_n) = 0$,则称 $\{x_n\}_{n=1}^{\infty}$ **依均方收敛**(converge in mean square)于常数 a,记为 $x_n \xrightarrow{ms} a$ 。

通过切比雪夫不等式,可以证明,依均方收敛意味着依概率收敛。

当 x_n 的均值越来越趋于 a,而方差越来越小并趋于 0 时,就有 $p\lim x_n = a$,即在极限处 x_n 退化为常数 a。

证明均方收敛通常比证明概率收敛更容易,故可通过证明前者来证明后者,这也是依均方收敛概念的主要用途之一。

反之,依概率收敛并不意味着均方收敛。

例 回到 $\{x_n\}$ 服从两点分布的例子,即 x_n 取值为 0 的概率为 1-(1/n),而取值为n的概率为(1/n)。虽然 x_n 依概率收敛到 0,但 x_n 并不依均方收敛到 0,因为此序列的期望恒等于 1:

$$\lim_{n \to \infty} \mathbf{E}(x_n) = \lim_{n \to \infty} \left[0 \cdot \left(1 - \frac{1}{n} \right) + n \cdot \frac{1}{n} \right] = 1 \neq 0$$
 (6.6)

随着 $n\to\infty$,随机序列 x_n 取值大于 0 的概率越来越小(为 1/n),但一旦取值为正数,则很大(等于 n),故此序列的期望始终为 1。

4. 依分布收敛

定义 记随机序列 $\{x_n\}_{n=1}^{\infty}$ 与随机变量x的累积分布函数分别为 $F_n(x)$ 与F(x)。如果对于任意给定x,都有 $\lim_{n\to\infty}F_n(x)=F(x)$,则称随机序列 $\{x_n\}_{n=1}^{\infty}$ 依分布收敛(converge in distribution)于随机变量x,记为 $x_n \xrightarrow{d} x$,并称x的分布为 x_n 的渐近分布(asymptotic distribution)或极限分布(limiting distribution)。

当n→∞时, x_n 的分布函数越来越像x的分布函数。

例 当t分布的自由度越来越大时,t分布依分布收敛于标准正态分布; 即当 $k \to \infty$ 时, $t(k) \stackrel{d}{\longrightarrow} N(0,1)$ 。

为了直观地显示依分布收敛的过程,在 Stata 中画 N(0, 1), t(1)与 t(5)的累积分布函数,参见图 6.5。

. twoway function N=normal(x) ,range(-5 5) | function t1=t(1,x),range(-5 5) | lpattern(dash) | function t5=t(5,x),range(-5 5) | lpattern(shortdash) ytitle(累积分布函数)

其中,选择项"lpattern(shortdash)"表示以短横来画线。

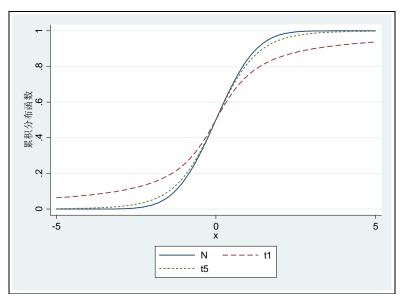


图 6.5 依分布收敛(累积分布函数)

更直观地,可通过概率密度函数,来考察t分布依分布收敛于标准正态的过程,参见图 6.6。

. twoway function N=normalden(x), range(-55) | function t1=tden(1,x), range(-55) | lpattern(dash) | function t5=tden(5,x), range(-55) | lpattern(shortdash) ytitle(概率密度)

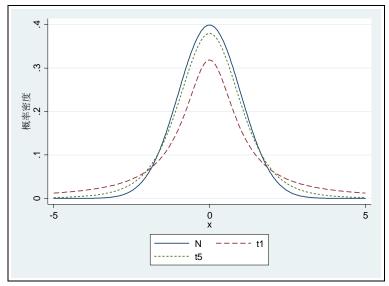


图 6.6 依分布收敛(概率密度函数)

许多统计量的大样本分布均为正态分布,故引入如下概念。

定义 如果 $x_n \xrightarrow{d} x$,且x服从正态分布,则称 x_n 为**渐近正态** (asymptotically normal),即当 $n \to \infty$ 时, x_n 的分布越来越像正态分布。

依分布收敛的运算也很方便。

假设 $x_n \xrightarrow{d} x$,而 $g(\cdot)$ 为连续函数,则 $g(x_n)$ 的渐近分布就是g(x),即 $g(x_n) \xrightarrow{d} g(x)$ 。

当 x_n 的分布越来越像x的分布时, $g(x_n)$ 的分布自然也越来越像 g(x)的分布。这为大样本理论的推导提供了方便。

例 假设 $x_n \xrightarrow{d} z$,其中 $z \sim N(0,1)$,则 $x_n^2 \xrightarrow{d} z^2$,其中 $z^2 \sim \chi(1)$,即 $x_n^2 \xrightarrow{d} \chi(1)$,因为平方是连续函数。

因此,渐近标准正态的平方服从渐近χ(1)的分布。

"依概率收敛"比"依分布收敛"更强,前者是后者的充分条件;但反之,则不然。

如果 $x_n \xrightarrow{p} x$,则意味着 $(x_n - x) \xrightarrow{p} 0$,即在极限处 x_n 与x的具体取值并无区别,故二者的概率分布也必然相同,所以 $x_n \xrightarrow{d} x$ 。

如果 $x_n \xrightarrow{d} x$,这只说明在极限处 x_n 与x的分布函数相同,但 x_n 与x的实际取值仍可以很不相同(比如, x_n 与x相互独立)。

依分布收敛只是分布函数的收敛(随机变量之间可以毫无关系), 而依概率收敛才是随机变量本身的收敛。

例 假设x与y都为标准正态,且相互独立。考虑随机序列 $\left\{x_n = x + (1/n)\right\}_{n=1}^{\infty}$ 。

由于 $1/n \to 0$,故 x_n 的渐近分布为标准正态,因此 $x_n \xrightarrow{d} y(y$ 也是标准正态)。

但 x_n 却与y相互独立, x_n 的具体取值也与y毫无关系,故 x_n 并不依概率收敛于y。

总之,"依均方收敛"⇒"依概率收敛"⇒"依分布收敛"。

6.3 大数定律与中心极限定理

大样本理论所依赖的两大工具是大数定律与中心极限定理,但 须作推广。

1. 大数定律(Law of Large Numbers)

假定 $\{x_n\}_{n=1}^{\infty}$ 为独立同分布的随机序列,且E $(x_1) = \mu$,Var $(x_1) = \sigma^2$ 存在,则样本均值 $\overline{x}_n \equiv \frac{1}{n} \sum_{i=1}^n x_i \xrightarrow{p} \mu$ 。

证明: 首先, $E(\overline{x}_n) = \frac{1}{n} \sum_{i=1}^n E(x_i) = \frac{1}{n} \cdot n\mu = \mu$,故样本均值 \overline{x}_n 的期望仍为 μ 。

其次, $Var(\overline{x}_n) = Var\left(\frac{x_1 + \dots + x_n}{n}\right) = \frac{1}{n^2}(n\sigma^2) = \frac{\sigma^2}{n} \to 0$,样本均值 \overline{x}_n 的方差收敛到 0。

因此, \bar{x}_n 依均方收敛于 μ 。

由于"依均方收敛"是"依概率收敛"的充分条件,故 $\bar{x}_n \xrightarrow{p} \mu$ 。

当样本容量n很大时,样本均值趋于总体均值,故名"大数定律"。

2. 中心极限定理(Central Limit Theorem)

根据大数定律,当 $n\to\infty$ 时,样本均值 \overline{x}_n 依概率收敛到总体均值 μ 。但一般情况下, \overline{x}_n 的具体分布很难推导。

中心极限定理告诉我们,无论原序列 $\{x_n\}_{n=1}^{\infty}$ 服从什么分布,当 $n \to \infty$ 时,样本均值 \overline{x}_n 的渐近分布都为正态分布。

只要样本容量n足够大,则 \bar{x}_n 的真实分布将很接近于正态分布。

中心极限定理 假定 $\{x_n\}_{n=1}^{\infty}$ 为独立同分布的随机序列,且 $E(x_1) = \mu$, $Var(x_1) = \sigma^2$ 存在,则

$$\frac{\overline{x}_n - \mu}{\sqrt{\sigma^2/n}} \xrightarrow{d} N(0, 1) \tag{6.7}$$

标准化之后的样本均值(即减去期望,除以标准差)的渐近分布为标准正态。

直观上,可视为 $\bar{x}_n \xrightarrow{d} N(\mu, \sigma^2/n)$; 但不严格,因为 \bar{x}_n 的方差 $\sigma^2/n \to 0$ (在极限处, \bar{x}_n 的方差为 0,故退化为常数 μ)。

将表达式(6.7)两边同乘 σ ,并将 $\sqrt{1/n}$ 放到分子上,可得中心极限定理的等价表达式:

$$\sqrt{n}(\overline{x}_n - \mu) \xrightarrow{d} N(0, \sigma^2)$$
 (6.8)

 $\sqrt{n} \to \infty$; 而根据大数定律, $(\bar{x}_n - \mu) \xrightarrow{p} 0$,故上式用 $\sqrt{n} \cdot (\bar{x}_n - \mu)$ (即" $\infty \cdot 0$ "型)得到非退化的渐近正态分布。

表达式(6.8)的好处是,容易推广到多维的情形。

多维的中心极限定理: 假定 $\{x_n\}_{n=1}^{\infty}$ 为独立同分布的随机向量序列,且E $(x_1) = \mu$, Var $(x_1) = \Sigma$ 存在,则 $\sqrt{n}(\bar{x}_n - \mu) \stackrel{d}{\longrightarrow} N(\mathbf{0}, \Sigma)$ 。

6.4 使用蒙特卡罗法模拟中心极限定理

假设x服从在(0,1)上的均匀分布,从此分布随机抽取观测值,样本容量为30。

希望用蒙特卡罗法直观地"看到"样本均值x₃₀的分布,并与正态分布相比较。

从(0,1)上的均匀分布抽取 10000 个样本容量为 30 的随机样本,得到 10000 个 \bar{x}_{30} 的观测值,然后画直方图。

使用如下 Stata 程序:

首先,用命令 program 定义一个叫"onesample"的程序,从均匀分布抽取一个样本容量为 30 的随机样本,并计算 \bar{x}_{30} ;

其次,用命令 simulate 重复此程序 10000 次,得到 10000 个 \bar{x}_{30} 的观测值;

最后,用命令 histogram 画 \bar{x}_{30} 的直方图。

具体来说,在Stata命令窗口输入如下命令:

. program onesample, rclass (定义程序 onesample, 并以r()形式储存结果)

drop _all

(删去内存中已有数据)

set obs 30

(确定随机抽样的样本容量为30)

gen x=runiform() (得到在(0,1)上均匀分布的随机样本)

sum x

(使用命令 sum 计算样本均值)

return scalar mean_sample=r(mean) (将样本均值记 为 mean_sample)

end

(程序 onesample 结束)

. set more off

(指定 Stata 输出结果连续翻页)

. simulate xbar=r(mean_sample),seed(101) reps(10000) nodots: onesample

选择项 "reps(10000)" 表示, 命令 simulate 将运行 "onesample"程序 10000 遍, 并生成变量 xbar 来记录这 10000 个样本均值。

选择项 "seed(101)" 用来确定随机数的初始值,以便再次模拟或别人运行此程序时,也能得到完全一样的结果。

选择项"nodots"表示不显示表示模拟过程的点点(默认以一个点表示抽取一个样本)。

. hist xbar, normal

其中,选择项"normal"表示画出相应的正态分布,参见图 6.7。

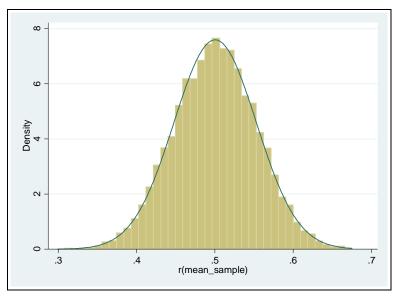


图 6.7 模拟中心极限定理

虽然样本容量仅30,但 \bar{x}_{30} 的分布已很接近于正态分布。

6.5 统计量的大样本性质

关心当样本容量 $n \to \infty$ 时,统计量是否具有良好的大样本性质。

1. 一致估计量

定义 考虑参数 β 的估计量 $\hat{\beta}_n$, 其中下标n为样本容量(强调 $\hat{\beta}_n$ 对样本容量n的依赖)。如果 $\lim_{n\to\infty}\hat{\beta}_n=\beta$,则称 $\hat{\beta}_n$ 是参数 β 的一致估计量(consistent estimator)。

一致性(consistency)意味着,当样本容量足够大时, $\hat{\beta}_n$ 依概率收敛到真实参数 β ,参见图 6.8。

这是对估计量最基本,也是最重要的要求。

如果估计方法不一致,则意味着研究没有太大意义;因为无论样本容量多大,估计量也不会收敛到真实值。

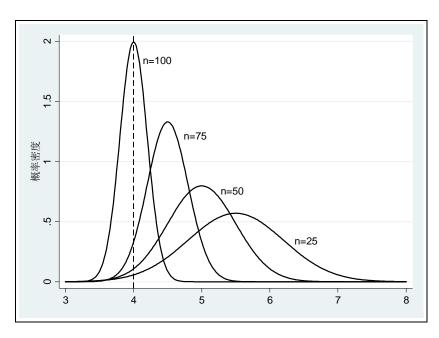


图 6.8 一致估计量示意图

在多维情况下,称估计量 $\hat{\boldsymbol{\beta}}_n$ 是参数 $\boldsymbol{\beta}$ 的一致估计量,如果 $\text{plim}\,\hat{\boldsymbol{\beta}}_n = \boldsymbol{\beta}$,即 $\hat{\boldsymbol{\beta}}_n$ 的各分量都是 $\boldsymbol{\beta}$ 相应分量的一致估计。

3. 渐近正态分布与渐近方差

定义 如果 $\sqrt{n}(\hat{\beta}_n - \beta) \xrightarrow{d} N(0, \sigma^2)$,则称 $\hat{\beta}_n$ 为渐近正态 (asymptotically normal),称 σ^2 为其渐近方差(asymptotic variance),记为Avar($\hat{\beta}_n$)。

可近似认为 $\hat{\beta}_n \xrightarrow{d} N(\beta, \sigma^2/n)$,但不严格(方差 σ^2/n 趋于 0,故为退化的分布)。

在多维情况下,如果 $\sqrt{n}(\hat{\boldsymbol{\beta}}_n - \boldsymbol{\beta}) \xrightarrow{d} N(\boldsymbol{\theta}, \boldsymbol{\Sigma})$,其中 $\boldsymbol{\Sigma}$ 为半正定矩阵,则称 $\hat{\boldsymbol{\beta}}_n$ 为渐近正态分布,而称 $\boldsymbol{\Sigma}$ 为 $\hat{\boldsymbol{\beta}}_n$ 的渐近协方差矩阵,记为 $\operatorname{Avar}(\hat{\boldsymbol{\beta}}_n)$ 。

4. 渐近有效

假设 $\hat{\beta}_n$ 与 $\tilde{\beta}_n$ 都是 β 的渐近正态估计量。如果Avar($\hat{\beta}_n$) \leq Avar($\tilde{\beta}_n$), 则称 $\hat{\beta}_n$ 比 $\tilde{\beta}_n$ 更为渐近有效(asymptotically more efficient)。

在大样本下, $\hat{\beta}_n$ 的方差小于 $\tilde{\beta}_n$ 的方差(在小样本下未必如此)。

在多维情况下,假设 $\hat{\boldsymbol{\beta}}_n$ 与 $\tilde{\boldsymbol{\beta}}_n$ 都是 $\boldsymbol{\beta}$ 的渐近正态估计量。如果 [Avar($\tilde{\boldsymbol{\beta}}_n$)-Avar($\hat{\boldsymbol{\beta}}_n$)]为半正定矩阵,则称 $\hat{\boldsymbol{\beta}}_n$ 比 $\tilde{\boldsymbol{\beta}}_n$ **更为渐近有效**。

6.6 随机过程的性质

大数定律与中心极限定理假设随机序列为 iid, 但对于大多数经济变量, 此假定太强。

比如,今年的通货膨胀率通常依赖于去年的通货膨胀率,二者并非相互独立。

需要研究随机序列的性质,并将推广大数定律与中心极限定理。

随机序列 $\{x_n\}_{n=1}^{\infty}$ 有个更好听的名称,叫"随机过程"(stochastic process)。

如下标为时间,则记为 $\{x_t\}_{t=1}^{\infty}$,也称"时间序列"(time series)。

1. 严格平稳过程

考察中国 1978—2013 年的通货膨胀率,即 $\{\pi_{1978}, \pi_{1979}, \cdots, \pi_{2013}\}$,参见图 6.9。

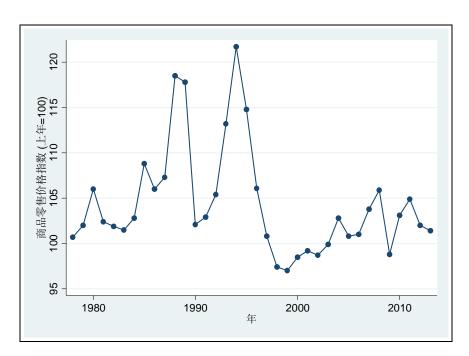


图 6.9 中国零售商品价格指数 (上年=100)

假如每年的通货膨胀率作为随机变量都有不同的分布,如何估计 $E(\pi_{1978})$ 与 $Var(\pi_{1978})$ 呢?

每年通货膨胀率的样本容量仅为1,且历史不能重演!

如果这 36 年的通货膨胀率分布都不变,则可将 $\pi = \frac{1}{36} \sum_{t=1978}^{2013} \pi_t$ 作为 $E(\pi_t)$ 的估计量。

通常要求随机过程 $\{x_t\}_{t=1}^{\infty}$ 的概率分布不随时间推移而改变。

无论过去、现在还是未来去看此随机过程,它的概率分布性质都一样。

这种随机过程称为"严格平稳过程",它要求随机过程的有限维 分布不随时间推移而改变。

比如, x_t 的分布与 x_s 的分布相同($\forall t, s$);

 (x_1, x_4) 的分布与 (x_2, x_5) 相同(二者均相隔 3 期);

 (x_1, x_2, x_3) 的分布与 (x_5, x_6, x_7) 相同(二者均为连续3期)。

定义 随机过程 $\{x_t\}_{t=1}^{\infty}$ 是严格平稳过程(strictly stationary process),简称平稳过程,如果对任意 m 个时期的时间集合 $\{t_1,t_2,\cdots,t_m\}$,随机向量 $\{x_{t_1},x_{t_2},\cdots,x_{t_m}\}$ 的联合分布等于随机向量 $\{x_{t_1+k},x_{t_2+k},\cdots,x_{t_m+k}\}$ 的联合分布,其中k为任意整数。

将 $\{x_{t_1}, x_{t_2}, \dots, x_{t_m}\}$ 中每个变量的时间下标全部前移或后移k期,不会改变其分布。

 $\{x_{t_1}, x_{t_2}, \dots, x_{t_m}\}$ 的联合分布仅取决于 $\{t_1, t_2, \dots, t_m\}$ 各个时期之间的相对距离,而不依赖于其绝对位置。

例 如果随机过程 $\{x_t\}_{t=1}^{\infty}$ 为 iid,则 $\{x_t\}_{t=1}^{\infty}$ 是平稳过程,且不存在序列相关。

例 如果随机过程 $\{x_t\}_{t=1}^{\infty} = \{x_1, x_1, x_1, \cdots\}$ (即 $x_t \equiv x_1$),则 $\{x_t\}_{t=1}^{\infty}$ 是平稳过程,且存在最强的序列相关。

例 考虑以下一阶自回归过程(AR(1)),

$$y_t = \rho y_{t-1} + \varepsilon_t \quad (t = 1, \dots, T)$$
 (6.9)

其中, $\{\varepsilon_t\}$ 为独立同分布,且 $Cov(y_{t-1},\varepsilon_t)=0$ 。

命题 如果 $\rho=1$,则 $\{y_t\}$ 不是平稳过程。如果 $|\rho|<1$,则 $\{y_t\}$ 为 平稳过程。

证明: 如果 $\rho=1$,则 $y_t=y_{t-1}+\varepsilon_t$ 。因此, $y_1=y_0+\varepsilon_1$,而 $y_2=y_1+\varepsilon_2=y_0+\varepsilon_1+\varepsilon_2$,以此类推可知

$$y_t = y_0 + \varepsilon_1 + \varepsilon_2 + \dots + \varepsilon_t \tag{6.10}$$

给定初始值 y_0 , 当 $t \to \infty$ 时, $Var(y_t) = t\sigma_{\varepsilon}^2 \to \infty$, 其中 $\sigma_{\varepsilon}^2 \equiv Var(\varepsilon_t)$,

即方差越来越大,以至无穷。

故 $\{y_t\}$ 不是平稳过程(平稳过程要求同分布,故方差不变)。

由于 y_t 只是在 y_{t-1} 的基础上,加上随机扰动项 ε_t ,故当 $\rho=1$ 时,称 $\{y_t\}$ 为"随机游走"(random walk)。

如果 $|\rho|$ <1,则 $Var(y_t)$ 会收敛到常数。对方程(6.9)两边同时取方差,可得

$$Var(y_t) = \rho^2 Var(y_{t-1}) + \sigma_{\varepsilon}^2 \qquad (6.11)$$

记
$$z_t \equiv \text{Var}(y_t)$$
, $z_{t-1} = \text{Var}(y_{t-1})$,则上式可写为
$$z_t = \rho^2 z_{t-1} + \sigma_{\varepsilon}^2 \qquad (6.12)$$

这是确定性的一阶线性差分方程,因为 $z_t \equiv \text{Var}(y_t)$ 为非随机。由于 $\rho^2 < 1$,故 $\text{Var}(y_t)$ 将收敛到一个稳定值,参见图 6.10。

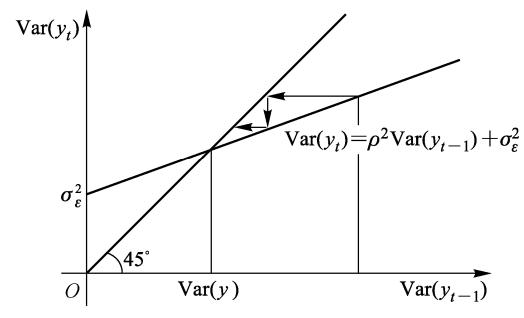


图 6.10 平稳一阶自回归过程的方差收敛

在方程(6.12)中,令 $z_t = z_{t-1}$,可求解此收敛的稳定值 z^* :

$$z^* = \rho^2 z^* + \sigma_{\varepsilon}^2 \tag{6.13}$$

移项整理可得,

$$z^* = \frac{\sigma_{\varepsilon}^2}{1 - \rho^2}$$

如果忽略序列 $\{y_t\}$ 的前面几项,可将 $\{y_t\}$ 的方差视为常数。

进一步可证明, $\{y_t\}_{t=0}^{\infty}$ 是严格平稳过程。

有时仅关心随机过程的期望、方差及协方差是否稳定,而不要求整个分布都稳定,故引入以下"弱平稳过程"的概念。

定义 随机过程 $\{x_t\}_{t=1}^{\infty}$ 是弱平稳过程(weakly stationary process) 或**协方差平稳过程**(covariance stationary process),如果 $E(x_t)$ 不依赖于t,而且 $Cov(x_t,x_{t+k})$ 仅依赖于k(即 x_t 与 x_{t+k} 在时间上的相对距离) 而不依赖于其绝对位置t。

对于弱平稳过程,由于 $E(x_t)$ 不依赖于t,故其期望为常数。

由于 $Cov(x_t, x_{t+k})$ 仅依赖于k,如果令k = 0,则 $Cov(x_t, x_t) = Var(x_t)$ 也不依赖于t,故弱平稳过程的方差也是常数。

严格平稳过程是弱平稳过程的充分条件;但反之则不然。

弱平稳过程只要求二阶矩平稳(即期望、方差、协方差等不随时间而变),而概率分布还可能依赖于更高阶的矩。

定义 对于弱平稳过程 $\{x_t\}_{t=1}^{\infty}$,如果对于 $\forall t$,都有 $E(x_t)=0$,而且 $Cov(x_t, x_{t+k})=0$ ($\forall k \neq 0$),则称为白噪声过程(white noise process)。

白噪声过程不一定独立同分布,也不一定是严格平稳过程。

"白噪声"是性质比较好的"噪声",即该噪声的期望值为0,而不同期之间的噪声互不相关。

对于随机向量过程 $\{x_t\}_{t=1}^{\infty}$,可以类似地定义平稳过程或弱平稳过程(只要将上述定义中的x置换为x即可)。

如果 $\{x_t\}_{t=1}^{\infty}$ 为(弱)平稳过程,则其每个分量都是(弱)平稳过程; 反之,则不然。

2. 渐近独立性

"严格平稳过程"(相当于"同分布"假定)还不足以应用大数定律或中心极限定理,因为它们都要求独立同分布(iid)。

但"相互独立"的假定对于大多数经济变量过强。

比如,今年的通胀率显然与去年的通胀率相关。

但今年的通胀率与 100 年前的通胀率或许可近似地视为相互独立, 称为**渐近独立**(ergodic, 也称**遍历性**), 或**弱相依**(weakly dependent)。

渐近独立意味着,只要两个随机变量相距足够远,可近似认为它们相互独立。

例相互独立的随机序列是渐近独立的。

例 AR(1)是否渐近独立? 考虑以下一阶自回归模型:

$$y_t = \rho y_{t-1} + \varepsilon_t \tag{6.14}$$

其中, $|\rho|$ <1,而 ε_t 为白噪声。

计算其各阶"自协方差"(autocovariance)。

当时间间隔为1期时,一阶自协方差为

$$Cov(y_t, y_{t-1}) = Cov(\rho y_{t-1} + \varepsilon_t, y_{t-1}) = \rho \sigma_y^2 + \underbrace{Cov(\varepsilon_t, y_{t-1})}_{=0} = \rho \sigma_y^2$$
 (6.15)

其中, σ_v^2 为 y 的方差;而

$$Cov(\varepsilon_t, y_{t-1}) = Cov(\varepsilon_t, \rho y_{t-2} + \varepsilon_{t-1}) = Cov(\varepsilon_t, \varepsilon_{t-1}) = 0$$
,因为 ε_t 为白噪声。

当时间间隔为2期时,原方程(6.14)可写为

$$y_t = \rho y_{t-1} + \varepsilon_t = \rho(\rho y_{t-2} + \varepsilon_{t-1}) + \varepsilon_t = \rho^2 y_{t-2} + \rho \varepsilon_{t-1} + \varepsilon_t \quad (6.16)$$

因此,二阶自协方差为

$$Cov(y_t, y_{t-2}) = Cov(\rho^2 y_{t-2} + \rho \varepsilon_{t-1} + \varepsilon_t, y_{t-2}) = \rho^2 \sigma_y^2$$
 (6.17)

以此类推,当时间间隔为j期时,

$$Cov(y_t, y_{t-j}) = \rho^j \sigma_v^2$$
 (6.18)

由于 $|\rho|$ <1, 故当上式 $j\to\infty$ 时, $Cov(y_t,y_{t-j})\to 0$ 。

相距越远,则序列 $\{y_t\}$ 的自协方差越小,且在极限处变为0(不相关),故此 AR(1)模型为渐近独立的过程。

渐近独立定理(Ergodic Theorem) 假设 $\{x_i\}_{i=1}^{\infty}$ 为渐近独立的严格 平稳过程,且 $\mathbf{E}(x_i) = \mu$ 存在,则 $\overline{x}_n \equiv \frac{1}{n}\sum_{i=1}^n x_i \stackrel{p}{\longrightarrow} \mu$,即样本均值 \overline{x}_n 是总体均值 $\mathbf{E}(x_i)$ 的一致估计。

渐近独立定理是对大数定律的重要推广,更适用于经济数据。

大数定律要求每个 x_i 相互独立,而渐近独立定理允许 $\{x_i\}_{i=1}^{\infty}$ 存在"序列相关" (serial correlation),只要此相关关系在极限处消失即可。

大数定律要求每个 x_i 的分布相同,而渐近独立定理要求 $\{x_i\}_{i=1}^{\infty}$ 为严格平稳过程,故也是同分布的。

类似地,可将中心极限定理作相应的推广,即在一定条件下,中心极限定理也适用于渐近独立的平稳过程。

命题 如果 $\{x_i\}_{i=1}^{\infty}$ 为渐近独立的严格平稳过程,则对于任何连续函数 $f(\cdot)$, $\{y_i \equiv f(x_i)\}_{i=1}^{\infty}$ 也是渐近独立的严格平稳过程。

根据此命题,则渐近独立定理意味着,渐近独立平稳过程 $\{x_i\}_{i=1}^{\infty}$ 的任何"总体矩"(population moment) $\mathbf{E}[f(x_i)]$,都可以由其对应的"样本矩"(sample moment) $\frac{1}{n}\sum_{i=1}^{n}f(x_i)$ 来一致地估计。

例 对于渐近独立的平稳过程 $\{x_i\}_{i=1}^{\infty}$,样本方差 $s^2 = \frac{1}{n-1} \sum_{i=1}^{n} (x_i - \overline{x})^2$ 是总体方差 $Var(x) = E[x - E(x)]^2$ 的一致估计。

样 本 协 方 差 $s_{xy} = \frac{1}{n-1} \sum_{i=1}^{n} (x_i - \overline{x})(y_i - \overline{y})$ 为 总 体 协 方 差 Cov(x, y) = E[(x - E(x))(y - E(y))]的一致估计。

6.7 大样本 OLS 的假定

假定 6.1 线性假定

$$y_i = \beta_1 + \beta_2 x_{i2} + \dots + \beta_K x_{iK} + \varepsilon_i \quad (i = 1, \dots, n)$$
 (6.19)

假定 **6.2** (K+1)维随机过程 $\{y_i, x_{i1}, \dots, x_{iK}\}$ 为渐近独立的平稳过程(ergodic stationarity),故适用大数定律与中心极限定理。

例 如果样本为随机样本,则 $\{y_i, x_{i1}, ..., x_{iK}\}$ 独立同分布,故是渐近独立的平稳过程。

假定 6.3 前定解释变量(predetermined regressors)

所有解释变量均为"前定"(predetermined),也称"同期外生"(contemporaneously exogenous),即它们与同期(同方程)的扰动项正交,即 $\mathbf{E}(x_{ik}\varepsilon_i)=0$, $\forall i,k$ 。

由于 $E(x_{ik}\varepsilon_i)=0$,故 x_{ik} 与 ε_i 不相关,仿佛在 ε_i 产生之前, x_{ik} 已经确定,故名"前定解释变量"。

此假定比严格外生性假定更弱,因为后者要求扰动项与过去、 现在及未来的解释变量都不相关(对于时间序列数据而言),而前定 变量仅要求与同期的扰动项不相关。

假定 6.4 秩条件(rank condition)

数据矩阵**X**满列秩,即**X**中没有多余(可由其他变量线性表出)的解释变量,故不存在严格多重共线性。

大样本理论的假定 6.1 与 6.4 与小样本理论相同,而假定 6.2 与 6.3 则比小样本理论更为放松。

大样本 OLS 无须假设"严格外生性"与"正态随机扰动项", 具有更大的适用性。

6.8 OLS 的大样本性质

在假定 6.1-6.4 之下, OLS 估计量 $\hat{\beta}$ 具有以下良好的大样本性质。

(1) $\hat{\beta}$ 为一致估计量,即 $\lim_{r\to\infty}\hat{\beta} = \beta$ 。

以一元回归为例。考虑以下模型:

$$y_i = \alpha + \beta x_i + \varepsilon_i \quad (i = 1, \dots, n)$$
 (6.20)

 β 的 OLS 估计量为

$$\hat{\beta} = \frac{\sum_{i=1}^{n} (x_i - \overline{x})(y_i - \overline{y})}{\sum_{i=1}^{n} (x_i - \overline{x})^2}$$
 (6.21)

此模型的离差形式为(参见习题):

$$y_i - y = \beta(x_i - \overline{x}) + (\varepsilon_i - \overline{\varepsilon})$$
 (6.22)

$$\overline{y} = \frac{1}{n} \sum_{i=1}^{n} y_i, \quad \overline{x} = \frac{1}{n} \sum_{i=1}^{n} x_i, \quad \overline{m} \, \overline{\varepsilon} = \frac{1}{n} \sum_{i=1}^{n} \varepsilon_i \circ$$

将方程(6.22)代入(6.21)可得:

$$\hat{\beta} = \frac{\sum_{i=1}^{n} (x_{i} - \overline{x}) \left[\beta(x_{i} - \overline{x}) + (\varepsilon_{i} - \overline{\varepsilon}) \right]}{\sum_{i=1}^{n} (x_{i} - \overline{x})^{2}}$$

$$= \frac{\beta \sum_{i=1}^{n} (x_{i} - \overline{x})^{2} + \sum_{i=1}^{n} (x_{i} - \overline{x})(\varepsilon_{i} - \overline{\varepsilon})}{\sum_{i=1}^{n} (x_{i} - \overline{x})^{2}}$$

$$= \beta + \frac{\sum_{i=1}^{n} (x_{i} - \overline{x})(\varepsilon_{i} - \overline{\varepsilon})}{\sum_{i=1}^{n} (x_{i} - \overline{x})^{2}}$$

$$= \beta + \frac{\frac{1}{n-1} \sum_{i=1}^{n} (x_{i} - \overline{x})(\varepsilon_{i} - \overline{\varepsilon})}{\frac{1}{n-1} \sum_{i=1}^{n} (x_{i} - \overline{x})^{2}} \xrightarrow{p} \beta + \frac{\text{Cov}(x_{i}, \varepsilon_{i})}{\text{Var}(x_{i})} = \beta \quad (6.23)$$

其中,根据假定 6.3, $Cov(x_i, \varepsilon_i) = 0$ 。

前定解释变量,或扰动项与解释变量同期不相关,是保证 OLS 一致的最重要条件。

反之,如果
$$Cov(x_i, \varepsilon_i) \neq 0$$
,则 $plim_{n \to \infty} \hat{\beta} = \beta + \frac{Cov(x_i, \varepsilon_i)}{Var(x_i)} \neq \beta$ 。

进一步,如果
$$Cov(x_i, \varepsilon_i) > 0$$
,则 $\lim_{n \to \infty} \hat{\beta} > \beta$ 。

比如,考察教育投资的回报率, x_i 为教育年限,而 ε_i 为被遗漏的个人能力。 x_i 与 ε_i 正相关(能力高者通常上学更久),故 OLS 估计量将高估教育投资的回报率。

另一方面,如果
$$Cov(x_i, \varepsilon_i) < 0$$
,则 $\lim_{n \to \infty} \hat{\beta} < \beta$ 。

比如,考察上医院对健康的作用, x_i 为是否上医院,而 ε_i 为个人原来的健康状况(被遗漏)。 x_i 与 ε_i 负相关(通常只有健康不佳者才上医院),故 OLS 估计量将低估上医院对健康的正面作用(去医院者的健康往往不如未去医院者)。

通过图示考察 $Cov(x_i, \varepsilon_i) \neq 0$ 的后果,参见图 6.11。

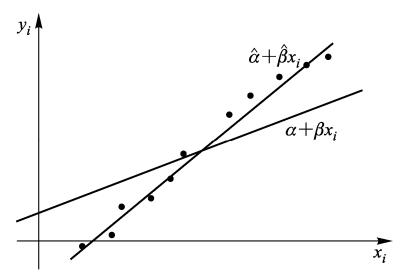


图 6.11 扰动项与解释变量相关导致不一致估计

真实(总体)回归线为 $\alpha + \beta x_i$,而样本回归线为 $\hat{\alpha} + \hat{\beta} x_i$ 。 假设Cov(x_i, ε_i) > 0。

由于 x_i 与 ε_i 正相关,故当 x_i 较小时, ε_i 也倾向于较小;而当 x_i 较大时, ε_i 也倾向于较大。

故样本回归线比真实回归线更为陡峭, $\hat{\beta}$ 将高估 β 。

反之,如果 $Cov(x_i,\varepsilon_i)<0$,则 $\hat{\beta}$ 将低估 β 。

增大样本容量 $(n \to \infty)$ 能否使偏差(bias)消失吗?

不能!即便使用人口普查的海量数据,偏差也依然存在!

在计量经济学中,如果解释变量与扰动项相关,即 $Cov(x_i, \varepsilon_i) \neq 0$,则称此解释变量为"内生解释变量"(endogenous regressor),简称"内生变量"。

反之,则为"外生变量"(exogenous variable)。

由于内生变量的存在,致使 OLS 回归出现偏差,统称为"内生性偏差"(endogeneity bias),或简称"内生性"。

在什么情况下可能出现内生性偏差?

如果存在遗漏变量、双向因果关系、或解释变量测量误差 (measurement errors),常会出现解释变量与扰动项同期相关的情形,导致OLS不一致。

(2) $\hat{\boldsymbol{\beta}}$ 服从渐近正态分布,即 $\sqrt{n}(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta}) \xrightarrow{d} N(\mathbf{0}, \operatorname{Avar}(\hat{\boldsymbol{\beta}}))$,其中 $\operatorname{Avar}(\hat{\boldsymbol{\beta}})$ 为 $\hat{\boldsymbol{\beta}}$ 的渐近协方差矩阵。

 $\hat{\pmb{\beta}}$ 之所以服从渐近正态,因为在一定条件下,中心极限定理适用于渐近独立的平稳过程。

(3) 由于大样本理论一般不假设球形扰动项,故渐近协方差矩阵 $Avar(\hat{\beta})$ 的表达式更为复杂。

根据第5章,OLS估计量 $\hat{\beta}$ 的协方差矩阵可写为:

$$\operatorname{Var}(\hat{\boldsymbol{\beta}} \mid \boldsymbol{X}) = (\boldsymbol{X}'\boldsymbol{X})^{-1} \boldsymbol{X}' \operatorname{Var}(\boldsymbol{\varepsilon} \mid \boldsymbol{X}) \boldsymbol{X} (\boldsymbol{X}'\boldsymbol{X})^{-1} \quad (6.24)$$

其中, $Var(\varepsilon|X)$ 为扰动项的协方差矩阵。

如果存在球形扰动项(同方差、无自相关),则 $Var(\boldsymbol{\varepsilon}|\boldsymbol{X}) = \sigma^2 \boldsymbol{I}_n$,上式简化为

$$\operatorname{Var}(\hat{\beta} \mid X) = (X'X)^{-1}X'(\sigma^2 I_n)X(X'X)^{-1} = \sigma^2(X'X)^{-1}$$
 (6.25)

对于横截面数据,经常存在异方差,但无自相关(比如,各截面单位之间相互独立)。

考虑存在条件异方差,但无自相关的情形。

扰动项的协方差矩阵可写为

$$\operatorname{Var}(\boldsymbol{\varepsilon} \mid \boldsymbol{X}) = \begin{pmatrix} \sigma_1^2 & 0 \\ & \ddots & \\ 0 & \sigma_n^2 \end{pmatrix}$$
 (6.26)

其中, $\sigma_1^2, ..., \sigma_n^2$ 不全相等。

如何估计上式的 $\left\{\sigma_1^2, \dots, \sigma_n^2\right\}$?

以 OLS 残差平方 $\{e_1^2,\dots,e_n^2\}$ 替代上式的 $\{\sigma_1^2,\dots,\sigma_n^2\}$,得到扰动项协方差矩阵的估计量:

$$\widehat{\operatorname{Var}(\boldsymbol{\varepsilon} \mid \boldsymbol{X})} = \frac{n}{n - K} \begin{pmatrix} e_1^2 & 0 \\ & \ddots & \\ 0 & e_n^2 \end{pmatrix}$$
 (6.27)

其中, $\frac{n}{n-K}$ 为自由度的调整(在大样本下无差别)。

将表达式(6.27)代入(6.24),可得如下方差估计量

$$\widehat{\operatorname{Var}(\hat{\boldsymbol{\beta}} \mid \boldsymbol{X})} = (\boldsymbol{X}'\boldsymbol{X})^{-1} \boldsymbol{X}' \widehat{\operatorname{Var}(\boldsymbol{\varepsilon} \mid \boldsymbol{X})} \boldsymbol{X} (\boldsymbol{X}'\boldsymbol{X})^{-1} \qquad (6.28)$$

考虑 $\sqrt{n}\hat{\boldsymbol{\beta}}$ 的方差估计量,即 $\hat{\boldsymbol{\beta}}$ 的渐近方差估计量:

$$\widehat{\operatorname{Avar}(\hat{\boldsymbol{\beta}} \mid \boldsymbol{X})} = n(\boldsymbol{X}'\boldsymbol{X})^{-1}\boldsymbol{X}'\widehat{\operatorname{Var}(\boldsymbol{\varepsilon} \mid \boldsymbol{X})}\boldsymbol{X}(\boldsymbol{X}'\boldsymbol{X})^{-1} \qquad (6.29)$$

上式为 $\hat{\beta}$ 渐近协方差矩阵的一致估计量,即

$$\widehat{\operatorname{Avar}(\hat{\boldsymbol{\beta}} \mid \boldsymbol{X})} \xrightarrow{p} \operatorname{Avar}(\hat{\boldsymbol{\beta}} \mid \boldsymbol{X}) \quad (6.30)$$

由于表达式(6.29)在推导过程中并未假设"条件同方差",故在"条件异方差"情况下也成立,称为"异方差稳健的标准误" (heteroskedasticity-consistent standard errors),简称"稳健标准误" (robust standard errors)。

在形式上,稳健标准误也是夹心估计量。

稳健标准误的思想最早由 Eicker(1967)与 Huber(1967)提出,并由 White(1980)严格证明,故也称 White's standard errors, Huber-White standard errors。

稳健标准误的表达式虽较复杂,但对于计算机,其计算成本可以忽略(无须人为记忆)。

通过使用迭代期望定律可以证明,在条件同方差的假定下,稳健标准误还原为普通(非稳健)标准误。

考虑同方差的极端情形,即 $e_1^2 = e_2^2 = \cdots = e_n^2$ (所有残差的绝对值都相等,但符号可以相反),则

$$\widehat{\operatorname{Var}(\boldsymbol{\varepsilon} \mid \boldsymbol{X})} = \frac{n}{n - K} \begin{pmatrix} e_1^2 & 0 \\ & \ddots \\ 0 & e_n^2 \end{pmatrix} = \frac{ne_i^2}{n - K} \boldsymbol{I}_n = \underbrace{\sum_{i=1}^n e_i^2}_{=s^2} \boldsymbol{I}_n = s^2 \boldsymbol{I}_n \quad (6.31)$$

稳健的协方差矩阵简化为同方差情况下的普通(非稳健)协方差 矩阵:

$$\widehat{\operatorname{Var}(\hat{\boldsymbol{\beta}} \mid \boldsymbol{X})} = (\boldsymbol{X}'\boldsymbol{X})^{-1} \boldsymbol{X}' \widehat{\operatorname{Var}(\boldsymbol{\varepsilon} \mid \boldsymbol{X})} \boldsymbol{X} (\boldsymbol{X}'\boldsymbol{X})^{-1}$$

$$= (\boldsymbol{X}'\boldsymbol{X})^{-1} \boldsymbol{X}' (s^2 \boldsymbol{I}_n) \boldsymbol{X} (\boldsymbol{X}'\boldsymbol{X})^{-1} = s^2 (\boldsymbol{X}'\boldsymbol{X})^{-1}$$
(6.32)

6.9 大样本统计推断

对于渐近独立的平稳过程,如果样本容量足够大,则 OLS 估计量 $\hat{\boldsymbol{\beta}}$ 的渐近正态分布是对其真实分布的较好近似,可使用其渐近分布进行大样本假设检验与区间估计。

大样本统计推断(large sample inference)的步骤与小样本 OLS 基本相同。

1. 检验单个系数: $H_0:\beta_k=c$

考虑检验 $H_0: \beta_k = c$, 其中c为已知常数。

根据大样本理论,OLS 估计量 $\hat{\boldsymbol{\beta}}$ 服从渐近正态分布,即 $\sqrt{n}(\hat{\boldsymbol{\beta}}-\boldsymbol{\beta})$ — d $\rightarrow N(\mathbf{0}, \text{Avar}(\hat{\boldsymbol{\beta}}))$,其中Avar $(\hat{\boldsymbol{\beta}})$ 为渐近协方差矩阵。

具体到 $\hat{\beta}$ 的第k个元素 $\hat{\beta}_k$,则有

$$\sqrt{n} (\hat{\beta}_k - \beta_k) \xrightarrow{d} N(0, \text{Avar}(\hat{\beta}_k))$$
 (6.33)

 $Avar(\hat{\beta}_k)$ 为 $\hat{\beta}_k$ 的渐近方差,即渐近方差矩阵 $Avar(\hat{\beta})$ 主对角线上的第k个元素。

在原假设 H_0 成立的情况下, $\beta_k = c$,故表达式(6.33)可写为

$$\sqrt{n} (\hat{\beta}_k - c) \xrightarrow{d} N(0, \operatorname{Avar}(\hat{\beta}_k))$$
 (6.34)

记 $\widehat{Avar}(\widehat{\beta}_k)$ 为渐近方差矩阵估计量 $\widehat{Avar}(\widehat{\beta})$ 主对角线上的第k个元素,则 $\widehat{Avar}(\widehat{\beta}_k)$ 是 $\widehat{Avar}(\widehat{\beta}_k)$ 的一致估计量。

定义t统计量为

$$t_{k} = \frac{\sqrt{n}(\hat{\beta}_{k} - c)}{\sqrt{\widehat{\text{Avar}}(\hat{\beta}_{k})}} = \frac{\hat{\beta}_{k} - c}{\sqrt{\frac{1}{n}\widehat{\text{Avar}}(\hat{\beta}_{k})}} = \frac{\hat{\beta}_{k} - c}{\text{SE}^{*}(b_{k})} \xrightarrow{d} N(0, 1)$$
 (6.35)

 $SE^*(\hat{\beta}_k) \equiv \sqrt{\frac{1}{n} \widehat{Avar(\hat{\beta}_k)}}$ 即为异方差稳健的标准误。

统计量 t_k 称为"稳健t比值"(robust t ratio),服从渐近标准正态分布,而不是t分布。

对于双边检验(即 $H_1: \beta_k \neq c$),则 $|t_k|$ 越大,越倾向于拒绝 H_0 。

比如,对于 5%的显著性水平,如果 $|t_k|$ 大于临界值 1.96,则可拒绝 H_0 。

也可以通过p值进行检验,方法与小样本理论相同。

2. 检验线性假设: $H_0: \mathbf{R}\boldsymbol{\beta} = \mathbf{r}$

考虑检验m个线性假设是否同时成立:

$$H_0: \mathbf{R} \underbrace{\mathbf{\beta}}_{m \times K} = \mathbf{r}$$

其中,r为m维列向量(m < K),R为 $m \times K$ 矩阵。

 $rank(\mathbf{R}) = m$,即 \mathbf{R} 满行秩,没有多余或自相矛盾的行或方程。

对于原假设 $H_0: R\beta = r$,根据沃尔德检验原理,可考察 $(R\hat{\beta} - r)$ 的大小,譬如其二次型 $(R\hat{\beta} - r)'(R\hat{\beta} - r)$ 。

在 H_0 成立的情况下,可证明统计量

$$W = n(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{r})'[\widehat{\mathbf{R}}\widehat{\mathrm{Avar}}(\hat{\boldsymbol{\beta}})\mathbf{R}']^{-1}(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{r}) \xrightarrow{d} \chi^{2}(m) \quad (6.36)$$

 $RAvar(\hat{\beta})R'$ 为($R\hat{\beta}-r$)的渐近方差矩阵(使用夹心估计量公式)。

如果统计量W大于 $\chi^2(m)$ 的临界值,则拒绝原假设。

虽然统计量W 服从 χ^2 分布,而非小样本的F分布,但 χ^2 分布与F分布在大样本情况下是等价的。

即使在大样本下使用稳健标准误进行假设检验,Stata 也依然汇报F统计量及其p值。

命题 假设统计量 $F \sim F(m,n)$ 分布,则当 $n \to \infty$ 时, $mF \xrightarrow{d} \chi^2(m)$ 。

证明: 因为 $F \sim F(m,n)$,故可写为 $F = \frac{\chi^2(m)/m}{\chi^2(n)/n}$,其中分子与分母相互独立。

根据 χ^2 分布的性质, χ^2 分布的期望等于自由度,而方差等于自由度的两倍; 即 $E[\chi^2(n)] = n$,且 $Var[\chi^2(n)] = 2n$ 。

分 母 的 期 望 为 $E[\chi^2(n)/n] = n/n = 1$, 而 方 差 为 $Var[\chi^2(n)/n] = 2n/n^2 = 2/n \to 0$ (当 $n \to \infty$ 时)。

分母依均方收敛于 1,故依概率收敛于 1(前者是后者的充分条件),即 $\chi^2(n)/n \longrightarrow 1$ 。

F 统计量的性质仅由分子 $\chi^2(m)/m$ 决定,故 $F \xrightarrow{d} \chi^2(m)/m$ 。

因此,在大样本下, $mF \xrightarrow{d} \chi^2(m)$ 。

6.10 大样本 OLS 的 Stata 实例

在 Stata 中,容易得到 OLS 估计的稳健标准误,其命令为

reg y x1 x2 x3, robust

其中,选择项"robust"表示稳健标准误。

以数据集 nerlove.dta 为例,取自 Nerlove(1963)对电力行业规模报酬的经典研究,包括 1955 年美国 145 家电力企业的横截面数据。

主要变量为tc (total cost,总成本),q (total output,总产量),pl (price of labor,小时工资率),pk (user cost of capital,资本的使用成本)与pf (price of fuel,燃料价格),以及相应的对数值 lntc,lnq,lnpl,lnpk,与lnpf。

假设企业i的生产函数为 Cobb-Douglas 函数:

$$Q_i = A_i L_i^{\alpha_1} K_i^{\alpha_2} F_i^{\alpha_3} \tag{6.37}$$

A, L, K, F分别为生产率、劳动力、资本与燃料。

记 $r = \alpha_1 + \alpha_2 + \alpha_3$ 为规模效应(degree of returns to scale)。

如果r=1,则规模报酬不变。

如果r > 1,则规模报酬递增。

如果r < 1,则规模报酬递减。

Nerlove (1963)要确定美国电力行业的规模经济。

假设企业追求成本最小化,则成本函数也为Cobb-Douglas 函数:

$$TC_{i} = \delta_{i} Q_{i}^{1/r} (P_{L})_{i}^{\alpha_{1}/r} (P_{K})_{i}^{\alpha_{2}/r} (P_{F})_{i}^{\alpha_{3}/r}$$
 (6.38)

 δ_i 是 $A_i, \alpha_1, \alpha_2, \alpha_3$ 的函数。取对数后可得,

$$\ln TC_{i} = \beta_{1} + \frac{1}{r} \ln Q_{i} + \frac{\alpha_{1}}{r} \ln P_{L,i} + \frac{\alpha_{2}}{r} \ln P_{K,i} + \frac{\alpha_{3}}{r} \ln P_{F,i} + \varepsilon_{i}$$
 (6.39)

首先,使用普通标准误进行 OLS 估计:

. use nerlove.dta,clear

. reg lntc lnq lnpl lnpk lnpf

						┷		
Source	SS	df	M	IS		Number of obs	=	145
						F(4, 140)	=	437.90
Model	269.524728	4	67.381	1819		Prob > F	=	0.0000
Residual	21.5420958	140	.15387	2113		R-squared	=	0.9260
						Adj R-squared	=	0.9239
Total	291.066823	144	2.0212	9738		Root MSE	=	.39227
							-	
lntc	Coef.	Std.	Err.	t	P> t	[95% Conf.	In	terval]
٦	E00012E	0154						
lnq	.7209135	.0174	337	41.35	0.000	.6864462	•	7553808
lnq lnpl	.7209135	.0174		41.35 1.52	0.000 0.131	.6864462 1367602		7553808 .048689
_			802				1	
lnpl	.4559645	.299	802 295	1.52	0.131	1367602	1	.048689

 $R^2 = 0.9260$, $\bar{R}^2 = 0.9239$,检验整个方程显著性的 F 统计量高达 437.9,其相应 p 值(Prob > F)为 0.0000,此回归方程高度显著。

但 lnpl 与 lnpk 这两个变量均不显著,其p 值(P>|t|)分别为 0.131 与 0.528。

变量 lnpk 的系数(Coef.)符号为负,与经济理论的预测相反。 Nerlove(1963)认为,这是由于"资本使用成本"数据不太可靠。

由于 lnq 的系数为1/r(即规模报酬的倒数), 故可估计规模报酬为

- . display 1/_b[lnq]
- 1.387129

其中, "_b[lnq]"表示"lnq"的OLS系数估计值。

由于 $\hat{r}=1.387129>1$,故认为可能存在规模报酬递增。

为检验规模报酬不变的原假设" $H_0: r=1$ ",输入命令

. test lnq=1

此命令检验的原假设为,变量 lnq 的系数等于 1。

```
(1) lnq = 1
F(1, 140) = 256.27
Prob > F = 0.0000
```

p值为0.0000,强烈拒绝原假设,认为存在规模报酬递增。

其次, 使用稳健标准误重新进行回归。

. reg lntc lnq lnpl lnpk lnpf,r

```
. reg lntc lnq lnpl lnpk lnpf,r
Linear regression
                                                        Number of obs =
                                                                            145
                                                        F(4,
                                                                140) = 177.19
                                                        Prob > F
                                                                      = 0.0000
                                                        R-squared
                                                                      = 0.9260
                                                        Root MSE
                                                                      = .39227
                             Robust
                                                P>|t|
        lntc
                    Coef.
                            Std. Err.
                                                           [95% Conf. Interval]
         lnq
                 .7209135
                            .0325376
                                        22.16
                                                 0.000
                                                            .656585
                                                                        .785242
                 .4559645
                             .260326
                                        1.75
                                                                       .9706429
        lnpl
                                                0.082
                                                          -.0587139
                -.2151476
                            .3233711
                                        -0.67
                                                0.507
                                                          -.8544698
                                                                       .4241745
        lnpk
        lnpf
                 .4258137
                            .0740741
                                       5.75
                                                0.000
                                                         .2793653
                                                                       .5722622
                -3.566513
                            1.718304
                                        -2.08
                                                0.040
                                                          -6.963693
                                                                      -.1693331
       _cons
```

使用选择项 "<u>r</u>obust" 所得到的 OLS 回归系数完全相同,只是所得到的稳健标准误(Robust Std. Err.)与普通标准误(Std. Err.)不同。

对于变量 lnq 的系数, 其稳健标准误(0.033)几乎是普通标准误(0.017)的两倍。

其他变量系数的稳健标准误反而比普通标准误有所下降。

如果认为存在异方差,则应使用稳健标准误。

在异方差的情况下,如果使用普通标准误,将低估变量 lnq 系数的真实标准误,导致不正确的统计推断。

在 Stata 中使用稳健标准误,即可进行大样本检验。

对单个变量系数显著性的检验,可使用上表中的稳健t统计量(服 从渐近正态分布)来进行。 也可直接看表中所列的p值 (P>|t|)。

对于一般的线性假设,可使用命令 test 来检验。

比如, 检验变量 lnq 的系数是否为 1:

. test lnq=1

```
(1) lnq = 1
F(1, 140) = 73.57
Prob > F = 0.0000
```

p值为 0.0000,故即使用稳健标准误,仍强烈拒绝"变量 lnq 的 系数为 1"的原假设。

6.11 大样本理论的蒙特卡罗模拟

考虑以下数据生成过程(DGP):

$$y = \alpha + \beta x + \varepsilon$$
, $x \sim \chi^2(1)$, $\varepsilon \sim \chi^2(10) - 10$ (6.40)

其中, $\alpha = 1$, $\beta = 2$, 解释变量x服从 $\chi^2(1)$ 分布;

扰动项 ε 服从经过位移后的 χ^2 (10)分布,以保证其期望为零(卡方分布的期望为其自由度);且 χ 与 ε 相互独立。

首先,考虑样本容量为 20 的情形,看 OLS 估计量 $\hat{\beta}$ 与真实值 $\beta = 2$ 的差距,以及 $\hat{\beta}$ 的分布能否收敛到正态分布。

抽取 10000 个样本容量为 20 的随机样本,进行回归,得到 10000

 $\uparrow \hat{\beta}$.

先用命令 program 定义一个叫"chi2data"的程序进行一次抽样;

然后,用命令 simulate 来重复此程序 10000 次:

. program chi2data,rclass (定义程序 chi2data,以 r()形式储存结果)

drop _all (删去内存中已有数据)

set obs 20 (确定随机抽样的样本容量为 20)

gen x = rchi2(1) (生成服从 χ^2 (1)分布的解释变量)

gen y = 1 + 2*x + rchi2(10)-10 (生成被解释变量)

reg y x (线性回归)
return scalar b=_b[x] (存储 $\hat{\beta}$ 的估计值)
end (程序 chi2data 结束)

- . set more off (指定 Stata 输出结果连续翻页)
- . simulate bhat=r(b),reps(10000) seed(10101)
 nodots:chi2data

选择项 "reps(10000)" 表示通过命令 simulate 将程序 "chi2data" 模拟 10000 次。

得到 10000 个 $\hat{\beta}$ 后,可计算其均值与标准差:

. sum bhat

Variable	Obs	Mean	Std. Dev.	Min	Max
bhat	10000	1.990334	.967356	-3.513781	8.522547

 $\hat{\beta}$ 的样本均值为 1.990, 接近真实值 2, 验证了 $\hat{\beta}$ 为 β 的无偏估计。

但标准(误)差为 0.967,接近于 1,故估计误差较大(因为样本容量仅为 20)。

通过直方图来看这 10000 个 $\hat{\beta}$ 的分布,参见图 6.12。

. hist bhat, normal

其中,选择项"normal"表示同时画相应的正态分布密度图。

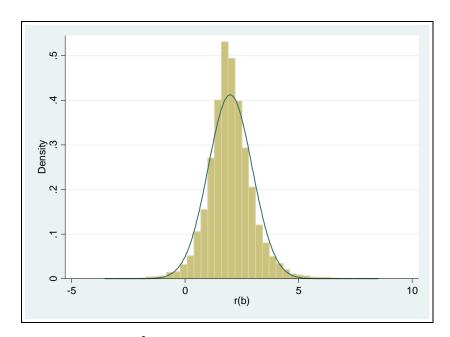


图 6.12 $\hat{\beta}$ 的分布(样本容量为 20)

当样本容量为 20 时, $\hat{\beta}$ 的真实分布与正态分布仍有一定差距。

其次,将样本容量增加至100,仍然抽取10000个随机样本。

在上述程序中将命令 "set obs 20" 改为 "set obs 100", 再次得到 $10000 \, \hat{\beta}$; 然后看 $\hat{\beta}$ 的统计特征。

. sum bhat

Variable	Obs	Mean	Std. Dev.	Min	Max
bhat	10000	1.99551	.3359594	.7352199	3.459108

 $\hat{\beta}$ 的样本均值为 1.996,更加接近真实值 2。

 $\hat{\beta}$ 的标准(误)差从 0.967 下降到 0.336。

再次画 $\hat{\beta}$ 的直方图,并与正态分布比较,参见图 6.13。

. hist bhat, normal

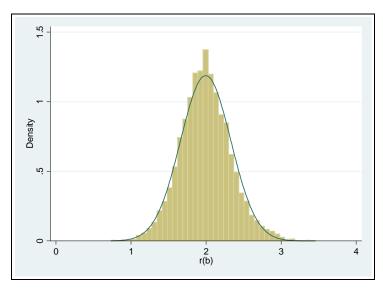


图 6.13 $\hat{\beta}$ 的分布(样本容量为 100)

当样本容量为 100 时, $\hat{\beta}$ 的真实分布与正态分布已较为接近。

将样本容量增加为 1000, 得到 10000 个 $\hat{\beta}$, 再看统计特征。

. sum bhat

Variable	0bs	Mean	Std. Dev.	Min	Max
bhat	10000	1.999062	.0997443	1.620384	2.429879

 $\hat{\beta}$ 的样本均值为 1.999,已十分接近于真实值 2;而 $\hat{\beta}$ 的标准(误) 差则下降为 0.0997。

这验证了 $\hat{\beta}$ 依均方收敛于 β ,故 $\lim_{n\to\infty}\hat{\beta}=\beta$,即 $\hat{\beta}$ 为一致估计量。

通过直方图看 $\hat{\beta}$ 的真实分布,参见图 6.14。

. hist bhat, normal

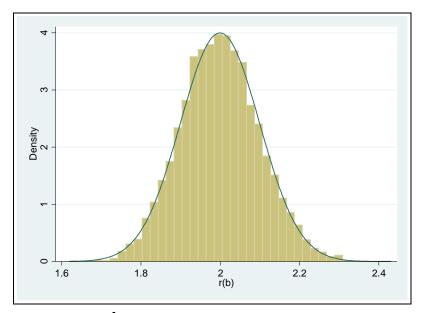


图 6.14 $\hat{\beta}$ 的分布(样本容量为 1000)

 $\hat{\beta}$ 的真实分布已非常接近于正态分布,可放心地使用大样本理论进行统计推断。

蒙特卡罗模拟验证了 OLS 估计量的一致性与渐近正态性。