第12章 面板数据

12.1 面板数据的特点

面板数据(panel data 或 longitudinal data),指在一段时间内跟踪同一组个体(individual)的数据。

它既有横截面维度(n位个体),又有时间维度(T个时期)。

一个T=3的面板数据结构如表 12.1。

表 12.1 面板数据的结构

	у	x_1	x_2	x_3
个体 1: t = 1				
↑ 体 1: t = 2				
个体 1: t=3				
个体 2: t=1				
个体 2: t = 2				
个体 2: $t=3$				
•••••				
个体 $n: t=1$				
个体 $n: t=2$				
个体 $n: t=3$				

通常的面板数据T较小,n较大,在使用大样本理论时让n趋于无穷大,称为"短面板"(short panel)。

如果T较大,n较小,则称为"长面板"(long panel)。

在面板模型中,如果解释变量包含被解释变量的滞后值,称为"动态面板"(dynamic panel);

反之,称为"静态面板"(static panel)。本书仅关注静态面板。

在面板数据中,如果每个时期在样本中的个体完全一样,则称为"平衡面板"(balanced panel);

反之,则称为"非平衡面板"(unbalanced panel)。主要关注平衡面板,但在本章第11节讨论非平衡面板。

面板数据的主要优点如下。

(1) 有助于解决遗漏变量问题:

遗漏变量常由不可观测的个体差异或"异质性"(heterogeneity)造成(比如个体能力)。

如果个体差异"不随时间而改变"(time invariant),则面板数据提供了解决遗漏变量问题的又一利器。

(2) 提供更多个体动态行为的信息:

面板数据有横截面与时间两个维度,可解决截面数据或时间序列不能解决的问题。

例 如何区分规模效应与技术进步对企业生产效率的影响。截面数据没有时间维度,无法观测到技术进步。单个企业的时间序列数据,也无法区分生产效率提高有多少由于规模扩大,有多少由于技术进步。

例 对于失业问题,截面数据告诉我们在某个时点上哪些人失业,时间序列告诉我们某个人就业与失业的历史,但均无法告诉我们是否失业的总是同一批人(低流转率),还是失业的人群总在变动(高流转率)。

如有面板数据,就可能解决上述问题。

(3) 样本容量较大:同时有截面与时间维度,面板数据的样本容量通常更大,可提高估计精度。

面板数据也会带来问题。

样本数据通常不满足 iid 假定,因为同一个体在不同期的扰动项一般存在自相关。

面板数据的收集成本通常较高,不易获得。

12.2 面板数据的估计策略

一个极端策略是,将面板看成截面数据进行混合回归(pooled regression),即要求样本中每位个体拥有完全相同的回归方程。

混合回归的缺点是,忽略个体不可观测的异质性(heterogeneity),而该异质性可能与解释变量相关,导致估计不一致。

另一极端策略是,为每位个体估计单独的回归方程。

分别回归的缺点是,忽略个体的共性,可能没有足够大的样本容量。

实践中常采用折衷的策略,即假定个体的回归方程拥有相同的斜率,但可有不同截距项,以捕捉异质性(参见图 12.1)。

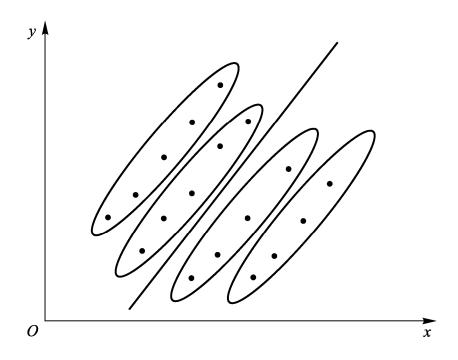


图 12.1 面板数据中不同个体的截距项可以不同

这种模型称为"个体效应模型"(individual-specific effects model):

$$y_{it} = \mathbf{x}'_{it}\boldsymbol{\beta} + \mathbf{z}'_{i}\boldsymbol{\delta} + u_{i} + \varepsilon_{it} \quad (i = 1, \dots, n; t = 1, \dots, T)$$
 (12.1)

 z_i 为不随时间而变(time invariant)的个体特征($z_{it} = z_i$, $\forall t$),比如性别;

 x_{it} 可以随个体及时间而变(time-varying)。

扰动项由 $(u_i + \varepsilon_{it})$ 两部分构成,称为"复合扰动项"(composite error term)。

不可观测的随机变量 u_i 是代表个体异质性的截距项,即"个体效应" (individual effects)。

 ε_{it} 为随个体与时间而改变的扰动项,称为"idiosyncratic error"。

一般假设 $\{\varepsilon_{it}\}$ 为独立同分布,且与 u_i 不相关。

如果 u_i 与某个解释变量相关,则进一步称为"固定效应模型" (Fixed Effects Model,简记 FE)。

此时 OLS 不一致。解决方法是转换模型,消去 u_i 获得一致估计。

如果 u_i 与所有解释变量(x_{it}, z_i)均不相关,则进一步称为"随机效应模型"(Random Effects Model,简记 RE)。

与横截面数据相比, 面板数据提供了更丰富的模型与估计方法。

12.3 混合回归

如果所有个体都拥有完全一样的回归方程,则 $u_1 = u_2 = \cdots = u_n$ 。

将相同的个体效应统一记为 α ,方程(12.1)可写为:

$$y_{it} = \alpha + x'_{it} \beta + z'_{i} \delta + \varepsilon_{it} (12.2)$$

其中, x_{ii} 不包括常数项。

把所有数据放在一起,像横截面数据那样进行 OLS 回归,故称"混合回归"(pooled regression)。

虽可假设不同个体的扰动项相互独立,但同一个体在不同时期 的扰动项之间往往自相关。 每位个体不同时期的所有观测值构成一个"聚类"(cluster)。

样本观测值可分为不同的聚类,在同一聚类里的观测值互相相关,不同聚类之间的观测值不相关,称为"聚类样本"(cluster sample)。

对于聚类样本,仍可进行 OLS 估计,但需使用"聚类稳健的标准误"(cluster-robust standard errors),形式上也是夹心估计量,表达式更为复杂。

对于样本容量为nT的平衡面板,共有n个聚类,而每个聚类中包含T期观测值。

使用聚类稳健标准误的前提是,聚类中的观测值数目T较小,而聚类数目n较大($n \rightarrow \infty$);

此时聚类稳健标准误是真实标准误的一致估计。

聚类稳健标准误更适用于时间维度T比截面维度n小的短面板。

在推导过程中未假定同方差,故聚类稳健标准误也是异方差稳 健的。

混合回归的基本假设是不存在个体效应,对此须进行统计检验,在下文介绍。

12.4 固定效应模型:组内估计量

考虑固定效应模型:

$$y_{it} = \mathbf{x}'_{it}\mathbf{\beta} + \mathbf{z}'_{i}\mathbf{\delta} + u_{i} + \varepsilon_{it}$$
 (12.3)

其中, u_i 与某解释变量相关,故 OLS 不一致。

解决方法:通过模型变换,消掉个体效应 u_i 。

给定个体 i, 方程两边对时间取平均:

$$\overline{y}_i = \overline{x}_i' \beta + z_i' \delta + u_i + \overline{\varepsilon}_i \qquad (12.4)$$

其中, $\overline{y}_i \equiv \frac{1}{T} \sum_{t=1}^{T} y_{it}$, \overline{x}_i 与 $\overline{\varepsilon}_i$ 的定义类似。

将原方程减去平均方程(12.4),可得离差形式:

$$y_{it} - \overline{y}_i = (\boldsymbol{x}_{it} - \overline{\boldsymbol{x}}_i)' \boldsymbol{\beta} + (\varepsilon_{it} - \overline{\varepsilon}_i)$$
 (12.5)

 \mathbf{z}_{i} 与 \mathbf{u}_{i} 被消去。定义 $\tilde{\mathbf{y}}_{it} \equiv \mathbf{y}_{it} - \overline{\mathbf{y}}_{i}$, $\tilde{\mathbf{x}}_{it} \equiv \mathbf{x}_{it} - \overline{\mathbf{x}}_{i}$, $\tilde{\varepsilon}_{it} \equiv \varepsilon_{it} - \overline{\varepsilon}_{i}$,则

$$\tilde{y}_{it} = \tilde{x}'_{it} \beta + \tilde{\varepsilon}_{it} \qquad (12.6)$$

只要新扰动项 $\tilde{\varepsilon}_{it}$ 与新解释变量 \tilde{x}_{it} 不相关,则 OLS 一致,称为"固定效应估计量" (Fixed Effects Estimator),记为 $\hat{\beta}_{FE}$ 。

 $\hat{\beta}_{\text{FE}}$ 主要使用每位个体的组内离差信息,也称"组内估计量" (within estimator)。

即使 u_i 与 x_{ii} 相关,只要使用组内估计量,即可得一致估计,这是面板数据的一大优势。

由于可能存在组内自相关,应使用以每位个体为聚类的聚类稳健标准误。

在离差变换过程中, $z_i'\delta$ 也消掉,无法估计 δ 。

 $\hat{oldsymbol{eta}}_{ ext{FE}}$ 无法估计不随时间而变的变量之影响,这是 FE 的一大缺点。

为保证($\varepsilon_{it} - \overline{\varepsilon}_i$)与($x_{it} - \overline{x}_i$)不相关,须假定个体 i 满足严格外生性 (比前定变量或同期外生的假定更强),即 $\mathbf{E}(\varepsilon_{it} | \mathbf{x}_{i1}, \dots, \mathbf{x}_{iT}) = 0$,因为 \overline{x}_i 中包含了所有($\mathbf{x}_{i1}, \dots, \mathbf{x}_{iT}$)的信息。

12.5 固定效应模型: LSDV 法

个体固定效应 u_i ,传统上视为个体i的待估参数,即个体i的截距项。

对于n位个体的n个不同截距项,可在方程中引入(n-1)个个体虚拟变量来体现:

$$y_{it} = \alpha + x'_{it} \beta + z'_{i} \delta + \sum_{i=2}^{n} \gamma_{i} D_{i} + \varepsilon_{it}$$
 (12.7)

其中,个体虚拟变量 $D_2=1$,如果为个体 2;否则, $D_2=0$ 。其他 (D_3, \dots, D_n) 的定义类似。

用 OLS 估计此方程, 称为"最小二乘虚拟变量法"(Least Square Dummy Variable, LSDV)。

LSDV 法的估计结果与组内估计量 FE 完全相同。

正如线性回归与离差形式的回归在某种意义上等价(参见习题):

$$y_i = \alpha + \beta x_i + \varepsilon_i \iff y_i - \overline{y} = \beta (x_i - \overline{x}) + (\varepsilon_i - \overline{\varepsilon})$$
 (12.8)

做完 LSDV 后,如发现某些个体的虚拟变量不显著而删去,则 LSDV 的结果就不会与 FE 相同。

LSDV 的好处是,可得到对个体异质性 u_i 的估计。

LSDV 法的缺点是,如果n很大,须在回归方程中引入很多虚拟变量,可能超出 Stata 所允许的变量个数。

12.6 固定效应模型:一阶差分法

对于固定效应模型,还可对原方程两边进行一阶差分,消去个体效应 u_i :

$$y_{it} - y_{i,t-1} = (\boldsymbol{x}_{it} - \boldsymbol{x}_{i,t-1})' \boldsymbol{\beta} + (\varepsilon_{it} - \varepsilon_{i,t-1})$$
 (12.9)

使用 OLS 即得到"一阶差分估计量"(First Differencing Estimator),记为 $\hat{\pmb{\beta}}_{FD}$ 。

只要扰动项的一阶差分 $(\varepsilon_{it} - \varepsilon_{i,t-1})$ 与解释变量的一阶差分 $(x_{it} - x_{i,t-1})$ 不相关,则 $\hat{\boldsymbol{\beta}}_{ED}$ 一致。

此一致性条件比保证 $\hat{oldsymbol{eta}}_{ ext{\tiny EE}}$ 一致的严格外生性假定更弱。

可以证明(参见习题),如果T=2,则 $\hat{\boldsymbol{\beta}}_{FD}=\hat{\boldsymbol{\beta}}_{FE}$ 。

对于T > 2,如果 $\{\varepsilon_{it}\}$ 为独立同分布,则 $\hat{\beta}_{FE}$ 比 $\hat{\beta}_{FD}$ 更有效率。

实践中,主要用 $\hat{oldsymbol{eta}}_{ ext{FE}}$,较少用 $\hat{oldsymbol{eta}}_{ ext{FD}}$ 。

12.7 时间固定效应

个体固定效应模型解决了不随时间而变(time invariant)但随个体而异的遗漏变量问题。

还可能存在不随个体而变(individual invariant),但随时间而变 (time varying)的遗漏变量问题。

比如,企业经营的宏观经济环境。

在个体固定效应模型中加入时间固定效应(礼):

$$y_{it} = \mathbf{x}'_{it}\mathbf{\beta} + \mathbf{z}'_{i}\mathbf{\delta} + \lambda_{t} + u_{i} + \varepsilon_{it}$$
 (12.10)

其中, 4,随时间而变, 但不随个体而变。

可视 λ_t 为第t期特有的截距项,并解释为"第t期"对y的效应; 故称 $\{\lambda_1, ..., \lambda_T\}$ 为"时间固定效应"(time fixed effects)。

使用 LSDV 法,对每个时期定义一个虚拟变量,把(T-1)个时间虚拟变量包括在回归方程中:

$$y_{it} = \alpha + \mathbf{x}'_{it}\boldsymbol{\beta} + \mathbf{z}'_{i}\boldsymbol{\delta} + \sum_{t=2}^{T} \gamma_{t} D_{t} + u_{i} + \varepsilon_{it}$$
 (12.11)

时间虚拟变量 $D_2=1$,如果t=2;否则, $D_2=0$;以此类推。

方程(12.11)既考虑了个体固定效应,又考虑了时间固定效应,称为"双向固定效应"(Two-way FE)。

可通过检验这些时间虚拟变量的联合显著性来判断是否应使用双向固定效应模型。

如果仅考虑个体固定效应,称为"单向固定效应"(One-way FE)。

有时为节省参数(比如,时间维度T较大),可引入时间趋势项,以替代上述(T-1)个时间虚拟变量:

$$y_{it} = \mathbf{x}'_{it}\boldsymbol{\beta} + \mathbf{z}'_{i}\boldsymbol{\delta} + \gamma t + u_{i} + \varepsilon_{it}$$
 (12.12)

上式隐含假定,每个时期的时间效应相等,即每期均增加γ。

如果此假定不太可能成立, 应在方程中加入时间虚拟变量。

12.8 随机效应模型

考虑随机效应模型:

$$y_{it} = \mathbf{x}'_{it}\boldsymbol{\beta} + \mathbf{z}'_{i}\boldsymbol{\delta} + u_{i} + \varepsilon_{it} \qquad (12.13)$$

其中,个体效应 u_i 与解释变量均不相关,故 OLS 一致。

由于扰动项由 $(u_i + \varepsilon_{it})$ 组成,不是球型扰动项,故 OLS 不是最有效率的。

假设不同个体之间的扰动项互不相关。

由于ui的存在,同一个体不同时期的扰动项之间仍存在自相关。

对于 $t \neq s$,可证明

$$Cov(u_i + \varepsilon_{it}, u_i + \varepsilon_{is}) = Cov(u_i, u_i) + \underbrace{Cov(u_i, \varepsilon_{is})}_{=0} + \underbrace{Cov(\varepsilon_{it}, u_i)}_{=0} + \underbrace{Cov(\varepsilon_{it}, \varepsilon_{is})}_{0}$$

$$= Var(u_i) \equiv \sigma_u^2 \neq 0$$
(12.14)

其中, $\sigma_u^2 \equiv \text{Var}(u_i)$ 为个体效应 u_i 的方差。

如果t = s,则

$$Var(u_i + \varepsilon_{it}) = \sigma_u^2 + \sigma_{\varepsilon}^2 \qquad (12.15)$$

其中, $\sigma_{\varepsilon}^2 \equiv \text{Var}(\varepsilon_{it})$ 为 ε_{it} 的方差(不随i, t变化)。

当 $t \neq s$ 时,个体i扰动项的自相关系数为

$$\rho = \operatorname{Corr}(u_i + \varepsilon_{it}, \ u_i + \varepsilon_{is}) = \frac{\operatorname{Cov}(u_i + \varepsilon_{it}, u_i + \varepsilon_{is})}{\operatorname{Var}(u_i + \varepsilon_{it})} = \frac{\sigma_u^2}{\sigma_u^2 + \sigma_\varepsilon^2}$$
(12.16)

自相关系数 ρ 越大,则复合扰动项 $(u_i + \varepsilon_{it})$ 中个体效应的部分 (u_i) 越重要。Stata 记 ρ 为 "rho"。

由于扰动项 $(u_i + \varepsilon_{it})$ 存在组内自相关,故 OLS 不是最有效率的。

使用 GLS 转换原模型,使变换后扰动项无自相关。

定义

$$\theta = 1 - \frac{\sigma_{\varepsilon}}{(T\sigma_{u}^{2} + \sigma_{\varepsilon}^{2})^{1/2}}$$
 (12.17)

其中,T为面板数据的时间维度。

显然, $0 \le \theta \le 1$ 。

给定个体i,将方程(12.13)两边对时间进行平均,然后同乘 θ :

$$\theta \overline{y}_i = \theta \overline{x}_i' \beta + \theta z_i' \delta + \theta u_i + \theta \overline{\varepsilon}_i \qquad (12.18)$$

将原方程(12.13)减去方程(12.18)可得"广义离差"(quasi-demeaned)模型:

$$y_{it} - \theta \overline{y}_i = (\mathbf{x}_{it} - \theta \overline{\mathbf{x}}_i)' \boldsymbol{\beta} + (1 - \theta) \mathbf{z}_i' \boldsymbol{\delta} + \underbrace{\left[(1 - \theta) u_i + (\varepsilon_{it} - \theta \overline{\varepsilon}_i) \right]}_{\text{挑劾项}}$$
(12.19)

由于 $0 \le \theta \le 1$,故 $(y_{ii} - \theta \overline{y}_i)$ 只是减去 \overline{y}_i 的一部分,故名"广义离差"。

广义离差方程的扰动项[$(1-\theta)u_i + (\varepsilon_{it} - \theta\overline{\varepsilon}_i)$]不再有自相关,对此方程进行 OLS 估计,即为 GLS 估计量。

但 θ 通常未知,须先估计 $\hat{\theta}$,再进行 FGLS 估计。

可用下式来估计 $\hat{\theta}$:

$$\hat{\theta} = 1 - \frac{\hat{\sigma}_{\varepsilon}}{(T\hat{\sigma}_{u}^{2} + \hat{\sigma}_{\varepsilon}^{2})^{1/2}} \qquad (12.20)$$

其中, $\hat{\sigma}_u$ 与 $\hat{\sigma}_{\varepsilon}$ 分别为 σ_u 与 σ_{ε} 的样本估计值。

Stata 分别记 $\hat{\sigma}_u$ 、 $\hat{\sigma}_{\varepsilon}$ 与 $\hat{\theta}$ 为"sigma_u"、"sigma_e"与"theta"。

对于随机效应模型,由于 OLS 一致,且其扰动项为($u_i + \varepsilon_{it}$),故可用 OLS 的残差估计($\sigma_u^2 + \sigma_{\varepsilon}^2$)。

另一方面,FE 也一致,且其扰动项为(ε_{it} $-\overline{\varepsilon}_{i}$),故可用 FE 的残差估计 σ_{ε}^{2} 。

由此得到 $\hat{\theta}$,再用 FGLS 估计原模型,可得"随机效应估计量" (Random Effects Estimator),记为 $\hat{\beta}_{RE}$ 。

如假设扰动项服从正态分布,可进行最大似然估计(MLE)。

12.9 组间估计量

对于随机效应模型,还可使用"组间估计量"。

如每位个体的时间序列数据较不准确或噪音较大,可对每位个体取时间平均值,然后用平均值作横截面回归:

$$\overline{y}_i = \overline{x}_i' \beta + z_i' \delta + u_i + \overline{\varepsilon}_i \quad (i = 1, \dots, n)$$
 (12.21)

对上式用 OLS, 即为"组间估计量"(Between Estimator), 记 $\hat{oldsymbol{eta}}_{\mathrm{BE}}$ 。

由于 $\{\bar{x}_i, \bar{z}_i\}$ 包含 $\{x_{it}, z_i\}$ 的信息,如 u_i 与 $\{x_{it}, z_i\}$ 相关,则 $\hat{\boldsymbol{\beta}}_{BE}$ 不一致。

故不能在固定效应模型下使用组间估计法。

即使在随机效应模型下,由于面板数据被压缩为截面数据,损失较多信息量,组间估计法也不常用。

12.10 拟合优度的度量

对于面板模型,如使用混合回归,可直接用混合回归的 R^2 衡量拟合优度。

如使用固定效应或随机效应,拟合优度的度量略复杂。

对于有常数项的线性回归模型,拟合优度 \mathbb{R}^2 等于被解释变量 \mathbb{R}^2 与预测值 $\hat{\mathbb{R}}$ 之间相关系数的平方,即 $\mathbb{R}^2 = [\operatorname{corr}(\mathbb{R}^2)]^2$ 。

给定估计量($\hat{\boldsymbol{\beta}}$, $\hat{\boldsymbol{\delta}}$), Stata 提供了以下三种 R^2 。

- (1) 对应于原模型(12.1),称[Corr(y_{it} , $x'_{it}\hat{\boldsymbol{\beta}} + z'_{i}\hat{\boldsymbol{\delta}}$)]²为"整体 R^2 " (R^2 overall),衡量估计量($\hat{\boldsymbol{\beta}}$, $\hat{\boldsymbol{\delta}}$)对原模型的拟合优度。
- (2) 对应于组内模型(12.6),称[$Corr(\tilde{y}_{it}, \tilde{x}'_{it}\hat{\boldsymbol{\beta}})$]²为"组内 R^2 " (R^2 within),衡量估计量($\hat{\boldsymbol{\beta}}, \hat{\boldsymbol{\delta}}$)对组内模型的拟合优度。
- (3) 对应于组间模型(12.21),称[$Corr(\bar{y}_i, \bar{x}_i'\hat{\boldsymbol{\beta}} + z_i'\hat{\boldsymbol{\delta}})$]²为"组间 R^2 " (R^2 between),衡量估计量($\hat{\boldsymbol{\beta}}, \hat{\boldsymbol{\delta}}$)对组间模型的拟合优度。

无论固定效应、随机效应还是组间回归,都可计算这三种 R^2 。

对于固定效应模型,建议使用组内 R^2 ;

对于组间回归模型,建议使用组间 R^2 。

对于随机效应模型,这三种 R^2 都只是相应的相关系数平方而已(并非随机效应模型广义离差回归的 R^2)。

12.11 非平衡面板

在面板数据中,如每个时期在样本中的个体完全一样,称为"平衡面板数据" (balanced panel)。

但有时某些个体的数据可能缺失(比如,个体死亡、企业倒闭或

被兼并、个体不再参与调查),或者新个体在后来才加入到调查中来。

如每个时期观测到的个体不完全相同,称为"非平衡面板" (unbalanced panel)或"不完全面板" (incomplete panel)。

非平衡面板数据不影响计算离差形式的组内估计量(within estimator),固定效应模型的估计可照样进行。

对于随机效应模型, 非平衡面板数据也无实质影响。

假设个体i的时间维度为 T_i ,只要在做广义离差变换时,为每位个体定义

$$\hat{\theta}_i = 1 - \frac{\hat{\sigma}_{\varepsilon}}{(T_i \hat{\sigma}_u^2 + \hat{\sigma}_{\varepsilon}^2)^{1/2}}$$
 (12.22)

即可照常进行 FGLS 估计。

非平衡面板可能出现的最大问题是,那些原来在样本中但后来 丢掉的个体,如果"丢掉"的原因内生(与扰动项相关),则会导致 样本不具有代表性(不再是随机样本),导致估计量不一致。

比如,低收入人群更易从面板数据中丢掉。

如果从非平衡面板数据中提取一个平衡的面板数据子集,则必然会损失样本容量,降低估计效率。

如人为"丢掉"个体并非完全随机,同样会破坏样本的随机性。

12.12 究竟该用固定效应还是随机效应模型

处理面板数据, 究竟使用固定效应还是随机效应是根本问题。

检验原假设" $H_0: u_i 与 x_{it}, z_i$ 不相关"(随机效应为正确模型)。

如果 H_0 成立,则 FE 与 RE 都一致,但 RE 比 FE 更有效率。

如果 H_0 不成立,则 FE 一致,而 RE 不一致。

如果 H_0 成立,则 FE 与 RE 估计量将共同收敛于真实的参数值, 二者的差距将在大样本下消失,故($\hat{\boldsymbol{\beta}}_{\text{FE}} - \hat{\boldsymbol{\beta}}_{\text{RE}}$)— $\stackrel{p}{\longrightarrow} \mathbf{0}$ 。

反之,如果二者的差距过大,则倾向于拒绝原假设。

以二次型度量此距离,豪斯曼检验(Hausman, 1978)的统计量为

$$(\hat{\boldsymbol{\beta}}_{FE} - \hat{\boldsymbol{\beta}}_{RE})' \left[\overline{\operatorname{Var}(\hat{\boldsymbol{\beta}}_{FE} - \hat{\boldsymbol{\beta}}_{RE})} \right]^{-1} (\hat{\boldsymbol{\beta}}_{FE} - \hat{\boldsymbol{\beta}}_{RE}) \xrightarrow{d} \chi^{2}(K) \quad (12.23)$$

其中,K为 $\hat{\beta}_{EE}$ 的维度,即 x_{it} 中随时间而变的解释变量个数。

如果该统计量大于临界值,则拒绝 H_0 。

此检验的缺点是,为计算 $Var(\hat{\boldsymbol{\beta}}_{FE} - \hat{\boldsymbol{\beta}}_{RE})$,假设在 H_0 成立情况下, $\hat{\boldsymbol{\beta}}_{RE}$ 是最有效率的(fully efficient)。

但如果扰动项存在异方差,则 $\hat{oldsymbol{eta}}_{RE}$ 并非最有效率。

传统的豪斯曼检验不适用于异方差的情形,须使用异方差稳健的豪斯曼检验(参见下文)。

12.13 面板模型的 Stata 命令及实例

1. 面板数据的设定

设定面板数据的 Stata 命令为

xtset panelvar timevar

命令"xtset"告诉Stata 你的数据为面板数据。

面板(个体)变量 "panelvar" 的取值须为整数且不重复,相当于将样本中每位个体进行编号。

"timevar"为时间变量。

假如 "panelvar" 本来是字符串(比如,国家名字 country),可用以下命令转换为数字型变量:

encode country, gen(cntry)

选择项"gen(cntry)"表示将新生成的数字型变量记为 cntry。 这样,变量 cntry 就以"1,2,3,…"来指代不同的国家。

显示面板数据统计特性的 Stata 命令:

xtdes (显示面板数据的结构,是否为平衡面板)

xtsum (显示组内、组间与整体的统计指标)

xtline varname (对每位个体分别显示该变量的时间序列图; 如希望将所有个体的时间序列图叠放在一起, 可加上选择项overlay)

以数据集 lin_1992.dta 为例,取自 Lin(1992)对家庭联产承包责任制(household responsibility system)与中国农业增长的经典研究。

该省际面板包含中国 28 个省 1970—1987 年有关种植业的数据。

被解释变量为"种植业产值对数"(ltvfo, 1980年不变价格)。

解释变量包括:耕地面积对数(ltlan,千亩),种植业劳动力(ltwlab),机械动力与畜力对数(ltpow,千马力),化肥使用量对数(ltfer,千吨),截止年底采用家庭联产承包制的生产队比重(hrs),

农村消费者价格与农村工业投入品价格之比的一阶滞后(mipric1, 1950年=100),超额收购价格与农村工业投入品价格之比(giprice, 1950年=100),复种指数(mci,播种面积除以耕地面积),非粮食作物占播种面积比重(ngca),时间趋势(t),province(省),year(年)。

为解决异方差问题, Lin (1992)将种植业产量、耕地面积、种植业劳动力、机械动力与畜力、化肥使用量这些传统的投入与产出变量都除以每省的生产队数目(team)。

两个价格变量 mipric1 与 giprice 为全国性指标,各省都一样, 只随时间变化。

首先,设定 province 与 year 为面板(个体)变量及时间变量:

- . use lin_1992.dta,clear
- . xtset province year

panel variable: province (strongly balanced)

time variable: year, 70 to 87

delta: 1 unit

这是一个平衡的面板数据(strongly balanced)。

其次,显示数据集的结构:

. xtdes

province:	1, 2,	, 28				n =		28		
year:	70, 71, .	70, 71,, 87						18		
	Delta(yea:	r) = 1 ur	nit							
	Span(year									
(province*year uniquely identifies each observation)										
Distributi	on of T_i:	min	5%	25%	50%	75%	95%	max		
		18	18	18	18	18	18	18		
Freq.	Percent	Cum.	Patter	n						
										
28	100.00	100.00	111111	111111111	1111					
										
28	100.00		XXXXX	XXXXXXXX	XXXX					

上表显示, n=28, 而T=18。n大而T小, 故是短面板。

显示数据集中以上变量的统计特征:

.xtsum ltvfo ltlan ltwlab ltpow ltfer hrs mipricl giprice mci ngca

Variable		Mean	Std. Dev.	Min	Max	Obs	serv	ations
ltvfo	overall	7.647758	.5331999	5.51	9.33	N	_	504
	between		.4611992	6.982222	8.977222	n	=	28
	within		.2806888	5.61498	8.471647	Т	=	18
ltlan	overall	5.837877	.8084866	4.57	7.76	N	=	504
	between		.8143036	4.617222	7.697778	n	=	28
	within		.1138892	4.758988	6.163988	Т	=	18
ltwlab	overall	3.19752	.4193496	.98	3.86	N	=	504
	between		.3195715	2.303889	3.646111	n	=	28
	within		.2778123	1.618631	4.053631	Т	=	18
ltpow	overall	2.692778	.9463811	. 2	5.04	N	=	504
	between		.7702036	1.475	4.180556	n	=	28
	within		.5678668	.31	3.909444	Т	=	18
ltfer	overall	2.15119	.7903761	23	3.98	N	=	504
	between		.5624935	1.081111	3.649444	n	=	28
	within		.564791	.4173016	3.510079	Т	=	18
hrs	overall	.3497479	.4526283	0	1	N	=	476
Ì	between		.0453814	.2123529	.4094118	n	=	28
	within		.4504245	0596639	1.053866	Т	=	17
mipric1	overall	2.248889	.2431379	1.76	2.73	N	=	504
Ì	between		0	2.248889	2.248889	n	=	28
	within		.2431379	1.76	2.73	Т	=	18
giprice	overall	2.858889	.4537578	2.39	3.56	N	=	504
	between		0	2.858889	2.858889	n	=	28
	within		.4537578	2.39	3.56	Т	=	18
mci	overall	1.538452	.4931854	.85	2.55	N	=	504
	between		.4972044	.8666667	2.487222	n	=	28
	within		.0661412	1.323452	1.880119	Т	=	18
ngca	overall	.199623	.076145	.06	.91	N	=	504
1	between		.0631671	.1144444	.3466667	n	=	28
	within		.0440777	.1151786	.8951786	Т	=	18

除 hrs 外,所有变量的观测样本均为28×18 = 504。

关键变量 hrs 的样本容量仅为 $28\times17=476$,因为缺失 1980 年的 hrs 观测数据。

看被解释变量 ltvfo 在 28 个省的时间趋势图,如图 12.2。

. xtline ltvfo

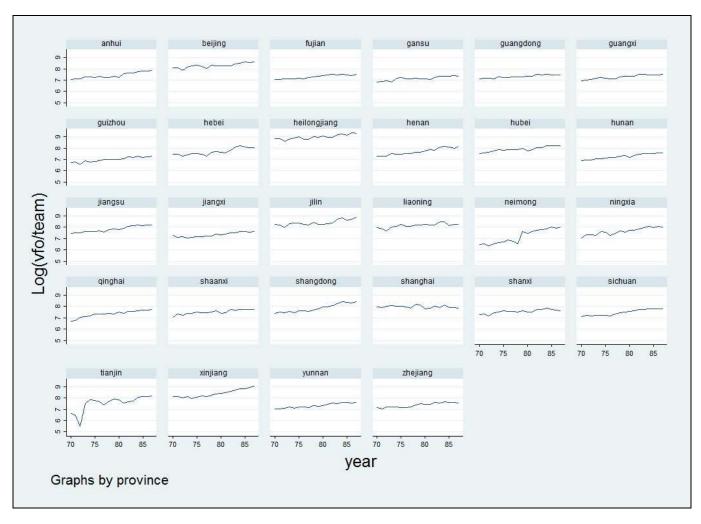


图 12.2 28 省种植业产值的时间趋势图

不同省的种植业产值均随时间而增长,但变化趋势与时机不尽相同。

种植业产值的省际差异有助于估计决定种植业产值的因素。

2. 混合回归

作为参照系,首先进行混合回归。Stata 命令的基本格式为

reg y x1 x2 x3, vce(cluster id)

其中,"id"指用来确定每位个体的变量。

选择项 "vce(cluster id)"表示以变量 id 作为聚类变量来计算聚类稳健的标准误。

. reg ltvfo ltlan ltwlab ltpow ltfer hrs mipricl giprice mci ngca, vce(cluster province)

选择项"vce(cluster province)"表示,使用以"province"为聚类变量的聚类稳健标准误。

将此结果储存,并记为"OLS"。

. estimates store OLS

ression				Number of obs	= 476
				F(9, 27)	= 81.39
				Prob > F	= 0.0000
				R-squared	= 0.8685
				Root MSE	= .19689
	(Std.	Err. adjus	sted for	28 clusters in	province)
	Robust				
fo C	oef. Std. Er		P> t	[95% Conf.	Interval]
an .69	3795 .11502	4 6.03	0.000	.4577853	.9298048
ab .265	0224 .056629	4 4.68	0.000	.1488285	.3812164
ow029	1884 .067038	5 -0.44	0.667	1667401	.1083633
er .311	0617 .053131	8 5.85	0.000	.2020443	.4200792
rs .228	6926 .048945	8 4.67	0.000	.1282642	.329121
c1 .012	2048 .054779	9 0.22	0.825	1001943	.1246039
ce053	8892 .027446	8 -1.96	0.060	1102054	.002427
ci .694	9202 .168969	2 4.11	0.000	.3482241	1.041616
1 205	3056 .522263	9 0.58	0.564	7662914	1.376903
ca .305	.52220				

关键变量 hrs 在 1%水平上显著为正。

如使用普通标准误,则可输入命令:

. reg ltvfo ltlan ltwlab ltpow ltfer hrs mipricl giprice mci ngca

	Number of obs		MS	df	SS	Source
	F(9, 466)					
= 0.0000	Prob > F		2617737		119.355964	Model
= 0.8685	R-squared		3766613	466 .038	18.0652415	Residual
= 0.8660	Adj R-squared					
= .19689	Root MSE		2893078	475 .2	137.421205	Total
Interval]	[95% Conf.	P> t	t	Std. Err.	Coef.	ltvfo
.7662892	.6213008	0.000	18.81	.0368914	.693795	ltlan
.3118708	.2181741	0.000	11.12	.0238406	.2650224	ltwlab
.0360305	0944073	0.380	-0.88	.0331891	0291884	ltpow
.3516324	.2704911	0.000	15.07	.0206459	.3110617	ltfer
.289044	.1683412	0.000	7.45	.0307121	.2286926	hrs
.1171125	0927028	0.819	0.23	.0533863	.0122048	mipric1
0004395	1073389	0.048	-1.98	.0271999	0538892	giprice
.7975784	.592262	0.000	13.30	.0522416	.6949202	mci
	0784195	0.119	1.56	.1952732	.3053056	ngca
.6890306			3.81	.2832576	1.080587	cons

对比聚类稳健标准误与普通标准误可知,前者大于后者。

由于同一省不同年份之间的扰动项一般存在自相关,而普通标准误假设扰动项为独立同分布,故普通标准误的估计不准确。

3. 固定效应

由于每个省的"省情"不同,可能存在不随时间而变的遗漏变量,考虑使用固定效应模型(FE)。

固定效应模型(组内估计量)的 Stata 命令格式为 xtreg y x1 x2 x3,fe r

选择项 "fe"表示 "fixed effects" (固定效应估计量),默认为 "re"表示 "random effects" (随机效应估计量)。

选择项"r"表示使用聚类稳健标准误;如使用选择项"vce(cluster id)"也能达到相同效果。

LSDV 法的 Stata 命令为 reg y x1 x2 x3 i.id, vce(cluster id)

"id"表示用来确定个体的变量,"i.id"则表示根据变量 "id"而生成的虚拟变量。

选择项 "vce(cluster id)"表示使用聚类稳健的标准误。

首先使用组内估计量,并记其估计结果为 "FE_robust":

- . xtreg ltvfo ltlan ltwlab ltpow ltfer hrs mipric1 giprice mci ngca,fe r
 - . estimates store RE_robust

ixed-effects	(within) reg	ression		Number	of obs =	476
roup variable	e: province			Number	of groups =	: 28
-sq: within	= 0.8746			Obs per	group: min =	: 17
between	n = 0.6483				avg =	17.0
overal	1 = 0.6993				max =	: 17
				F(9,27)	=	274.25
orr(u_i, Xb)	= -0.3877			Prob >	F =	0.0000
		Robust			8 clusters in	
ltvfo	Coef.	Std. Err.	t	P> t	[95% Conf.	Interval]
ltlan	.6370234	.1681335	3.79	0.001	.2920421	.9820048
ltwlab	.1387786	.0624585	2.22	0.035	.0106242	.2669329
ltpow	.0577152	.0755568	0.76	0.452	0973146	.2127451
ltfer	.1826281	.043592	4.19	0.000	.0931846	.2720716
hrs	.2134022	.0391104	5.46	0.000	.1331542	.2936501
mipric1	.0543577	.0590331	0.92	0.365	0667682	.1754837
giprice	0151451	.0245968	-0.62	0.543	0656135	.0353233
mci	.1943697	.0770515	2.52	0.018	.0362731	.3524663
шст	7560001	.3821261	1.98	0.058	0278549	1.540261
ngca	.7562031			0.011	.583124	4.092667
	2.337895	.8552224	2.73	0.011		
ngca	1	.8552224	2.73	0.011		
ngca _cons	2.337895	.8552224	2.73			

输出结果包括常数项($_{cons}$),是所有个体效应 $_{u_i}$ 的平均值。

最后一行显示,"rho=0.89",故复合扰动项 $(u_i + \varepsilon_{it})$ 的方差主要来自个体效应 u_i 的变动。

究竟应使用混合回归还是个体固定效应模型?

在使用命令 "xtreg,fe"时,如不加选择项 "r" (将估计结果记为 "FE"),则输出结果还包含一个F 检验,其原假设为 " H_0 : 所有 $u_i = 0$ ",即可以接受混合回归:

- . xtreg ltvfo ltlan ltwlab ltpow ltfer hrs mipric1 giprice mci ngca,fe
 - . estimates store FE

Fixed-effects	(within) reg	ression		Number	of obs =	476		
Group variable	e: province	ce Number of groups = 28						
R-sq: within	= 0.8746			Obs per	group: min =	17		
between	n = 0.6483				avg =	17.0		
overal	1 = 0.6993				max =	17		
				F(9,439)) =	340.20		
corr(u_i, Xb)	= -0.3877			Prob >	F =	0.0000		
ltvfo	Coef.	Std. Err.	t	P> t	[95% Conf.	Interval]		
ltlan	.6370234	.0673191	9.46	0.000	.5047156	.7693312		
ltwlab	.1387786	.0261554	5.31	0.000	.0873732	.190184		
ltpow	.0577152	.0332508	1.74	0.083	0076352	.1230657		
ltfer	.1826281	.0219921	8.30	0.000	.1394053	.225851		
hrs	.2134022	.0223886	9.53	0.000	.1694	.2574043		
mipric1	.0543577	.0421659	1.29	0.198	0285145	.1372299		
giprice	0151451	.0187457	-0.81	0.420	0519876	.0216975		
mci	.1943697	.0876884	2.22	0.027	.0220285	.366711		
ngca	.7562031	.2168141	3.49	0.001	.3300804	1.182326		
_cons	2.337895	.385253	6.07	0.000	1.580726	3.095065		
sigma_u	.30549743							
sigma_e	.10589274							
rho	.89273901	(fraction	of variar	nce due t	o u_i)			
test that a	ll u_i=0:	F(27, 439)	= 43.4	 1 1	Prob >	F = 0.0000		

对于原假设"所有 $u_i = 0$ ",最后一行F检验的p值为 0.0000,故 拒绝原假设,认为 FE 优于混合回归。

由于未使用聚类稳健标准误,此F检验并不有效。

进一步通过 LSDV 法来考察 (将估计结果记为"LSDV"):

- . reg ltvfo ltlan ltwlab ltpow ltfer hrs mipric1
 giprice mci ngca i.province, vce(cluster province)
 - . estimates store LSDV

(Std. Err. adjusted for 28 clusters in province)

		(Sta. Err	adjust	ted for 2	8 clusters in	province)
ltvfo	Coef.	Robust Std. Err.	t	P> t	[95% Conf.	Interval]
ltlan	.6370234	.1732267	3.68	0.001	.2815916	.9924553
ltwlab	.1387786	.0643506	2.16	0.040	.0067421	.2708151
ltpow	.0577152	.0778457	0.74	0.465	1020109	.2174414
ltfer	.1826281	.0449126	4.07	0.000	.0904751	.2747811
hrs	.2134022	.0402952	5.30	0.000	.1307233	.296081
mipricl	.0543577	.0608214	0.89	0.379	0704375	.1791529
giprice	0151451	.0253419	-0.60	0.555	0671423	.0368522
mci	.1943697	.0793856	2.45	0.021	.0314839	.3572555
ngca	.7562031	.3937018	1.92	0.065	0516063	1.564013
province						
beijing	1816498	.1247829	-1.46	0.157	4376832	.0743835
fujian	.051657	.0501916	1.03	0.313	0513277	.1546418
gansu	8165674	.1380808	-5.91	0.000	-1.099886	5332489
guangdong	010488	.055811	-0.19	0.852	1250028	.1040268
guangxi	2304637	.0570853	-4.04	0.000	3475932	1133342
guizhou	2350768	.0615353	-3.82	0.001	3613369	1088167
hebei	2923854	.0997217	-2.93	0.007	4969974	0877733
heilongjiang	1410195	.2892268	-0.49	0.630	7344638	.4524249
henan	0904581	.0435714	-2.08	0.048	1798593	0010569
hubei	.1118905	.0340584	3.29	0.003	.0420085	.1817725
hunan	0373775	.0607647	-0.62	0.544	1620563	.0873014
jiangsu	.1150954	.0342058	3.36	0.002	.0449109	.18528
jiangxi	1352577	.0579781	-2.33	0.027	2542188	0162965
jilin	2220282	.2253552	-0.99	0.333	6844189	.2403624
liaoning	2789811	.172656	-1.62	0.118	6332419	.0752797
neimong	9288069	.2561317	-3.63	0.001	-1.454346	403268
ningxia	8813594	.1975659	-4.46	0.000	-1.286731	4759877
qinghai	7062497	.1521719	-4.64	0.000	-1.018481	3940187
shaanxi	3342067	.0925991	-3.61	0.001	5242045	144209
shangdong	0049215	.0581511	-0. 5 63	0.933	1242377	.1143947
shanghai	.113901	.0648627	1.76	0.090	0191862	.2469882
shanxi	5312338	.1514863	-3.51	0.002	8420581	2204095
sichuan	.0251618	.0320732	0.78	0.440	040647	.0909707
tianjin	3047612	.1190042	-2.56	0.016	5489376	0605848
xinjiang	4007117	.2397817	-1.67	0.106	8927032	.0912797
THIRDON	2771512	A622712	1 20	0 000	10777E7	1 476201

不少个体虚拟变量在 5%水平上显著,可拒绝"所有个体虚拟变量都为 0"的原假设,认为存在个体固定效应,不应使用混合回归。

LSDV 法的回归系数与组内估计量完全相同,但聚类稳健的标准误略有差别。

对于固定效应模型,也可使用一阶差分法(FD)。

Stata 没有专门执行一阶差分法的命令,但在使用命令"xtserial,output"对组内自相关进行检验时,可附带提供一阶差分法的估计结果(将此结果记为"FD"):

- . xtserial ltvfo ltlan ltwlab ltpow ltfer hrs mipric1 giprice mci ngca, output
 - . estimates store FD

Linear regress	sion				Number of ok)s =	420
					F(9, 27	7) =	902.61
					Prob > F	=	0.0000
					R-squared	=	0.5797
					Root MSE	=	.11179
		(Std. Err.	adjuste	ed for	28 clusters i	ln pr	ovince)
D.ltvfo	Coef.	Robust Std. Err.	t	P> t	[95% Conf	i. In	terval]

D.ltvfo	Coef.	Robust Std. Err.	t	P> t	[95% Conf.	Interval]
ltlan D1.	.9807158	.0926143	10.59	0.000	.790687	1.170745
ltwlab D1.	.2420082	.0734117	3.30	0.003	.0913798	.3926366
ltpow D1.	0171023	.0747984	-0.23	0.821	170576	.1363714
ltfer D1.	.2768317	.0589799	4.69	0.000	.155815	.3978485
hrs D1.	. 2427773	.0372382	6.52	0.000	.1663709	.3191837
mipric1 D1.	.0250908	.0357935	0.70	0.489	0483513	.0985329
giprice D1.	0157708	.021774	-0.72	0.475	0604473	.0289057
mci D1.	.1314675	.1260309	1.04	0.306	1271266	.3900616
ngca D1.	0260777	.4846049	-0.05	0.957	-1.020405	.9682494

58

Wooldridge test for autocorrelation in panel data HO: no first-order autocorrelation

F(1, 27) = 12.511

Prob > F = 0.0015

一阶差分估计量(FD)的估计系数与组内估计量(FE)有一定差别。

FE 比 FD 更有效率,故较少使用 FD。

也可在固定效应模型中考虑时间效应,即双向固定效应(Two-way FE),以捕捉技术进步等效应。

为节省待估参数,首先加入时间趋势项(将估计结果记为"FE_trend"):

- . xtreg ltvfo ltlan ltwlab ltpow ltfer hrs mipric1 giprice mci ngca t,fe r
 - . estimates store FE_trend

ixed-effects	(within) reg	ression		Number	of obs =	476
roup variabl	e: province			Number	of groups =	28
-sq: within	= 0.8749			Obs per	group: min =	17
between	n = 0.6490				avg =	17.0
overal	1 = 0.7006				max =	17
				F(10,27	') =	247.93
orr(u_i, Xb)	= -0.3767			Prob >	F =	0.0000
		(Std. Er	r. adjust	ted for 2	8 clusters in	province)
		Robust				
ltvfo	Coef.	Std. Err.	t	P> t	[95% Conf.	Interval]
ltlan	.6517195	.1843858	3.53	0.001	.2733911	1.030048
ltwlab	.1431791	.0589267	2.43	0.022	.0222716	.2640866
ltpow	.0366317	.0991178	0.37	0.715	1667413	.2400047
ltfer	.180359	.0428995	4.20	0.000	.0923365	.2683816
hrs	.1916276	.0295596	6.48	0.000	.1309763	.2522789
mipric1	.0198772	.0515121	0.39	0.703	0858168	.1255713
giprice	026268	.0226875	-1.16	0.257	0728189	.0202829
mci	.2014685	.078794	2.56	0.016	.0397965	.3631404
ngca	.6761116	.421738	1.60	0.121	1892234	1.541447
t	.0063068	.0106492	0.59	0.559	0155436	.0281572
_cons	2.36174	.8262751	2.86	0.008	.6663633	4.057116
sigma_u	.30327958					
D=9a_a						
sigma_e	.10589784					

时间趋势项 t 并不显著,而主要变量的显著性不变。

其次,加入年度虚拟变量。为演示目的,定义年度虚拟变量: . tab year,gen(year)

year	Freq.	Percent	Cum.
70	28	5.56	5.56
71	28	5.56	11.11
72	28	5.56	16.67
73	28	5.56	22.22
74	28	5.56	27.78
75	28	5.56	33.33
76	28	5.56	38.89
77	28	5.56	44.44
78	28	5.56	50.00
79	28	5.56	55.56
80	28	5.56	61.11
81	28	5.56	66.67
82	28	5.56	72.22
83	28	5.56	77.78
84	28	5.56	83.33
85	28	5.56	88.89
86	28	5.56	94.44
87	28	5.56	100.00
Total	504	100.00	· · · · · · · · · · · · · · · · · · ·

此命令将生成时间虚拟变量 year1, year2, ..., year18。

加入年度虚拟变量后,由于价格变量 mipric1 与 giprice 在各省都一样,无法包括在回归方程中,以避免严格多重共线性。

进行含时间虚拟变量的双向固定效应估计(将结果记为"FE_TW"):

- . xtreg ltvfo ltlan ltwlab ltpow ltfer hrs mci ngca year2-year18,fe r
 - . estimates store FE_TW

note: year11 omitted because of collinearity Fixed-effects (within) regression 476 Number of obs Group variable: province Number of groups = 28 R-sq: within = 0.8932Obs per group: min = 17 between = 0.659617.0 avg = overall = 0.7156max = 17 F(23,27) 949.82 $corr(u_i, Xb) = -0.3425$ Prob > F 0.0000 (Std. Err. adjusted for 28 clusters in province) Robust ltvfo Coef. Std. Err. P>|t| [95% Conf. Interval] ltlan .5833594 .1745834 3.34 0.002 .2251439 .9415749 .271545 ltwlab .1514909 .0585107 2.59 0.015 .0314368 .0971114 .2836453 ltpow .090911 1.07 0.295 -.0894225 ltfer .1693346 .0438098 3.87 0.001 .0794444 .2592248 .1503752 .2709368 hrs .0587581 2.56 0.016 .0298136 mci .1978373 .0810587 2.44 0.022 .0315186 .364156 1.94 .7784081 .4016301 0.063 -.0456688 1.602485 ngca year2 -.0240404 .023366 -1.03 0.313 -.0719836 .0239027 -.2154272 -.0492977 year3 -.1323624 .0404832 -3.27 0.003 -.0377336 .0356979 year4 .0357883 -1.05 0.301 -.111165 .0058554 .0500774 0.12 0.908 -.096895 .1086058 year5 .0096731 0.17 0.866 .1259911 .0566898 -.1066448 year6 -.0476465 .061423 -0.78 0.445 -.1736761 .0783832 year7 -.0869336 .0680579 -1.28 0.212 -.2265767 .0527096 year8 -.0325205 .0766428 -0.42 0.675 -.1897785 .1247376 year9 year10 -.0076332 .0833462 -0.09 0.928 -.1786454 .163379 (omitted) year11 0 year12 -.093479 .1093614 -0.85 0.400 -.3178701 .1309121 year13 -.0447862 .1207405 -0.37 0.714 -.2925251 .2029528 -.0309435 .1377207 0.824 -.313523 .2516361 year14 -0.22 .3374117 year15 .0442535 .1428764 0.31 0.759 -.2489048 -.0033372 .1561209 0.983 .3169965 year16 -0.02 -.3236709 .00484 .157992 0.03 0.976 -.3193329 .3290129 year17 year18 .0386475 .1639608 0.24 0.815 -.2977723 .3750674 2.651286 .7738994 1.063376 4.239196 _cons 3.433 0.002 sigma_u .29344594 sigma_e .09930555 rho .89724523 (fraction of variance due to u_i)

year1(1970年)作为基期,不包括在上述回归命令中。

1980年的 hrs 数据缺失,故 year11(1980年)也被去掉。

在双向固定效应模型中,hrs 也在5%水平上显著为正。

大多数的年度虚拟变量均不显著 (但 year3 在 1%水平上显著)。

检验所有年度虚拟变量的联合显著性:

. test year2 year3 year4 year5 year6 year7 year8 year9 year10 year12 year13 year14 year15 year16 year17 year18

```
(1) year2 = 0
(2) year3 = 0
(3) year4 = 0
(4) year5 = 0
(5) year6 = 0
(6) year7 = 0
(7) year8 = 0
(8) year9 = 0
(9) year10 = 0
(10) year12 = 0
(11) year13 = 0
(12) year 14 = 0
(13) year15 = 0
(14) year16 = 0
(15) year17 = 0
(16) year18 = 0
     F( 16,
              27) =
                    14.82
                       0.0000
          Prob > F =
```

强烈拒绝"无时间固定效应"的原假设,应在模型中包括时间固定效应。

在 Stata 13 中, 还可直接用以下命令来估计双向固定效应模型(不必先生成时间虚拟变量):

. xtreg ltvfo ltlan ltwlab ltpow ltfer hrs mci ngca i.year,fe r

其中,"i.year"表示根据变量 year 的不同取值来生成年度虚拟变量。

Fixed-effects (within) regression	Number of obs	=	476
Group variable: province	Number of groups	=	28
R-sq: within = 0.8932	Obs per group: min	=	17
between = 0.6596	avg	=	17.0
overall = 0.7156	max	=	17
	F(23,27)	=	949.82
$corr(u_i, Xb) = -0.3425$	Prob > F	=	0.0000

(Std. Err. adjusted for 28 clusters in province)

		•				/
ltvfo	Coef.	Robust Std. Err.	t	P> t	[95% Conf.	Interval]
ltlan	.5833594	.1745834	3.34	0.002	.2251439	.9415749
ltwlab	.1514909	.0585107	2.59	0.015	.0314368	.271545
ltpow	.0971114	.090911	1.07	0.295	0894225	.2836453
ltfer	.1693346	.0438098	3.87	0.001	.0794444	.2592248
hrs	.1503752	.0587581	2.56	0.016	.0298136	.2709368
mci	.1978373	.0810587	2.44	0.022	.0315186	.364156
ngca	.7784081	.4016301	1.94	0.063	0456688	1.602485
year						
71	0240404	.023366	-1.03	0.313	0719836	.0239027
72	1323624	.0404832	-3.27	0.003	2154272	0492977
73	0377336	.0357883	-1.05	0.301	111165	.0356979
74	.0058554	.0500774	0.12	0.908	096895	.1086058
75	.0096731	.0566898	0.17	0.866	1066448	.1259911
76	0476465	.061423	-0.78	0.445	1736761	.0783832
77	0869336	.0680579	-1.28	0.212	2265767	.0527096
78	0325205	.0766428	-0.42	0.675	1897785	.1247376
79	0076332	.0833462	-0.09	0.928	1786454	.163379
81	093479	.1093614	-0.85	0.400	3178701	.1309121
82	0447862	.1207405	-0.37	0.714	2925251	.2029528
83	0309435	.1377207	-0.22	0.824	313523	.2516361
84	.0442535	.1428764	0.31	0.759	2489048	.3374117
85	0033372	.1561209	-0.02	0.983	3236709	.3169965
86	.00484	.157992	0.03	0.976	3193329	.3290129
87	.0386475	.1639608	0.24	0.815	2977723	.3750674
_cons	2.651286	.7738994	3.4 3 7	0.002	1.063376	4.239196
sigma_u	.29344594					
sigma_e	.09930555					
rho	.89724523	(fraction	of variar	nce due	to u_i)	

4. 随机效应

个体效应还可能以随机效应(RE)的形式存在。

随机效应估计的 Stata 命令为

xtreg y x1 x2 x3, re r theta

选择项 "re"为默认选项(可省略);

选择项"r"表示使用聚类稳健标准误。如使用选择项"vce(cluster id)"也能达到相同效果。

选择项"theta"表示显示用于进行广义离差变换的 θ 值。

对于随机效应模型,也可进行 MLE 估计,Stata 命令为 xtreg y x1 x2 x3,mle

进行随机效应(RE)的估计(将结果记为"RE_robust"):

- . xtreg ltvfo ltlan ltwlab ltpow ltfer hrs mci ngca, re r theta
 - . estimates store RE_robust

Random-effect	s GLS regression	l	Number of obs	=	476
Group variable	e: province		Number of groups	s =	28
R-sq: within	= 0.8700		Obs per group: 1	min =	17
between	n = 0.8135		ć	avg =	17.0
overal	1 = 0.8263		r	max =	17
			Wald chi2(7)	=	2452.50
corr(u_i, X)	= 0 (assumed)		Prob > chi2	=	0.0000
theta	= .81012778				
		(Std. Err. adjust	ed for 28 cluster	rs in p	province)

		Robust				
ltvfo	Coef.	Std. Err.	z	P> z	[95% Conf.	Interval]
ltlan	.5655915	.1089863	5.19	0.000	.3519823	.7792007
ltwlab	.1441844	.0462225	3.12	0.002	.0535899	.234779
ltpow	.060477	.0508828	1.19	0.235	0392515	.1602055
ltfer	.1882741	.0386418	4.87	0.000	.1125376	.2640107
hrs	.2186096	.0377121	5.80	0.000	.1446952	.2925241
mci	.4702368	.0836862	5.62	0.000	.306215	.6342587
ngca	.6745175	.3663329	1.84	0.066	0434818	1.392517
_cons	2.387878	.5672669	4.21	0.000	1.276055	3.499701
sigma_u	.13324845					
sigma_e	.10624809					
rho	.6113231	l (fraction of variance due to u_i)				

最后三行显示, σ_u = 0.13324845, σ_{ε} = 0.10624809, $\rho \equiv \frac{\sigma_u^2}{\sigma_u^2 + \sigma_{\varepsilon}^2}$ = 0.6113231。

究竟使用混合回归,还是个体随机效应模型?

Breusch and Pagan (1980)提供了检验个体随机效应的LM 检验,原假设为" $H_0:\sigma_u^2=0$ ",备择假设为" $H_1:\sigma_u^2\neq0$ "。

如拒绝 H_0 ,则模型中应有反映个体特性的随机扰动项 u_i ,而不应使用混合回归。

该LM 检验的Stata命令为"xttest0"(在执行命令"xtreg,re"之后才能进行)。

. xttest0

```
Breusch and Pagan Lagrangian multiplier test for random effects
        ltvfo[province,t] = Xb + u[province] + e[province,t]
        Estimated results:
                                          sd = sqrt(Var)
                                  Var
                   ltvfo
                              .2893078
                                             .5378734
                              .0112887
                                             .1062481
                              .0177551
                                             .1332484
                       u
                Var(u) = 0
        Test:
                              chibar2(01) = 1235.75
                          Prob > chibar2 =
                                              0.0000
```

LM 检验拒绝 "不存在个体随机效应"的原假设(p值 0.0000), 认为应选择"随机效应"。 看一下使用普通标准误的随机效应估计(将结果记为"RE")。

- . xtreg ltvfo ltlan ltwlab ltpow ltfer hrs mci ngca,re
 - . estimates store RE

andom-effect	s GLS regress	ion		Number o	of obs =	476
roup variabl	e: province			Number o	of groups =	28
-sq: within	= 0.8700			Obs per	group: min =	17
betwee	n = 0.8135				avg =	17.0
overal	1 = 0.8263				max =	17
				Wald ch	i2(7) =	2981.73
rr(u_i, X)	= 0 (assume	d)		Prob > 0	chi2 =	0.0000
	Ţ					
ltvfo	Coef.	Std. Err.	Z	P> z	[95% Conf.	Interval]
ltlan	.5655915	.0478214	11.83	0.000	.4718633	.6593196
ltwlab	.1441844	.0233398	6.18	0.000	.0984394	.1899295
ltpow	.060477	.0252917	2.39	0.017	.0109062	.1100478
ltfer	.1882741	.0208337	9.04	0.000	.1474408	.2291075
hrs	.2186096	.0216932	10.08	0.000	.1760918	.2611275
mci	.4702368	.064681	7.27	0.000	.3434643	.5970093
ngca	.6745175	.2121571	3.18	0.001	.2586973	1.090338
_cons	2.387878	.2895274	8.25	0.000	1.820414	2.955341
	.13324845					
sigma_u	1					
sigma_u sigma_e	.10624809					

作为对照,对随机效应模型进行 MLE 估计(将结果记为"MLE"):

- . xtreg ltvfo ltlan ltwlab ltpow ltfer hrs mci ngca, mle nolog
 - . estimates store MLE

476	os =	mber of obs	Num	Random-effects ML regression				
28	Number of groups =			Group variable: province				
17	up: min =	s per group	Obs		an	u_i ~ Gaussi	andom effects	
17.0	avg =							
17	max =							
961.00	=	chi2(7)	LR					
0.0000	=	ob > chi2	Pro		39	= 332.8973	og likelihood	
Interval]	95% Conf.	z [95	P>	Z	Std. Err.	Coef.	ltvfo	
.6659326	.462725	000 .4	0.0	10.89	.0518396	.5643288	ltlan	
.1869882	948067	000 .09	0.0	5.99	.0235161	.1408974	ltwlab	
.1204231	229794	.02	0.0	2.88	.0248585	.0717013	ltpow	
.2175927	1368127	.13	0.0	8.60	.0206075	.1772027	ltfer	
.2564602	L741926	.17	0.0	10.26	.020987	.2153264	hrs	
.546201	2667654	.20	0.0	5.70	.0712859	.4064832	mci	
1.127645	3023172	.30	0.0	3.40	.2105466	.7149811	ngca	
3.08628	.894744	000 1.8	0.0	8.19	.3039688	2.490512	_cons	
.2864107	L600597	.16			.0317827	.2141094	/sigma_u	
.1133278	0993371	.09			.0035665	.1061021	/sigma_e	
.11332/0		.69			.0486812	.8028448	rho	

上表最后一行的LR检验强烈拒绝原假设" $H_0: \sigma_u = 0$ ",认为存在个体随机效应,不应进行混合回归。

随机效应 MLE 的系数估计值与 FGLS 有所不同, 但在性质上依然类似。

5. 固定效应还是随机效应: 豪斯曼检验

处理面板数据时, 究竟使用固定效应还是随机效应是基本问题。

为此,需进行豪斯曼检验。

豪斯曼检验的 Stata 命令为

xtreg y x1 x2 x3,fe (固定效应估计)

estimates store FE (存储结果)

xtreg y x1 x2 x3,re (随机效应估计)

estimates store RE (存储结果)

hausman FE RE, constant sigmamore (豪斯曼检验)

选择项 "constant"表示在比较系数估计值时包括常数项(默认不含常数项);选择项 "sigmamore"表示统一使用更有效率的那个估计量(即随机效应估计量)的方差估计。

hausman FE RE, constant sigmamore

	(b) FE	(B) RE	(b-B) Difference	sqrt(diag(V_b-V_B)) S.E.
ltlan	.6399658	.5655915	.0743743	.0476709
ltwlab	.1239927	.1441844	0201917	.0125808
ltpow	.0771604	.060477	.0166834	.0081232
ltfer	.1762775	.1882741	0119966	.0078425
hrs	.2075817	.2186096	0110279	.0052769
mci	.2580359	.4702368	2122009	.0583709
ngca	.7722795	.6745175	.097762	.0828671
_cons	2.310114	2.387878	0777638	.2078242

B = inconsistent under Ha, efficient under Ho; obtained from xtreq

Test: Ho: difference in coefficients not systematic

 $chi2(8) = (b-B)'[(V_b-V_B)^(-1)](b-B)$

48.49 Prob>chi2 = 0.0000

(V_b-V_B is not positive definite)

拒绝"H₀:u_i与解释变量不相关",应使用固定效应模型, 随机效应模型。

传统的豪斯曼检验假定,在 H_0 成立情况下,随机效应模型最有效率,在异方差情况下不适用。

下载非官方命令 xtoverid 进行稳健的豪斯曼检验。

"overid" 指 "overidentification test" (过度识别检验)。

随机效应模型与固定效应模型相比,前者多了"个体异质性 u_i 与解释变量不相关"的约束条件,可视为过度识别条件。

. ssc install xtoverid (下载安装命令 xtoverid)

在使用命令 xtoverid 之前,须先以稳健标准误执行命令 "xtreg,re"。

- . quietly xtreg ltvfo ltlan ltwlab ltpow ltfer hrs mci ngca,r
 - . xtoverid

```
Test of overidentifying restrictions: fixed vs random effects

Cross-section time-series model: xtreg re robust cluster(province)

Sargan-Hansen statistic 221.225 Chi-sq(7) P-value = 0.0000
```

 χ^2 (7)统计量为 221.225, p值为 0.0000,仍拒绝随机效应。

6. 组间估计量

为演示目的,进行组间估计。

. xtreg ltvfo ltlan ltwlab ltpow ltfer hrs mci ngca, be

Between regres	ssion (regress	sion on group	p means)	Number	of obs =	476	
Group variable	Number	of groups =	28				
R-sq: within	= 0.4673			Obs per	group: min =	17	
between	n = 0.9362				avg =	17.0	
overall	= 0.0232				max =	17	
				F(7,20)	=	41.93	
sd(u_i + avg(e	e_i.))= .1355	7173		Prob >	F =	0.0000	
ltvfo	Coef.	Std. Err.	t	P> t	[95% Conf.	Interval]	
ltlan	.7021718	.1177241	5.96	0.000	.4566037	.9477398	
ltwlab	.5020747	.0940029	5.34	0.000	.3059881	.6981612	
ltpow	1511518	.1188815	-1.27	0.218	3991344	.0968307	
ltfer	.1132485	.0976941	1.16	0.260	0905377	.3170347	
hrs	-3.757418	1.242961	-3.02	0.007	-6.350189	-1.164647	
mci	.586029	.1838616	3.19	0.005	.2025005	.9695575	
ngca	.4443814	.6565795	0.68	0.506	9252194	1.813982	
_cons	2.432839	1.005985	2.42	0.025	.3343904	4.531288	
		· · · · · · · · · · · · · · · · · · ·					

豪斯曼检验选择了固定效应,而组间估计量仅在随机效应情况 下才一致,故组间估计结果不可信。 例如,根据组间估计量, hrs 在 1%水平上显著为负,即家庭联产承包责任制反而对种植业产值有负作用。

将以上各主要方法的回归系数及标准误列表(为节省空间,不汇报包含年度虚拟变量的双向固定效应):

. esttab OLS FE_robust FE_trend FE RE, b se mtitle

	(1) OLS	(2) FE_robust	(3) FE_trend	(4) FE	(5) RE
ltlan	0.694***	0.637***	0.652**	0.640***	0.566***
	(0.115)	(0.168)	(0.184)	(0.0644)	(0.0478)
ltwlab	0.265***	0.139*	0.143*	0.124***	0.144***
	(0.0566)	(0.0625)	(0.0589)	(0.0253)	(0.0233)
ltpow	-0.0292	0.0577	0.0366	0.0772**	0.0605*
	(0.0670)	(0.0756)	(0.0991)	(0.0253)	(0.0253)
ltfer	0.311***	0.183***	0.180***	0.176***	0.188***
	(0.0531)	(0.0436)	(0.0429)	(0.0212)	(0.0208)
hrs	0.229***	0.213***	0.192***	0.208***	0.219***
	(0.0489)	(0.0391)	(0.0296)	(0.0213)	(0.0217)
mipricl	0.0122	0.0544	0.0199		
	(0.0548)	(0.0590)	(0.0515)		
giprice	-0.0539	-0.0151	-0.0263		
	(0.0274)	(0.0246)	(0.0227)		
mci	0.695***	0.194*	0.201*	0.258**	0.470***
	(0.169)	(0.0771)	(0.0788)	(0.0831)	(0.0647)
ngca	0.305	0.756	0.676	0.772***	0.675**
_	(0.522)	(0.382)	(0.422)	(0.217)	(0.212)
t			0.00631		
			(0.0106)		
_cons	1.081	2.338*	2.362**	2.310***	2.388***
	(0.827)	(0.855)	(0.826)	(0.340)	(0.290)
N	476	476	476	476	476